



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

熊壮 博士

医工交叉研究院

Interdisciplinary Institute for Medical Engineering

bioinformatics_fzu@163.com

明德至诚 博学远志




课程基本信息



生物信息学202...

群号: 1075712665



扫一扫二维码，加入群聊



■ 课程成绩

• 平时成绩40%

- 出勤 15%
- 课堂作业 10%
- 小组汇报 15%

• 期末考试60%

- 结课后考试



课程大纲

第一章 生物信息学概论 (3学时)

第二章 生物学数据库及其检索 (3学时)

第三章 测序技术 (12学时)

第四章 多组学数据分析 (12学时)

第五章 系统生物学 (6学时)

第六章 统计及机器学习在生物信息学中的应用 (6学时)

第一次上机实验 (6学时)

第二次上机实验 (6学时)

第三次上机实验 (6学时)



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

第一章 生物信息学概论

明德至诚 博学远志



主要内容

1. 背景
2. 什么是生物信息学
3. 生物信息学发展简史
4. 生物信息学的主要研究内容
5. 生物信息学的应用
6. 我国生物信息学的发展与挑战



背景

引领新质生产力发展方面

28项 重大工程项目

产业基础能力和竞争力提升

- 01 高端新材料
- 02 基础零部件和元器件
- 03 基础软件和工业软件
- 04 工业母机
- 05 高端仪器仪表
- 06 重大技术装备

新产业新赛道培育发展

- 01 集成电路
- 02 具身智能
- 03 生物制造
- 04 新型电池
- 05 商业航天
- 06 国产大飞机
- 07 低空装备
- 08 绿色氢能
- 09 脑机接口
- 10 高端医疗器械

前沿科技攻关

- 01 人工智能
- 02 量子科技
- 03 可控核聚变
- 04 生命科学与生物技术
- 05 脑科学与类脑研究
- 06 重大疾病防治与创新药研发
- 07 深海深地极地探测
- 08 深空探索

创新基础能力提升


- 01 国家实验室体系
- 02 重大科技基础设施
- 03 区域创新体系
- 04 科技基础条件平台

明德至诚 博学远志





背景

我从哪里来?



受精过程

HUMAN EMBRYONIC DEVELOPMENT



胚胎发育



成长成才




我要到哪里去?

明德至诚 博学远志



背景

Genome: the “manual of life” -- *Almost*



表观遗传





二十世纪的“三大科学计划”



曼哈顿原子弹计划

(1942-1945)

20亿美元

1945 美国

1964 中国



阿波罗登月计划

(1961-1972)

250亿美元

1969 美国

~2030 中国



人类基因组计划

(1990-2003)

30亿美元


美国、英国、法国

德国、日本、**中国**

明德至诚 博学远志



◆人类基因组计划HGP (Human Genome Project)




- 目的：测定人类基因组全部DNA序列，构建人类基因组遗传图谱。
- 由美国NIH和能源部提出和带头，美、英、德、法、日、**中**共同参与的国际合作项目。
- 1990年：正式启动，**30亿**美元。
- 2001年：人类基因组草图公开发表。
- 2003年：美国宣布该项目完成，完成的人类基因组**30亿**个碱基对序列的确定，识别出约**30,000**个基因。

3号染色体短臂上约
30Mb的测序任务



背景



人类基因组含有约**30亿**个DNA碱基对

编码蛋白质的区域约占**1.5%**

非编码RNA

调控序列

功能未知的区域

...

明德至诚 博学远志



背景

[illegible]

我们如何来解读生命之书呢？



如果每行打印**100**个字符，每页**50**行

你将填满**600000**页，堆叠**60米**高



如果每秒读1个碱基

不吃饭不睡觉 也要读**100年**

截至2023年，全球测序的碱基数目总计规模已达到数百亿亿个碱基对（exabase级别，1 exabase = 10^{18} 碱基对）


CGTGACCTTAAGTCGCAGAGCGAGTGATGAATTTGGGACGCTAATATGGGTGAATAGAGACTTATATCATCAGGG

明德至诚 博学远志




什么是生物信息学


生物计量学
(**bi**ometrics)




生物数学
(**bi**omathmatics)




生物化学
(**bio**chemistry)



bioinformatics?




生物物理学
(**bio**physics)



明德至诚 博学远志



什么是生物信息学



Hwa A. Lim
林华安

Bioinformatics is a new subject of genetic data collection, analysis and dissemination to the research community (1987)

生物信息学是一门收集、分析遗传数据以及分发给研究机构的新学科。

Bioinformatics refers to database-like activities, involving persistent sets of data that are maintained in a consistent state over essentially indefinite periods of time (1994)

生物信息学特指数据库类的工作，包括持久稳固的在一个稳定的地方提供对数据的支持。



什么是生物信息学

Biology + Informatics = Bioinformatics

But

1 + 1 $\neq$ 2

重点

- ◆ 生物信息学是一门**交叉学科**，它包含了**生物信息的获取、处理、存储、分发、分析和解释**等在内的所有方面，它**综合运用数学、计算机科学和生物学的各种工具**，来阐明和理解大量数据所包含的**生物学意义**。

(美国人类基因组计划第一个五年总结报告, 1995)

明德至诚 博学远志



什么是生物信息学

N.M. Luscombe,
D. Greenbaum,
M. Gerstein

Department of Molecular Biophysics
and Biochemistry
Yale University
New Haven, USA

Review

What is bioinformatics? An introduction and overview

Abstract: A flood of data means that many of the challenges in biology are now challenges in computing. Bioinformatics, the application of computational techniques to analyse the information associated with biomolecules on a large-scale, has now firmly established itself as a discipline in molecular biology, and encompasses a wide range of subject areas from structural biology, genomics to gene expression studies.

In this review we provide an introduction and overview of the current state of the field. We discuss the main principles that underpin bioinformatics analyses, look at the types of biological information and databases that are commonly used, and finally examine some of the studies that are being conducted, particularly with reference to transcription regulatory systems.

Introduction

Biological data are flooding in at an unprecedented rate (1). For example as of August 2000, the GenBank repository of nucleic acid sequences contained 8,214,000 entries (2) and the SWISS-PROT database of protein sequences contained 88,166 (3). On average,

Bioinformatics - a definition¹

(Molecular) **bio-informatics**: bioinformatics is conceptualising biology in terms of molecules (in the sense of physical chemistry) and applying "**informatics techniques**" (derived from disciplines such as applied maths, computer science and statistics) to **understand** and **organise** the **information** associated with these molecules, on a **large scale**. In short, bioinformatics is a management information system for molecular biology and has many

¹ As submitted to the Oxford English Dictionary

2001：生物信息学是在**大分子**方面的概念型的生物学，并且使用了信息学的技术，这包括了从**应用数学、计算机科学以及统计学**等学科衍生而来各种方法，并以此在**大尺度**上来理解和组织与生物大分子相关的信息。




什么是生物信息学

- **广义生物信息学观点**：生物学研究可以被看成是研究**信息的传递**：从DNA经转录翻译到蛋白质，从细胞质中到细胞核内，从母细胞到子细胞，从一个细胞或一个组织到另一个细胞或另一个组织，从一代到下一代，从一个物种到另一个物种的进化演变。这种信息论的观点即可称为生物信息学。

(Bioinformatic challenges for the next decade(s), David Eisenberg et al., 2006)

Roadmap of Bioinformatics





生物信息学发展简史

生物 (1809年)



拉马克 (法国, 1744-1829)

第一个提出进化论的人!
生物学伟大的奠基人!
进化论的倡导者和先驱!

- 拉马克主义:
 - 用进废退
 - 获得性遗传
- 拉马克认为: 生物经常使用的器官会逐渐发达, 如铁匠的手臂较粗, 而不使用的器官会逐渐退化。

信息 (1642年)



帕斯卡三件事:

压强、三角、计算机


- 压强单位pa,就是为了纪念法国物理学家帕斯卡而命名。
- 帕斯卡三角 (1654年) 在中国叫杨辉三角 (1261年), 贾宪三角 (1050年)。
- 19岁, 帕斯卡发明了人类有史以来第一台机械计算机。

帕斯卡 (法国, 1623-1662)



生物信息学发展简史

生物 (1859年)



达尔文 (英国, 1809-1882)

进化论的奠基人!

- 《物种起源》
 - 自然选择
 - 适者生存
- 恩格斯将“进化论”列为**十九世纪自然科学的三大发现之一**。

细胞学说、能量守恒定律

信息 (1700年)



莱布尼茨 (德国, 1646-1716)

历史上少见的通才!

- 莱布尼茨认为：数理逻辑、数学和计算机三者均出于一个统一的目的，即人的思维过程的演算化、计算机化、以至于在计算机上实现。
- 莱布尼茨**首次提出“计算机”这一概念**。

明德至诚 博学远志



生物信息学发展简史

生物 (1866年)




孟德尔 (奥地利, 1822-1884)

遗传学的奠基人!
现代遗传学之父!

- 1866年, 发表《植物杂交试验》。提出了遗传因子 (现称基因)、显隐性性状等重要概念, 并阐明其遗传规律。
- 直到1900年, 孟德尔定律才被认可。

信息 (1844年)



摩尔斯 (美国, 1791-1872)

- 1844年摩尔斯在美国国会议事厅里发出世界上地一封电报。
- 1858年, 横跨大西洋连接欧美两洲的海底电缆铺设成功。
- 清光绪年间, 有线电报进入中国。

摩尔斯电码的创立者!

明德至诚 博学远志




孟德尔之后生物学迅猛发展



米歇尔(瑞士, 1844-1895)

分离出核酸



约翰森 (丹麦, 1857-1927)

首次提出基因一词



摩尔根 (美国, 1866-1946)

发现染色体的遗传理论

明德至诚 博学远志



生物信息学发展简史

生物(1944年)



Oswald Avery




Colin MacLeod



Maclyn McCarty

1944年，美国微生物学家艾弗里、麦克劳德和麦卡蒂通过实验发现证实生物的遗传物质是 DNA

信息(1936年)



图灵 (英国, 1912-1954)

计算机之父!
人工智能之父!
计算机逻辑奠基者




明德至诚 博学远志



生物信息学发展简史

生物

信息



明德至诚 博学远志



生物信息学发展简史

生物信息

- 1979年美国洛斯阿拉莫斯实验室建立了GenBank数据库，后来成立NCBI。
- 1982年欧洲分子生物学实验室（EMBL）建立了核酸序列数据库(EBI)。
- 1984年日本建立了核酸序列数据库DDBJ。
- 90年代初三大核酸数据库资源共享，联合成立国际核酸序列数据库联盟（INSDC）。
- 1987年美国学者林华安首创了“bioinformatics”一词。

compbio

bioinformatique

bio-informatics

bioinformatics



生物信息学的主要研究内容

◆ 数据库建设与工具开发：生物数据的检索、下载、整合与共享。

EMBL-EBI: The home for big data in biology. We help scientists exploit complex information to make discoveries that benefit humankind. Find tools and resources or deposit data.

NIH National Library of Medicine National Center for Biotechnology Information. Log in. PubMed.gov. Search. Advanced.

国家基因组科学数据中心 National Genomics Data Center. 登录 语言 / Language. 免疫学数字解码重大研究计划.

Gene: Gene integrates information from a wide range of nomenclature, Reference Sequences (RefSeq), phenotypes, and links to genome-, phenotypic-, and clinical data worldwide.

Using Gene: Gene Quick Start, FAQ, Download/FTP, RefSeq Mailing List, Gene News, Factsheet.

Gene Tools: Submit GeneRIFs, Submit Correction, Statistics, BLAST, Genome Workbench, Splign.

数据资源: 原始数据, 基因组和变异, 基因表达, 非编码RNA, 表观基因组, 单细胞组学, 生物多样性和生物合成.




热门资源: BioCode (生物工具软件), BioProject (生物项目库), BioSample (生物样本库), Database Commons (生物数据库目录), GEN (基因表达数据库), GSA (组学原始数据归档库), GSA-Human (人类组学原始数据归档库).

明德至诚 博学远志



生物信息学的主要研究内容


◆ 组学数据分析与解释：包括基因组、转录组、蛋白质组等组学





生物信息学的主要研究内容


◆ 生物系统及网络分析





生物信息学的主要研究内容





◆ 生物系统及网络分析






生物信息学的主要研究内容

◆ 算法、方法开发：开发新的算法及统计学方法来揭示大数据之间的联系



Nature Reviews | Genetics



明德至诚 博学远志



生物信息学的应用

Applications of Bioinformatics



- ◆ **基础研究：** 机体的生理病理机制
 - 衰老、癌症发病机制
- ◆ **临床研究：** 疾病诊断，预后评估
 - 利用病原核酸序列诊断疾病
- ◆ **药物开发：** 新药筛选，药靶设计，老药新用
 - 肿瘤免疫检查点抑制剂
- ◆



生物信息学的应用



安吉丽娜·朱莉

我选择现在说出来，是因为我想让其他女性能从我的经历中获益。癌症仍然是一个大家谈虎色变的词，会让人产生深深的无助感。但是如今，血液检查可以帮助你发现自己是不是属于乳腺癌和卵巢癌的高危人群，从而采取相应的行动。

——安吉丽娜·朱莉

安吉丽娜·朱莉公开信《我的医疗选择》

我母亲在与癌症斗争了十年，一直坚持到看到自己的第一个孙子出身，将他揽入怀中，但她最后在五十六岁时过世。我其他的孩子就没能够与她相处了，也无法知道她是一个多可爱多亲切的外婆。

每次我和孩子们谈及外婆时，我总想能够解释清楚是什么病夺去了他们的外婆。于是孩子们会问，是否这些会发生在自己身上，我告诉孩子们没什么好担心的。但实际上，我身上带有一种能够大幅度增加患乳腺癌和卵巢癌的可能的基BRCA1。

每个带有该基因的人发病概率各不同，我的医生估计，我患上乳腺癌的几率大约是87%，卵巢癌的几率是50%。虽然大部分的乳腺癌病例都非基因所致，但是带有BRCA1基因的人患乳腺癌的几率比平常人平均高出65%。

当我认定“这就是事实”的时候，我决定提前做好预防，选择了做双乳切除手术以减少得病几率。一方面因为自己患乳腺癌的可能性比卵巢癌要高，另一方面也因为这个手术比较复杂。

四月二十七日，结束了为期三个月的治疗过程。在这期间，我一边保守这个消息，一边也没有放下工作。

但是现在我写这封信将这件事告之于众，其原因是我希望其他女性能够从中获益。癌症确实让人们害怕，不过如今已经可以通过血液检查来测定患乳腺癌和卵巢癌的几率。如果这个几率很高，也可以做出反应。

我的手术是从二月二日开始的。最开始做了一个乳头保留术，这个过程十分疼痛，但是能够帮助保留乳头和乳晕部分。两周后，手术进行到主要过程。乳房组织被移出，注入暂时填充物。手术进行了八个小时。朱莉称，醒来时满身的仪器，就像在科幻电影中。而几天后，就能够正常生活。九周后，手术的最后一个阶段也就是乳房重建。这项技术在近些年得到了较大发展，重建后的乳房会很漂亮。

我想通过这封信告诉大家，做这个决定并非易事。但是我很高兴自己做了这个决定。现在，我患乳腺癌的几率从87%降到了5%。终于可以告诉孩子们不必担心会因为乳腺癌而失去他们的母亲。欣慰的是，孩子们对这个过程一无所知，他们能够看到的仅仅是一个小伤疤，其他什么都没变，还是他们原来的妈妈。他们知道我是爱他们的，会为了和他们在一起做一切我能做的是。现在，我并没有感觉自己失去了半点女人味，反觉得自己更坚强了。

幸运的是，我的伴侣，布拉德皮特陪在身边关心我支持我。所以我想对那些妻子或女友正在经历这个手术的男士说，你们在这个过程中是非常关键的。我在医院做手术时，皮特每分每秒都在我身边。我们都知道做这件事对我们的家庭有益，也让我们更加亲密。


读到这封信的女性朋友们，我希望你们知道你们有选择权。我想鼓励每一位女士，特别是有乳腺癌或卵巢癌家族病史的女士，去搜集相关资料、咨询专家，他们能够在这方面帮助到你们，并告诉你们选择。

我感谢轮流为我做手术的优秀的医生们。我自己的经历也会在医院的网站上公布，希望能够帮到其他女性！

明德至诚 博学远志



生物信息学的应用



Y

知识挖掘

知识

Translation

$$Y = f(X)$$

↓

算法模型

算法


Integration

X

数据汇聚

数据

Deposition





我国生物信息学的发展与挑战

中国生物信息学的研究方向

1. 基因组信息学
2. 转录组信息学
3. 表观组信息学
4. 蛋白质组信息学
5. 修饰组信息学
6. 结构信息学
7. 单细胞生物信息学
8. 三维基因组信息学
9. 微生物组信息学
10. 计算癌症基因组学
11. 计算系统生物学
12. 药物信息学
13. 人工生物系统的设计与控制
14. 生物信息数据挖掘方法
15. 生命与健康大数据科学
16. 精准健康信息学
17. 群体遗传与计算演化基因组学
18. 生物影像信息学
19. 植物信息学
20. 生物信息学研究新方向、新技术与新方法

明德至诚 博学远志



我国生物信息学的发展与挑战

我国生信相关学会、协会（二级）

中国细胞生物学学会功能基因组信息学与系统生物学分会

中国生物工程学会计算生物学与生物信息学专业委员会

中国计算机学会生物信息学专委会

中国遗传学会基因组学专业委员会

中国生物物理学会生物信息学与理论生物物理专业委员会

中国生物化学与分子生物学会分子系统生物学专业委员会

中国运筹学会计算系统生物学分会

中国人工智能学会生物信息学与人工生命专业委员会

中国电子学会生物计算与生物信息处理专业委员会

中国医药生物技术协会生物医学信息技术分会

中国交叉科学学会生物信息学专业委员会

中国系统仿真学会生命系统建模仿真专业委员会



我国生物信息学的发展与挑战

中国生物信息学学会（筹）（一级）

地方学会：

内蒙古、北京、福建、广东、广西、黑龙江、湖北、湖南、江苏、山东、陕西、上海、四川、香港、浙江、重庆、吉林、澳门

专业委员会：

数据研究多样性

- ✓ 生物数据资源专委会
- ✓ 基因组信息学专委会
- ✓ 表观遗传信息学专委会
- ✓ 非编码RNA与RNA信息学专委会
- ✓ 生物大分子结构预测与模拟专委会
- ✓ 生物医学影像学专委会

计算-算法与整合

- ✓ 生物信息学算法专委会
- ✓ 生物医学数据挖据与计算分析专委会
- ✓ 人工智能与生命科学专委会
- ✓ 计算合成生物学专委会
- ✓ 网络生物学专委会
- ✓ 计算系统生物学专委会


生物、医学与安全

- ✓ 生物信息学与药物发现专委会
- ✓ 重大疾病组学信息学专委会
- ✓ 农林信息学专委会
- ✓ 转化信息学与数据共享安全专委会
- ✓ 单细胞多组学与整合生物学专委会



我国生物信息学的发展与挑战

中国生物信息学学会（筹）生物数据资源专委会



明德至诚 博学远志



我国生物信息学的发展与挑战

开设了生物信息学的本科院校

北京大学

同济大学

浙江大学

华中科技大学

南方科技大学

中南大学

东南大学

哈尔滨工业大学

华中农业大学

南方医科大学

南京医科大学

华南理工大学

兰州大学

河南大学

苏州大学

河北大学

哈尔滨医科大学

郑州大学

天津医科大学

大连理工大学

重庆医科大学

中国医科大学

香港中文大学 (深圳)

湖北大学

安徽医科大学

福建农林大学

徐州医科大学

福建医科大学

北京交通大学

湖南农业大学

山东第一医科大学



我国生物信息学的发展与挑战

知名企业




<https://www.bgi.com/>

明德至诚 博学远志



我国生物信息学的发展与挑战

知名企业



<https://www.novogene.cn/>

明德至诚 博学远志



我国生物信息学的发展与挑战

知名企业



<https://www.berrygenomics.com/>

明德至诚 博学远志



我国生物信息学的发展与挑战

生命科学研究进入大数据时代


生物数据爆炸式增长



PubMed 科研文献: >3600万

PubMed comprises more than 36 million citations for biomedical literature...

大数据驱动的科学新范式





明德至诚 博学远志



我国生物信息学的发展与挑战

生物AI大模型处于快速发展阶段，已经在蛋白质结构与互作预测、基因调控与表达、药物发现等多个生命科学核心领域展现出变革性潜力



明德至诚 博学远志



我国生物信息学的发展与挑战

AI 需要大数据支撑



nature

Explore content ▾ About the journal ▾ Publish with us ▾

[nature](#) > [articles](#) > article

Article | Published: 08 May 2024

Accurate structure prediction of biomolecular interactions with AlphaFold 3

[Josh Abramson](#), [Jonas Adler](#), [Jack Dunger](#), [Richard Evans](#), [Tim Green](#), [Alexander Pritzel](#), [Olaf Ronneberger](#), [Lindsay Willmore](#), [Andrew J. Ballard](#), [Joshua Bambrick](#), [Sebastian W. Bodenstein](#), [David A. Evans](#), [Chia-Chun Hung](#), [Michael O'Neill](#), [David Reiman](#), [Kathryn Tunyasuvunakool](#), [Zachary Wu](#), [Akvilė Žemgulytė](#), [Eirini Arvaniti](#), [Charles Beattie](#), [Ottavia Bertolli](#), [Alex Bridgland](#), [Alexey Cherepanov](#), [Miles Congreve](#), ... [John M. Jumper](#)  [+ Show authors](#)

[Nature](#) (2024) | [Cite this article](#)

317k Accesses | 5 Citations | 1423 Altmetric | [Metrics](#)

Inputs and data sources

Inputs to the network are the primary sequence, sequences from evolutionarily related proteins in the form of a MSA created by standard tools including jackhmmer⁶⁰ and HHBlits⁶¹, and 3D atom coordinates of a small number of homologous structures (templates) where available. For both the MSA and templates, the search processes are tuned for high recall; spurious matches will probably appear in the raw MSA but this matches the training condition of the network.

One of the sequence databases used, Big Fantastic Database (BFD), was custom-made and released publicly (see 'Data availability') and was used by several CASP teams. BFD is one of the largest publicly available collections of protein families. It consists of 65,983,866 families represented as MSAs and hidden Markov models (HMMs) covering 2,204,359,010 protein sequences from reference databases, metagenomes and metatranscriptomes.

BFD was built in three steps. First, 2,423,213,294 protein sequences were collected from UniProt (Swiss-Prot&TrEMBL, 2017-11)⁶², a soil reference protein catalogue and the marine eukaryotic reference catalogue⁷, and clustered to 30% sequence identity, while enforcing a 90% alignment coverage of the shorter sequences using MMseqs2/Linclust⁶³. This resulted in 345,159,030 clusters. For computational efficiency, we removed all clusters with less than three members, resulting in 61,083,719 clusters. Second, we added 166,510,624 representative protein sequences from Metaclust NR (2017-05; discarding all sequences shorter than 150 residues)⁶³ by aligning them against the cluster rep-

Jumper, J et al. Nature (2021, 2024).


明德至诚 博学远志



我国生物信息学的发展与挑战

国际三大生物信息/数据中心垄断地位

日本1986年



美国 1988年

欧洲 1992年

INSDC: 国际核酸序列数据库联盟

我国一直以来缺乏国家级生物数据中心


- ❑ 数据**流失** – 中国占国际数据库**数据**20%以上
 - 数据主权丧失，国家利益受损
- ❑ 数据**缺失** – 中国占国际数据库**用户**20%以上
 - 技术制约 – 国际网速慢、断网、美国政府停摆
 - 政治制约 – 卡脖子（数据获取、数据递交）
- ❑ 数据**丢失** – 国内数据大多依托项目保存，不可持续，数据孤岛
 - 宝贵数据永久失去
 - 国家资金严重浪费

明德至诚 博学远志



我国生物信息学的发展与挑战

“我国生物数据库的落后现象要有解决方案” —2019年3月



郝柏林院士
(1934-2018)




陈润生院士



赵国屏院士



孙之荣教授



2019/6/5，科技部、财政部联合发布

国家基因组科学数据中心（NGDC）成立

明德至诚 博学远志



我国生物信息学的发展与挑战

Nucleic Acids Research, 2024, 52, D1–D9
https://doi.org/10.1093/nar/gkad1173
Advance access publication date: 30 November 2023
Editorial



The 2024 *Nucleic Acids Research* database issue and the online molecular biology database collection

Daniel J. Rigden^{1,*} and Xosé M. Fernández²

¹Institute of Systems, Molecular and Integrative Biology, University of Liverpool, Crown Street, Liverpool L69 7ZB, UK

²IQVIA Ltd., The Point, 37 North Wharf Road, London W2 1AF, UK

*To whom correspondence should be addressed. Tel: +44 151 795 4467; Email: nardatabase@gmail.com

Abstract

The 2024 *Nucleic Acids Research* database issue contains 180 papers from across biology and neighbouring disciplines. There are 90 papers reporting on new databases and 83 updates from resources previously published in the Issue. Updates from databases most recently published elsewhere account for a further seven. Nucleic acid databases include the new NAKB for structural information and updates from Genbank, ENA, GEO, Tarbase and JASPAR. The Issue's Breakthrough Article concerns MPFamDB for novel prokaryotic protein families and the AlphaFold Protein Structure Database has an important update. Metabolism is covered by updates from Reactome, Wikipathways and Metaboblits. Microbes are covered by RefSeq, UNITE, SPIRE and P10K; viruses by ViralZone and PhageScope. Medically-oriented databases include the familiar COSMIC, Drugbank and TTD. Genomics-related resources include Ensembl, UCSC Genome Browser and Monarch. New arrivals cover plant imaging (OPIA and PlantPAD) and crop plants (SoyMD, TCOD and CropGS-Hub). The entire Database Issue is freely available online on the *Nucleic Acids Research* website (<https://academic.oup.com/nar>). Over the last year the NAR online Molecular Biology Database Collection has been updated, reviewing 1060 entries, adding 97 new resources and eliminating 388 discontinued URLs bringing the current total to 1959 databases. It is available at <http://www.oxfordjournals.org/nar/database/c/>.

New and updated databases

The 31st *Nucleic Acids Research* database issue, in customary fashion, ranges broadly across biology with a total of 180 papers. Last year's recent record of 90 new databases is matched this year (Table 1) while 83 papers report developments from resources previously covered by NAR. Seven further papers provide updates on databases most recently published elsewhere (Table 2). As usual, the issue leads off with reports from the major database providers at the European Bioinformatics Institute (EBI), the U.S. National Center for Biotechnology Information (NCBI), and the National Genomics Data Center (NGDC) in China (1–3). This year they are joined by an article from the SIB Swiss Institute of Bioinformatics (4). The following papers on individual databases are, as usual, grouped into categories: (i) nucleic acid sequence and structure, transcriptional regulation; (ii) protein sequence and structure, proteomics; (iii) metabolic and signalling pathways, enzymes and networks; (iv) genomics of viruses, bacteria, protozoa and fungi; (v) genomics of human and model organisms plus comparative genomics; (vi) human genomic variation, diseases and drugs; (vii) plants and (viii) other topics. As usual, many papers defy easy categorisation and so it is recommended that readers browse the full list.

The 'Nucleic acid databases' section contains a report on a major new repository of nucleic acid structural information, named NAKB (5). Updated weekly, this resource is the successor of the Nucleic Acid Database (6) and provides new annotations, visualisations, search options and database links for Protein Data Bank (PDB) (7) structures that contain nucleic acids. Other interesting new databases cover specific classes of sequence: Ribocentre-switch covers sequence, struc-

ture, function and applications of riboswitches (8), the UTEx Aptamer Database (9) captures literature on aptamers, notably harnessing undergraduate power to increase curation capacity, and TeloBase covers telomere sequences across the tree of life, mining both the literature and sequence databases (10). For sequence information in general, the INSDC consortium (11) members all report updates (12–14); perhaps the most notable is the DDBJ paper which emphasises how their activities increasingly reach beyond nucleic acid sequences, most recently to metabolomics with the establishment of the MetaboBank (14). Elsewhere, two new databases cover full-length sequences from long read technologies. FLIbase (15) covers isoforms in normal and cancerous human tissues, while FL-circAS focuses specifically on circular RNAs and their splice forms (16). They are joined, for the first time in NAR, by the popular circAtlas for vertebrate circular RNAs reporting a tripling of content, inclusion of clinical cancer samples and, importantly, adoption of a standardised circRNA nomenclature (17). Specific epitranscriptomic modifications are covered by updates from m6A-Atlas (18) and m7GHub (19) while RMBase (20) covers data related to 73 distinct modifications in 62 species, and the general database of RNA modifications, pathways and compounds MODOMICS adds novel modifications, both those seen experimentally in ribosome structures and artificial modifications used as experimental tools (21).

In gene expression and regulation, the foundational NCBI Gene Expression Omnibus (GEO) database returns (22) after a gap of 11 years to reflect on the gradual replacement of array-based data with next-generation sequence information, and the growing proportion of studies with a single-cell focus (also very visible in this Issue, see below). The venerable Tar-

published elsewhere (Table 2). As usual, the Issue leads off with reports from the major database providers at the European Bioinformatics Institute (EBI), the U.S. National Center for Biotechnology Information (NCBI), and the National Genomics Data Center (NGDC) in China (1–3). This year they



Received: November 22, 2023; Editorial Decision: November 22, 2023; Accepted: November 23, 2023

© The Author(s) 2023. Published by Oxford University Press on behalf of Nucleic Acids Research.

This is an Open Access article distributed under the terms of the Creative Commons Attribution License (<http://creativecommons.org/licenses/by/4.0/>), which permits unrestricted reuse, distribution, and reproduction in any medium, provided the original work is properly cited.

Nucleic Acids Research, 2024

生物信息学国际权威期刊《核酸研究》连续8年将国家基因组科学数据
中心NGDC与美国NCBI、欧洲EBI共同列为“全球主要数据中心”。
明德至诚 博学远志



我国生物信息学的发展与挑战

CNCB NGDC Databases Tools Standards Publications About

国家基因组科学数据中心 National Genomics Data Center Nstn

Sign in 语言 / Language

National Genomics Data Center

The National Genomics Data Center (NGDC), part of the China National Center for Bioinformation (CNCB), advances life & health sciences by providing open access to a suite of resources, with the aim to translate big data into big discoveries and support worldwide activities in both academia and industry.

All databases Find a bioproject, biosample, gene, protein, tool, database... Search

e.g., PRJCA000126; SAMC000385; tp53; EGFR; human; KaKs_Calculator; GenBank

Congratulations! On 28 September 2021, GSA reached a milestone of over 10 PB raw sequence data archived.

Submit Download BLAST SARS-CoV-2 OpenLB

Resources

- Raw Data & Metadata
- Genome & Variation
- Expression
- Noncoding RNA
- Epigenomics
- Single-cell Omics
- Biodiversity & Biosynthesis
- Health & Disease
- Literature & Education
- Tools

Popular Resources

BioCode Biological Tool Codes	BioProject Biological Project Library	BioSample Biological Sample Library
GSA Genome Sequence Archive	GSA-Human GSA for Human	OMIX Miscellaneous data
GWH Genome Warehouse	GVM Genome Variation Map	Database Commons Biological Database Catalog
GEN Gene Expression Nebulas	MethBank Methylation Bank	eGPS Cloud Cloud platform

基础数据库

- 生物项目数据库 (BioProject)
- 生物样本数据库 (BioSample)
- 原始组学数据归档库 (Genome Sequence Archive)
- 基因序列数据库 (GenBase)
- 基因组数据库 (Genome Warehouse)
- 基因表达数据库 (Gene Expression Nebulas)
- 基因组变异数据库 (Genome Variation Map)
- 甲基化数据库 (Methylation Bank)

特色资源库

- 2019新冠病毒信息库 (RCoV19)
- 表观组关联研究数据资源平台 (EWAS Open Platform)
- 万狗计划SNP数据库 (DogSD)
- 虚拟中国人基因组数据库 (VCGDB)
- 长非编码RNA知识库 (LncRNAWiki)

在线工具

- 生物信息工具库 (BIT)
- 表观组关联研究工具集 (EWAS Toolkit)

文献资料

- 生命科学文献库 (Open Library of Bioscience)

明德至诚 博学远志




我国生物信息学的发展与挑战

数据集被引用和访问情况：

截止2025年12月31日，数据资源累积被引超 **500** 次，
累计服务**123**个国家的超**30万**独立用户访问超**70万**次

入选国家数据局**首批**高质量数据集典型案例



高质量数据集典型案例发布

国家数据局 2025年08月30日 13:04 北京

8月28日，国家数据局在2025中国国际大数据产业博览会“高质量数据集主题交流活动”上发布高质量数据集典型案例。



高质量数据集典型案例 | 面向人群复杂特征的高质量DNA甲基化数据集

国家数据局 2025年09月28日 16:37 北京

推荐单位：中国科学院

申报单位：中国科学院北京基因组研究所（国家生物信息中心）

一、背景

随着人工智能技术在生命科学领域的快速发展，DNA甲基化作为表观遗传的重要调控机制，正展现出巨大的临床应用潜力。相较于传统的遗传生物标志物，DNA甲基化在健康监测与预警、疾病早诊与分型、精准治疗与干预、预后预测与评估等方面表现出更优异的性能。当前DNA甲基化数据来源广、类型多、标准不统一，严重制约AI模型的训练效果和临床应用转化。国家生物信息中心建立涵盖近300类人群复杂特征、超18万标准化DNA甲基化图谱的高质量数据集，支撑AI赋能应用。

明德至诚 博学远志



我国生物信息学的发展与挑战

为国内外的多个面向人口健康与疾病预测的AI模型提供高质量数据支撑

MethylGPT: a foundation model for the DNA methylome

To enable the pretraining of large-scale model, we collected 226,555 human DNA methylation profiles from 5,281 datasets through the EWAS Data Hub and Clockbase^{28,29}. After quality control and deduplication, we used 154,063 samples to pretrain MethylGPT. The model focuses on 49,156 physiologically-relevant CpG sites, selected based on association with EWAS traits (Methods)³⁰. These methylation profiles, representing samples from over 20 different tissue types, were processed to generate 7.6 billion training tokens (CpG sites), enabling comprehensive

哈佛医学院

Ying et al. *bioRxiv*. 2024

AI-driven feature selection and epigenetic pattern analysis :A screening strategy of CpGs validated by...

[66], were employed for selecting informative CpGs. To evaluate the stability of the methylation patterns of CpGs under the influence of different factors, epigenetic pattern analysis was performed for age, tissue, sex, and variance using the online website database, the EWAS Data Hub.

广州南方医科大学

Ying et al. *Forensic Science International*. 2025

Precious1GPT: multimodal transformer-based transfer learning for aging clock development...

To train our models, we used several datasets, including publicly available and in-house-built ones. For training age prediction models based on the epigenetic status of tissue, we employed 450 k Illumina Methylation array data from EWAS Data Hub [47] (number of samples = 8,374).

香港英矽智能

Urban et al. *Aging*. 2023

算法名称	论文	领域	数据支撑
MTCL	<i>Nature Aging</i> 2024	细胞动力学表观时钟	3,717个样本
OSMI	<i>BMC Bioinformatics</i> 2025	单样本甲基化填补	3,402个样本
InflammAge	<i>Aging Cell</i> 2024	唾液表观时钟	617,018个关系图谱
MethParquet	<i>Bioinformatics</i> 2024	甲基化数据分析包	2,070个样本



我国生物信息学的发展与挑战



鲍一明博士全职加入深圳医学科学院

🕒 2026-01-13

<https://www.smart-nbc.org.cn/>



明德至诚 博学远志



我国生物信息学的发展与挑战

下一代生物信息学-生物学3.0

- 生物学 V1.0:普通生物学和博物学，对生命进行观察和描述。
- 生物学 V2.0:现代生物学，探讨微观分子与宏观表型之间的线性因果关系。
- 生物学 V3.0:人工智能生物学，发展现代人工智能方法，整合大数据，揭示生命现象中复杂相互作用与调控方式的因果关系，实现生命科学研究根本性突破。

下一代生物信息学 = 人工智能生物学？



我国生物信息学的发展与挑战

下一代生物信息学-生物学3.0

全国生物信息学与系统生物学学术大会自1998年首届召开以来，已成功举办十二届，是中国生物信息学研究领域学术水平最高、影响最大的品牌会议。第十三届全国生物信息学与系统生物学学术大会将于2024年10月9日至12日在海南省海口市召开。此次会议由中国生物信息学组委会主办，海南医科大学、黑龙江省生物信息学学会承办，清华大学生物信息学教育部重点实验室、中国科学院数学与系统科学研究院协办。大会的主题为“生物医学大数据和人工智能驱动的生物信息学研究范式新发展”。



我国生物信息学的发展与挑战

下一代生物信息学-生物学3.0

您好！全国生物信息学与系统生物学学术大会自 1998 年首届召开以来，已成功举办十三届，现已成为中国生物信息学研究领域学术水平最高、影响最大的品牌会议。第十四届全国生物信息学与系统生物学学术大会将于 2025 年 10 月 7 日至 10 日在广西首府南宁市召开。本次会议由广西生物信息学学会承办，清华大学生物信息学教育部重点实验室协办。大会的主题为“生物信息学与人工智能交叉融合驱动生命科学（医学）研究范式变革”。



我国生物信息学的发展与挑战

应该学生物信息学的N个理由

- 0.计算是21世纪生物学研究的核心技能
- 1.计算技能是高度可转移的
- 2.计算能够帮助提高你的核心科学技能
- 3.应当在博士或博后期间获得新的技能
- 4.能够在生物学里建立更独特的技能
- 5.可以发表更多的论文
- 6.研究能有更大的灵活性
- 7.工作场所不受限制
- 8.计算研究的性价比高
- 9.成功的科学家死在办公室
- 10.能够知道为啥这个列表是从0开始



简书

<https://www.jianshu.com> › ...

应该学生物信息学的N个理由——来自科学网薛宇教授博文

2015年8月30日 — Russ认为计生是利用计算的方法来研究生物学，目标是得到新的生物学知识，因此这是科学；生信则是设计能够解决问题的工具、算法和数据库，目标是建立分析生物 ...



课后阅读


推荐教材



陈铭（科学出版社）



李霞（人民卫生出版社）



陈铭等翻译（科学出版社）



赵国屏（科学出版社）

明德至诚 博学远志