



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING


生物信息学

熊壮 博士

医工交叉研究院

Interdisciplinary Institute for Medical Engineering

bioinformatics_fzu@163.com



明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

第三章 测序技术

明德至诚 博学远志



第三章 测序技术

第四小节：序列比对

主要内容

序列比对相关概念

序列比对打分方法

双序列比对算法

比对的统计学显著性

数据库搜索

多序列比对



我们为何需要序列比对?



如何证明人与黑猩猩的基因相似度极高?



如何找出致病突变中的单个碱基差异?




如何快速比对新冠病毒的变异位点?



如何判断数据库中序列的亲缘关系?



生命是由序列书写的“文字”



从DNA双螺旋到氨基酸序列，
构成了生命的底层逻辑。



核心观点：生命的“文字”

生命的信息由DNA、RNA和蛋白质序列构成，这些由碱基或氨基酸组成的序列，就是生命的“文字”。



角色解析：生命的“源代码”

DNA：生命的“源代码”，存储遗传信息。

RNA：信息的“转录本”，传递遗传指令。


蛋白质：执行功能的“机器”，实现生命活动。



总结：这些由A、T、C、G或氨基酸组成的序列，共同书写了生命这本宏大的“天书”。



序列比对：给生命“天书”做校对



基因组就像不同版本的“天书”
记录着生命演化的密码

🔍 核心本质：对齐与比较

序列比对的本质，就是将不同的生命“天书”进行对齐和比较，找出它们的相同与差异之处。

🔗 技术价值：揭示演化与联系

不同物种的基因组存在缺失、插入或替换。通过特定算法对齐，能揭示生命的演化历程和内在联系，是现代生物信息学的基石。




序列比对：生物信息学的基石



疾病基因定位

寻找致病基因的第一步，帮助我们理解疾病的遗传基础，为精准医疗提供方向。



蛋白结构与功能预测

通过比对同源序列，利用已知蛋白信息，高效预测未知蛋白的三维结构和生物学功能。



进化树构建

基于序列差异分析，构建物种进化树，是进行物种分类和研究生物演化关系的基础。



科研必备工具

生物信息学研究中最基础、最常用的工具之一，贯穿于基因组学、转录组学等多个研究领域。



序列比对-相关概念

序列比对的定义

- **定义：**序列比对 (sequence alignment) 就是运用某种特定的数学模型或算法，找出两个或多个序列之间的**最大匹配碱基或残基数**，比对的结果反映了算法在多大程度上提供**序列之间的相似性关系及它们的生物学特征**。**序列比对是序列分析和数据库搜索的基础。**
- **目的：**通过比较两条或多条序列之间是否具有足够的相似性，从而判定它们之间是否具有**同源性**。


A	C	G	A	T
A	G	A	T	C

A	C	G	A	T	_
A	_	G	A	T	C



序列比对-相关概念

序列比对的定义





序列比对-相关概念

相似、同一与同源的定义

- **相似性** (Similarity) 是指两序列间直接的数量关系，如部分相同、相似的百分比或其他一些合适的度量。
- **同一性** (Identity) 是指两序列在**同一位点核苷酸或氨基酸残基完全相同的序列比例**。
- **同源性** (Homology) 是指从某个**共同祖先**经趋异进化而形成的不同序列。
- **相似性与同一性都是量的概念**，一般用百分数表示。两条序列具有41%的相似性。
- **同源是定性的概念，没有度的差异**。对于两个序列，他们或者同源或者不同源，不能说他们70%或80%同源。
- **同源序列**是来源于**共同祖先的相似序列**。
- 同源序列一定相似，相似序列不一定同源。



序列比对-相关概念


直系同源与旁系同源

- 同源可分为 **直系（垂直）同源**（Ortholog）和**旁系（水平）同源**（Paralog）
- **直系同源基因**是指在**不同物种间**有**相同功能**的同源基因，它是在物种形成过程中形成的。
 - 在进化上起源于一个共同祖先基因并**垂直传递**的同源基因；
 - 分布于**两种或两种以上物种**的基因组；
 - **功能高度保守**乃至近乎相同；
 - 结构相似；
 - 组织特异性与亚细胞分布相似
- **旁系同源基因**是指**一个物种内**的同源基因，是由于**祖先基因加倍**而横向产生的。即旁系同源是**基因复制**的结果。
- 直系同源基因与旁系同源基因统称同源基因



序列比对-相关概念

直系同源与旁系同源



珠蛋白基因家族

明德至诚 博学远志



序列比对-相关概念

直系同源与旁系同源

- 直系与旁系的共性是同源，都源于各自的祖先基因。
- 其区别在于：
 - 在进化起源上，直系同源强调在**不同基因组**间的**垂直传递**，旁系同源则是在**同一基因组**中的**横向加倍**；
 - 在功能上，**直系同源要求功能高度相似**，而**旁系同源在定义上对功能没有严格要求**，可能相似，但也可能并不相似（尽管结构上具有一定程度的相似），甚至于没有功能（如基因家族中的假基因）。



序列比对-相关概念

- 以下关于同源性的说法，错误的是（ ）
- A. 直系同源是指在不同物种间有相同功能的同源序列，它是在物种形成过程中形成的。
 - B. 直系同源与旁系同源均要求功能高度相似。
 - C. 旁系同源是基因复制的结果。
 - D. 旁系同源基因是指一个物种内的同源基因，是由于祖先基因加倍而横向产生的。



序列比对-相关概念

- 以下关于序列的相似性、同一性、同源性的说法，错误的是（ ）
- A. 家鼠和小龙虾同源的胰蛋白酶的蛋白质序列具有41%的相似性，也即具有41%的同源性。
 - B. 序列间具有很高的相似性并不等于具有同源性，但在大多数情况下相似性可以表明两序列间的同源性
 - C. 同一性是指两序列在同一位点核苷酸或氨基酸残基完全相同的序列比例。
 - D. 同源性是指从某个共同祖先经趋异进化而形成的不同序列。



序列比对的作用

➤ 获得共性序列

- 共性序列 (Consensus sequence, 一致/共有序列) 的概念用来描述一组 DNA 或者蛋白质序列, 通常这组序列互相之间**非常相似但又不完全相同**, 共性序列就由这组相似序列中**每个位置最常出现的碱基或者氨基酸组成**
- 共性序列常用于**数据库搜索、探针设计、识别高度相似的序列**

➤ 突变分析

- 与参考基因组比较, 识别序列中变异位点



序列比对-相关概念

序列比对的作用

➤ 种系分析

- 根据基因或基因组序列的差异判断种系关系
- 多序列比对通常是构造种系树的第一步。

➤ 保守区段分析

- 保守区段：某一段序列在进化演变过程中，在不同的物种中都被保留
- 多序列比对是识别进化上保守的这些区段的基本方法

➤ 基因和蛋白质功能分析

- 通过与已知功能的同源基因和蛋白质进行多序列比对来推断新基因和蛋白质的功能。



序列比对-打分方法

一、序列比对替换打分矩阵

掌握替换打分矩阵的定义

构建替换打分矩阵的两种手段

二、核酸序列替换打分矩阵

知道常用的三种打分矩阵

三、蛋白质序列替换打分矩阵

知道常用的打分矩阵

掌握PAM矩阵和BLOSUM矩阵的差别

四、空位罚分

知道什么是起始空位和延伸空位

能利用线性空位罚分和仿射空位罚分计算具体的罚分值

明德至诚 博学远志



序列比对-打分方法

序列比对替换打分矩阵

- 在序列比对中，一般需要给出一个定量的数值来描述两者的一致性和相似性。在此过程中，**替换打分矩阵**用来**评价碱基或残基之间的相似性**。
- 在长期实践中，发现一些特定的**碱基替换**或者**残基替换**的频率是要高于另一些替换的，因此可以通过**统计方法**或者**基于进化的突变模型**来给每一种替换定义不同的分值，从而**体现出不同碱基或残基之间发生替换的可能性**。
- 替换打分矩阵即是一种**打分规则**，其数学本质是**统计权重**，它**定量地描述了不同替换的意义**。
- 替换打分矩阵包括**核酸序列替换打分矩阵**和**蛋白质序列替换打分矩阵**。



序列比对-打分方法

序列比对替换打分矩阵

- 对于序列中单个字符的**替换**引起的失配，需要考虑不同字符间的替换具有不同的概率和意义。

A T C T G A T
A T T T G A T

A T C T G T A
A T G T G T A



序列比对-打分方法

序列比对替换打分矩阵

1. 等价矩阵 (Unitary matrix)

- 相同核苷酸间的匹配得分为1，不同核苷酸间的替换得分为0

	A	T	C	G
A	1	0	0	0
T	0	1	0	0
C	0	0	1	0
G	0	0	0	1



序列比对-打分方法

序列比对替换打分矩阵

2. 转换-颠换矩阵 (Transition-transversion matrix)

- **转换**: 嘌呤(A, G)之间的替换, 或者嘧啶(C, T)之间的替换
- **颠换**: 嘌呤与嘧啶间的替换。
- 转换的发生概率远高于颠换
- 转换得分为-1, 颠换得分为-5

	A	T	C	G
A	1	-5	-5	-1
T	-5	1	-1	-5
C	-5	-1	1	-5
G	-1	-5	-5	1



序列比对-打分方法

序列比对替换打分矩阵

3. BLAST矩阵


- 基于大量实际比对
- 匹配得分为+5，反之为-4

	A	T	C	G
A	5	-4	-4	-4
T	-4	5	-4	-4
C	-4	-4	5	-4
G	-4	-4	-4	5



序列比对-打分方法

蛋白质序列替换打分矩阵



1. 等价矩阵

- 匹配得分为1，反之为0

2. 遗传密码矩阵 (Genetic code matrix)

- 通过计算一个氨基酸转变成另一个氨基酸所需的密码子变化的数目而得到，矩阵元素的值对应于代价。
- 常用于进化距离的计算，优点是计算结果可以直接用于绘制进化树。
- 当蛋白质序列相似度较低时，不适用


3. 疏水性矩阵 (Hydrophobic matrix)

- 根据氨基酸侧链基团疏水性的不同以及氨基酸替换前后理化性质改变的大小
- 若一次氨基酸替换后疏水特性不发生大的变化，则这种替换的得分高，否则得分低
- 适用于偏重蛋白质功能方面的序列比对



序列比对-打分方法

蛋白质序列替换打分矩阵




4. PAM矩阵 (Dayhoff 突变数据矩阵)

- 根据对**氨基酸之间的相互替换率**计算得到的PAM矩阵，即可**接受点突变** (Point accepted mutation) 或**可接受突变百分比** (Percent of accepted mutation) 矩阵。
(可接受：突变不会因自然选择而被淘汰)
- PAM基于**氨基酸进化的点突变模型**，即如果两种氨基酸替换频繁，说明自然界易接受这种替换，那么这对氨基酸替换得分就应该高。
- **PAM-1**：一条序列1%的氨基酸发生突变，这一过程发生1次后，氨基酸之间的相对突变概率。PAM-1是基于相似性较高 (通常为 85%以上) 的序列比对后计算所得。



序列比对-打分方法

蛋白质序列替换打分矩阵



4. PAM矩阵 (Dayhoff 突变数据矩阵)

- PAM-n : PAM-1 自乘 n 次可以得到 PAM-n , 即发生了 n 次, 取对数即为其替换记分矩阵。
- n 越小表示氨基酸变异的可能性越小 (进化距离越近)
- 在实际使用中, 需要根据待比较序列之间的亲缘关系远近, 来选择适合的 PAM 矩阵。
- 如果序列亲缘关系远, 也就是说序列间会有很多突变, 那就选 PAM 后面跟一个大数字的矩阵。
- 如果亲缘关系近, 也就是突变比较少, 序列间大多数地方都是一样的, 那就选 PAM 后面跟一个小数字的矩阵。




序列比对-打分方法

蛋白质序列替换打分矩阵

PAM1 Mutation Matrix

1 PAM evolutionary distance

	Ala	Arg	Asn	Asp	Cys	Gln	Glu	Gly	His	Ile	Leu	Lys	Met	Phe	Pro	Ser	Thr	Trp	Tyr	Val
	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
Ala A	9867	2	9	10	3	8	17	21	2	6	4	2	6	2	22	35	32	0	2	18
Arg R	1	9913	1	0	1	10	0	0	10	3	1	19	4	1	4	6	1	8	0	1
Asn N	4	1	9822	36	0	4	6	6	21	3	1	13	0	1	2	20	9	1	4	1
Asp D	6	0	42	9859	0	6	53	6	4	1	0	3	0	0	1	5	3	0	0	1
Cys C	1	1	0	0	9973	0	0	0	1	1	0	0	0	0	1	5	1	0	3	2
Gln Q	3	9	4	5	0	9876	27	1	23	1	3	6	4	0	6	2	2	0	0	1
Glu E	10	0	7	56	0	35	9865	4	2	3	1	4	1	0	3	4	2	0	1	2
Gly G	21	1	12	11	1	3	7	9935	1	0	1	2	1	1	3	21	3	0	0	5
His H	1	8	18	3	1	20	1	0	9912	0	1	1	0	2	3	1	1	1	4	1
Ile I	2	2	3	1	2	1	2	0	0	9872	9	2	12	7	0	1	7	0	1	33
Leu L	3	1	3	0	0	6	1	1	4	22	9947	2	45	13	3	1	3	4	2	15
Lys K	2	37	25	6	0	12	7	2	2	4	1	9926	20	0	3	8	11	0	1	1
Met M	1	1	0	0	0	2	0	0	0	5	8	4	9874	1	0	1	2	0	0	4
Phe F	1	1	1	0	0	0	0	1	2	8	6	0	4	9946	0	2	1	3	28	0
Pro P	13	5	2	1	1	8	3	2	5	1	2	2	1	1	9926	12	4	0	0	2
Ser S	28	11	34	7	11	4	6	16	2	2	1	7	4	3	17	9840	38	5	2	2
Thr T	22	2	13	4	1	3	2	2	1	11	2	8	6	1	5	32	9871	0	2	9
Trp W	0	2	0	0	0	0	0	0	0	0	0	0	0	1	0	1	0	9976	1	0
Tyr Y	1	0	3	0	3	0	1	0	4	1	1	0	0	21	0	1	1	2	9945	1
Val V	13	2	1	1	3	2	2	3	3	57	11	1	17	1	3	2	10	0	2	9901





序列比对-打分方法

蛋白质序列替换打分矩阵

A	2																			
R	-2	6																		
N	0	0	2																	
D	0	-1	2	4																
C	-2	-4	-4	-5	12															
Q	0	1	1	2	-5	4														
E	0	-1	1	3	-5	2	4													
G	1	-3	0	1	-3	-1	0	5												
H	-1	2	2	1	-3	3	1	-2	6											
I	-1	-2	-2	-2	-2	-2	-2	-3	-2	5										
L	-2	-3	-3	-4	-6	-2	-3	-4	-2	-2	6									
K	-1	3	1	0	-5	1	0	-2	0	-2	-3	5								
M	-1	0	-2	-3	-5	-1	-2	-3	-2	2	4	0	6							
F	-3	-4	-3	-6	-4	-5	-5	-5	-2	1	2	-5	0	9						
P	1	0	0	-1	-3	0	-1	0	0	-2	-3	-1	-2	-5	6					
S	1	0	1	0	0	-1	0	1	-1	-1	-3	0	-2	-3	1	2				
T	1	-1	0	0	-2	-1	0	0	-1	0	-2	0	-1	-3	0	1	3			
W	-6	2	-4	-7	-8	-5	-7	-7	-3	-5	-2	-3	-4	0	-6	-2	-5	17		
Y	-3	-4	-2	-4	0	-4	-4	-5	0	-1	-1	-4	-2	7	-5	-3	-3	0	10	
V	0	-2	-2	-2	-2	-2	-2	-1	-2	4	2	-2	2	-1	-1	-1	0	-6	-2	4
	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V





FIGURE 3.14 Log-odds matrix for PAM250. High PAM values (e.g., PAM250) are useful for aligning very divergent sequences. A variety of algorithms for pairwise alignment, multiple sequence alignment, and database searching (e.g., BLAST) allow you to select an assortment of PAM matrices such as PAM250, PAM70, and PAM30. Adapted from NCBI, <ftp://ftp.ncbi.nlm.nih.gov/blast/matrix/>.



序列比对-打分方法

蛋白质序列替换打分矩阵




5. BLOSUM (Block Substitution Matrix) 矩阵

- BLOSUM矩阵的相似度是根据**真实数据**产生的。
- 基于**蛋白质序列块（短序列）** 比对进行推断
- **BLOSUM-80**代表该矩阵由**一致性 $\geq 80\%$** 的序列计算而来
- **BLOSUM-62**是指矩阵由**一致性 $\geq 62\%$** 的序列计算而来
- BLOSUM-n: **n越小，氨基酸相似的可能性越小**
- BLOSUM矩阵的优点是符合实际观测结果，不足之处是它不考虑进化距离，不能提供进化信息。



序列比对-打分方法

蛋白质序列替换打分矩阵



PAM/BLOSUM矩阵编号与序列亲缘关系的比较



序列比对-打分方法

空位罚分

- 对于序列中单个字符的**插入和缺失**引起的失配，序列比对采用**插入空位**来处理。
- 但在序列的比对中，引入空位就意味着序列中的残基或碱基的缺失和插入，这可能意味着功能的丧失或改变，所以过多空位引入可能使比对失去意义。
- **空位罚分** (gap penalty)：即**每插入一个空位，就在总分值中减去一定分值，用匹配残基（碱基）的总分值减去空位罚分。**

ATCTGTA
ATTGTA

➔

ATCTGTA
AT - TGT A



序列比对-打分方法

空位罚分

- **起始空位**：指序列比对时，在某一序列中插入一个空位，使两个序列之间有更好的匹配。
- **延伸空位**：指在引入一个或几个空位后，继续引入下一个连续的空位，使两个序列之间有更好的匹配。
- 空位罚分包括两部分：**空位起始罚分**和**空位延伸罚分**。一般空位起始罚分高，而空位延伸罚分相对较低。
- 空位延伸罚分值可以与空位起始罚分值相同，也可从比空位起始罚分值小。
- 空位罚分方式：**线性空位罚分**，**仿射空位罚分**

	起	延	延				起	延	
C	—	—	—	T	T	A	A	C	T
C	G	G	A	T	C	A	—	—	T



序列比对-打分方法

空位罚分

➤ 线性空位罚分 (Constant gap penalty)

- 最简单的罚分方式，**仅考虑起始空位罚分**，连续的空位不罚分。
- 如下图所示，设起始空位罚分值为 - 4，序列应罚8 分。

			-4					-4		
			┌───┐					┌──┐		
C	-	-	-	T	T	A	A	C	T	
C	G	G	A	T	C	A	-	-	T	



序列比对-打分方法

空位罚分

➤ 仿射空位罚分 (Affine gap penalty)

- 起始空位对应着一个罚分，延伸空位则对应一个相对较低的罚分。
- 仿射空位罚分采用线性函数 $g(k) = a + b * (k - 1)$ 计算连续空位罚分（ a 为起始空位罚分； b 为空位延伸罚分； k 为空位数量）。
- 罚分与空位的长度成比例
- 如下图所示，采用仿射空位罚分， $a = -4$ 、 $b = -3$ ，则共罚 17 分

$$-17 = \{-4 + [-3 \times (3 - 1)]\} + \{-4 + [-3 \times (2 - 1)]\}$$

	-4	-3	-3				-4	-3	
C	—	—	—	T	T	A	A	C	T
C	G	G	A	T	C	A	—	—	T



序列比对-打分方法

空位罚分

- 练习题：假定如图所示的序列比对中，起始空位罚4分，延伸空位罚3分（即 $a = -4$ 、 $b = -3$ ），那么线性空位罚分和仿射空位罚分两种方法分别罚多少分。

C	—	T	—	—	—	A	A	C	T
C	G	T	G	A	C	A	—	—	T

线性		-4		-4				-4		
	C	—	T	—	—	—	A	A	C	T
	C	G	T	G	A	C	A	—	—	T

仿射		-4		-4	-3	-3		-4	-3	
	C	—	T	—	—	—	A	A	C	T
	C	G	T	G	A	C	A	—	—	T



序列比对-双序列比对算法

一、dotplot 算法

- 了解dotplot 算法的基本步骤

二、双序列全局比对

- 掌握全局比对时适用场景
- 熟练使用Needleman-Wunsch算法进行序列全局比对

三、双序列局部比对


- 掌握局部比对时适用场景
- 熟练使用Smith-Waterman算法进行序列局部比对



序列比对-双序列比对算法

dotplot 算法

- dotplot 法或对角线作图由Gibb提出。
- 将两条待比较的序列分别放在矩阵的X/Y轴上
- 依次比较两条序列的每个字符，当**对应行与列的字符匹配时**，则在**矩阵对应的位置上打点**，得到点矩阵。
- 在点阵矩阵中，将位于**对角线方向上相邻的点连接起来**，这些**直线所对应的矩形区域**就是这两条序列的相似性片段。






序列比对-双序列比对算法

dotplot 算法

- 两条序列**完全相同**，点矩阵的**主对角线**各位置都被标记。






序列比对-双序列比对算法

dotplot 算法

- 两条序列**有共同的子序列**，对每一个子序列有一条与**对角线平行**的由一系列点组成的斜线。






序列比对-双序列比对算法

dotplot 算法

- 两条序列**有共同的子序列**，对每一个子序列有一条与**对角线平行**的由一系列点组成的斜线。






序列比对-双序列比对算法

dotplot 算法

- 两条序列**反向匹配**，在**反对角线**方向上有由点组成的斜线。





序列比对-双序列比对算法

双序列全局比对

- **全局比对**：将参与比对的两条序列里面的**所有字符**进行比对。
- 主要用途：寻找关系密切的序列；鉴别或证明新序列与已知序列家族的同源性，是进行分子进化分析的重要前提。
- 代表算法：**Needleman-Wunsch**算法（动态规划）。




序列比对-双序列比对算法

双序列全局比对

➤ Needleman-Wunsch算法

- a, b 是两条待比对序列
- $|a| = m, |b| = n$
- $S(i, j)$ 是按照指定替换打分矩阵得到的前缀 $a[1...i]$ 与 $b[1...j]$ 的最大相似性得分
- $w(c, d)$ 是字符 c 和 d 按照替换计分矩阵计算的得分
- $S(0, 0) = 0$

$$S(i, j) = \max \begin{cases} S(i-1, j-1) + w(a_i, b_j) & \text{匹配或失配} \\ S(i-1, j) + w(a_i, -) & a_i \text{ 比对到空格上} \\ S(i, j-1) + w(-, b_j) & b_j \text{ 比对到空格上} \end{cases}$$





序列比对-双序列比对算法

双序列全局比对

- 例题1：利用动态规划算法对序列 $a = \text{AGCACCA}$ 与序列 $b = \text{ACACTA}$ 进行全局比对。计分规则： $w(\text{匹配}) = +2$ ； $w(a, -) = w(-, b) = w(\text{失配}) = -1$



序列比对-双序列比对算法

双序列全局比对

➤ 矩阵初始化


	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1						
C	-2						
A	-3						
C	-4						
T	-5						
A	-6						

$$S(i, j) = \max \begin{cases} S(i-1, j-1) + w(a_i, b_j) & \text{匹配或失配} \\ S(i-1, j) + w(a_i, -) & \text{\textcolor{red}{a}_i 比对到空格上} \\ S(i, j-1) + w(-, b_j) & \text{\textcolor{red}{b}_j 比对到空格上} \end{cases}$$

➤ 计算比对得分

➤ $w(\text{匹配}) = +2$

➤ $w(a, -) = w(-, b)$
 $= w(\text{失配}) = -1$



双序列全局比对

	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1						
C	-2						
A	-3						
C	-4						
T	-5						
A	-6						



序列比对-双序列比对算法

双序列全局比对

➤ 回溯路径：从右下角向元素开始，回溯到当前单元格来源的单元格中值最大的单元格。

	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1	2 +	1 ←	0 ←	-1 ←	-2 ←	-3 ←
C	-2	1 ↑	1 +	3 +	2 ←	1 ←	0 ←
A	-3	0 +	0 ↑	2 ↑	5 +	4 ←	3 ←
C	-4	-1 ↑	-1 ↑	2 +	4 ↑	7 +	6 ←
T	-5	-2 ↑	-2 ↑	1 ↑	3 ↑	6 ↑	6 +
A	-6	-3 +	-3 ↑	0 ↑	3 +	5 ↑	8 +

A G C A C — A
A — C A C T A



序列比对-双序列比对算法

双序列全局比对

- 例题2：利用动态规划算法对序列 $a = \text{ATGCAGCTGCTT}$ 与序列 $b = \text{AGCT}$ 进行全局比对。计分规则： $w(\text{匹配}) = +2$ ； $w(a, -) = w(-, b) = w(\text{失配}) = -1$



序列比对-双序列比对算法

双序列全局比对

A	T	G	C	A	G	C	T	G	C	T	T
A	—	G	C	—	—	—	T	—	—	—	—

	—	A	T	G	C	A	G	C	T	G	C	T	T
—	0	-1	-2	-3	-4	-5	-6	-7	-8	-9	-10	-11	-12
A	-1	2 +	1 ←	0 ←	-1 ←	-2 ←	-3 ←	-4 ←	-5 ←	-6 ←	-7 ←	-8 ←	-9 ←
G	-2	1 ↑	1 +	3 +	2 ←	1 ←	0 ←	-1 ←	-2 ←	-3 ←	-4 ←	-5 ←	-6 ←
C	-3	0 ↑	0 +	2 ↑	5 +	4 ←	3 ←	2 ←	1 ←	0 ←	-1 ←	-2 ←	-3 ←
T	-4	-1 ↑	2 +	1 ←	4 ↑	4 +	3 ←	2 ←	4 +	3 ←	2 ←	1 ←	0 ←



序列比对-双序列比对算法

双序列局部比对

- 对一条长序列和短序列进行全局比对，整体相似性得分可能不高，找不到相似的序列。
- **局部比对**：在每个序列中使用某些**局部区域片段**进行比对，找出两个序列间**高相似度的片段**。
- 适用于**亲缘关系较远**、整体上不具有相似性而在一些较小的区域上存在局部相似性的两个序列
- 代表算法：**Smith-Waterman**算法



序列比对-双序列比对算法

双序列局部比对

➤ Smith-Waterman 算法

- a, b 是两条待比对序列
- $|a| = m, |b| = n$
- $S(i, j)$ 是按照指定替换打分矩阵得到的前缀 $a[1...i]$ 与 $b[1...j]$ 的最大相似性得分
- $w(c, d)$ 是字符 c 和 d 按照替换计分矩阵计算的得分
- $S(i, 0) = 0, 0 \leq i \leq m; S(0, j) = 0, 0 \leq j \leq n$



序列比对-双序列比对算法

双序列局部比对

$$S(i, j) = \max \begin{cases} S(i-1, j-1) + w(a_i, b_j) & \text{匹配或失配} \\ S(i-1, j) + w(a_i, -) & a_i \text{ 比对到空格上} \\ S(i, j-1) + w(-, b_j) & b_j \text{ 比对到空格上} \\ 0 & \text{表示此前的序列不具有相似性, 重置} \end{cases}$$

- 回溯：从矩阵得分的**最大分值的元素**开始回溯直至**分数为0的元素**



序列比对-双序列比对算法

双序列局部比对

- 例题1：利用动态规划算法对序列 $a =$
ATGCAGCTGCTT 与序列 $b =$ AGCT 进行局部比对。计
分规则： $w(\text{匹配}) = +2$; $w(a, -) = w(-, b) = w(\text{失配}) = -1$



序列比对-双序列比对算法

双序列局部比对

➤ 矩阵初始化

$$S(i, 0) = 0, 0 \leq i \leq m; \quad S(0, j) = 0, 0 \leq j \leq n$$

	—	A	T	G	C	A	G	C	T	G	C	T	T
—	0	0	0	0	0	0	0	0	0	0	0	0	0
A	0												
G	0												
C	0												
T	0												



序列比对-双序列比对算法

双序列局部比对

➤ 计算比对得分

	—	A	T	G	C	A	G	C	T	G	C	T	T
—	0	0	0	0	0	0	0	0	0	0	0	0	0
A	0	2 +	1 ←	0 ←	0	2 +	1 ←	0 ←	0	0	0	0	0
G	0	1 ↑	1 +	3 +	2 ←	1 ←	4 +	3 ←	2 ←	2 +	1 ←	0 ←	0
C	0	0 ↑	0 + ↑	2 ↑	5 +	4 ←	3 ←	6 +	5 ←	4 ←	4 +	3 ←	2 ←
T	0	0	2 +	1 ←	4 ↑	4 +	3 ←	5 ↑	8 +	7 ←	6 ←	6 +	5 ←



序列比对-双序列比对算法

双序列局部比对

ATGC **AGCT** GCTT
- - - - **AGCT** - - - -

➤ 路径回溯

	—	A	T	G	C	A	G	C	T	G	C	T	T
—	0	0	0	0	0	0	0	0	0	0	0	0	0
A	0	2 +	1 ←	0 ←	0	2 +	1 ←	0 ←	0	0	0	0	0
G	0	1 ↑	1 +	3 +	2 ←	1 ←	4 +	3 ←	2 ←	2 +	1 ←	0 ←	0
C	0	0 ↑	0 + ↑	2 ↑	5 +	4 ←	3 ←	6 +	5 ←	4 ←	4 +	3 ←	2 ←
T	0	0	2 +	1 ← ↑	4 ↑	4 +	3 ←	5 ↑	8 +	7 ←	6 ←	6 +	5 ←



序列比对-双序列比对算法

双序列比对工具-全局比对



[Job Dispatcher](#) [Help & Privacy](#) [Your Jobs](#) **Input form**

[Feedback](#)

Welcome to the Job Dispatcher website! If you need assistance or have feedback, please [contact](#) us.

×

EMBOSS Needle reads two input sequences and writes their optimal global sequence alignment to file.

Input sequence ⓘ

Sequence type

☒ Protein ☐ DNA

Paste your first sequence here - or use the example sequence

https://www.ebi.ac.uk/jdispatcher/psa/emboss_needle

明德至诚 博学远志



序列比对-双序列比对算法

双序列比对工具-局部比对

[EMBL-EBI home](#) [Services](#) [Research](#) [Training](#) [About us](#) [Feedback](#)

EMBOSS Water

Pairwise Sequence Alignment (PSA)

[Job Dispatcher](#) [Help & Privacy](#) [Your Jobs](#) [Input form](#)

Welcome to the Job Dispatcher website! If you need assistance or have feedback, please [contact](#) us.

EMBOSS Water uses the Smith-Waterman algorithm (modified for speed enhancements) to calculate the local alignment of two sequences.

Input sequence ⓘ

Sequence type

☒ Protein ☐ DNA

Paste your first sequence here - or use the example sequence

https://www.ebi.ac.uk/jdispatcher/psa/emboss_water

明德至诚 博学远志



序列比对-比对的统计学显著性

典型方法

- 目的：确定由比对算法计算的相似性是否可靠，是否偶然
- 假定序列A和B的比对得分是 S ，为判断 S 的可靠性
 - 法1：将序列A或B与大量**非同源的序列**做比对，得到比对得分集合 S_1 ，然后将 S 与 S_1 进行比较。
 - 法2：把序列A或B与一组**随机产生的序列**进行比对，得到比对得分集合 S_2 ，然后将 S 与 S_2 进行比较。



序列比对-比对的统计学显著性

典型方法

- 法3：首先随机将序列A与B中的一个打乱重组，比如说重组100次，并与另一个序列比对，得到一组比对得分 S_3 ；接着计算 S_3 的均值 M 和标准差 D ，并计算 Z 值：
$$Z = (S - M) / D$$
；最后根据 Z 值判断两个序列相似得分的显著性

$$\left\{ \begin{array}{ll} Z > 5: & \text{同源} \\ Z < 3: & \text{不同源} \\ 3 \leq Z \leq 5: & \text{可能同源} \end{array} \right.$$



一、经典BLAST

- 理解BLAST算法的基本原理

二、BLAST在线工具

- 掌握BLAST的不同检索模式
- 会使用BLAST算法在指定数据库中搜索相似序列



序列比对-数据库搜索

经典BLAST

- BLAST: basic local alignment search tool
- 数据库搜索是**双序列局部比对**的特例
- **查询序列** (Query): 希望通过数据库搜索确定其性质或功能的序列
- **目标序列** (Hits): 通过数据库搜索得到的和查询序列具有一定相似性的序列



序列比对-数据库搜索

经典BLAST

- BLAST是目前最常用的数据库搜索算法。
- BLAST的要点是**片段对** (segment pair) 的概念，它是指两个给定序列中的一对子序列，它们的**长度相等**，且可以形成**无空格的完全匹配**。

KSD	FGETS	IV	ATGG	STE
NE	FGETS	LI	ATGG	NPA



序列比对-数据库搜索

经典BLAST

➤ BLAST基本步骤

- ① 找出某些“**种子**” (**Word**), 即查询序列和目标序列间非常短的**片段对**, 他们的比对得分大于或等于某个阈值
- ② 向两端**不带空格**地扩展种子, 并使用替换计分矩阵计算得分, 当得分低于某个既定阈值时停止扩展 (改进后的BLAST允许空位的插入)
- ③ 给出扩展后的片段对, 即为**高分值片段对** (High-scoring pairs, HSPs)


K	SD	FGETS	IV	ATGG	S	TE
	::		::		:	
	NE	FGETS	LI	ATGG	N	PA



序列比对-数据库搜索

经典BLAST

BLAST 算法



High-scoring Segment Pair (HSP)

明德至诚 博学远志



BLAST在线工具

➤ BLAST的查询序列和数据库的类型

程序名	查询序列	数据库类型	方法
blastp	蛋白质	蛋白质	用蛋白质查询序列搜索蛋白质序列数据库
blastn	核酸	核酸	用核酸查询序列搜索核酸序列数据库
blastx	核酸	蛋白质	将核酸序列按6条链翻译成蛋白质序列后搜索蛋白质序列数据库
tblastn	蛋白质	核酸	用蛋白质查询序列搜索核酸序列数据库，核酸序列按6条链翻译成蛋白质
tblastx	核酸	核酸	将核酸序列按6条链翻译成蛋白质序列后搜索由核酸序列数据库按6条链翻译成的蛋白质序列的数据库



序列比对-数据库搜索

BLAST在线工具

 **National Library of Medicine**
National Center for Biotechnology Information

yuanhuating@gmail...

BLAST®

HomeRecent ResultsSaved StrategiesHelp

 Check out the ClusteredNR database on BLAST+[Learn more](#)[Give us feedback](#)

Basic Local Alignment Search Tool

BLAST finds regions of similarity between biological sequences. The program compares nucleotide or protein sequences to sequence databases and calculates the statistical significance. [Learn more](#)

NEWS


ClusteredNR database on BLAST+
The ClusteredNR database is now available for BLAST+
Thu, 24 Aug 2023[More BLAST news...](#)

Web BLAST

**Nucleotide BLAST**
nucleotide ▶ nucleotide

blastx
translated nucleotide ▶ protein

tblastn
protein ▶ translated nucleotide

**Protein BLAST**
protein ▶ protein

BLAST Genomes

Enter organism common name, scientific name, or tax id

HumanMouseRatMicrobes

Search

<https://blast.ncbi.nlm.nih.gov/Blast.cgi>

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Standard Nucleotide BLAST

blastn

blastp

blastx

tblastn

tblastx

BLASTN programs search nucleotide databases using a nucleotide query. more...

Reset pageBookmark

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) ? Clear

Query subrange ?

From

To

Or, upload file

选择文件 | 未选择文件 ?

Job Title

Enter a descriptive title for your BLAST search ?

☐ Align two or more sequences ?

Choose Search Set

Database

☒ Standard databases (nr etc.): ☐ rRNA/ITS databases ☐ Genomic + transcript databases ☐ Betacoronavirus

New

☐ Experimental databases

Try experimental taxonomic nt databases

Download

For more info see What are taxonomic nt databases?

Nucleotide collection (nr/nt) ?

Organism

Optional

Enter organism name or id--completions will be suggested

☐ exclude

Add organism

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown ?

Exclude

Optional

☐ Models (XM/XP) ☐ Uncultured/environmental sample sequences

Limit to

Optional

☐ Sequences from type material

Entrez Query

Optional

Enter an Entrez query to limit search ?

YouTube Create custom database

Program Selection

Optimize for

☒ Highly similar sequences (megablast)

☐ More dissimilar sequences (discontiguous megablast)

☐ Somewhat similar sequences (blastn)

Choose a BLAST algorithm ?

查询页面

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

BLAST (blastn) 参数

Algorithm parameters

General Parameters

Max target sequences

10

展示的目标序列数目

Select the maximum number of aligned sequences to display ?

Short queries

☒ Automatically a

Expect threshold

0.05

期望值：控制搜索的敏感性。该值越小，搜索越严格

Word size

16

“种子” 的长度

Max matches in a query range

0

Scoring Parameters

Match/Mismatch Scores

1,-1

匹配和错配打分

Gap Costs

Existence: 5 Extension: 2

空格罚分

Filters and Masking

Filter

☒ Low complexity regions ?

☐ Species-specific repeats for: Homo sapiens (Human) ?

Mask

☒ Mask for lookup table only ?

☐ Mask lower case letters ?

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Algorithm parameters

General Parameters

Max target sequences

10

Select the maximum number of aligned sequences to display ?

Short queries

☒ Automatically adjust parameters for short input sequences ?

Expect threshold

0.05

?

Word size

6

?

Max matches in a query range

0

?

Scoring Parameters

Matrix

BLOSUM62

?

Gap Costs

Existence: 11 Extension: 1

?

Compositional adjustments

Conditional compositional score matrix adjustment

?

Filters and Masking

Filter

☒ Low complexity regions ?

Mask

☐ Mask for lookup table only ?

☐ Mask lower case letters ?

替换打分矩阵

BLAST (blastp) 参数

明德至诚 博学远志



BLAST在线工具

实例1: BLAST检索

>myprotein seq_ for NCBI blast

VKCRLNVLLWYQDAYGEVEINDGKLYDAYVSYSDCPEDRK
FINFILKPQLERRRGYKLFLDDRDLLPRAEPSADLLVNLSRCR
RLIVVLSDAFLSRAWCSHSFREGLCRLLELTRRPIFITFEGQRR
DPAHPALRLLRQHRHLVTL LLWRPGSVTPSSDFWKEVQLAL
PRKVQYRPVEGDPQTQLQDDKDPMLILRGRVPEGRALDSEV
DPDPEGDLGVRGPVFGEPSAPPHTSGVSLGESRSSEVDVSDL
GSRNYSARTDFYCLISKDDM



序列比对-数据库搜索

BLAST在线工具

BLAST[®] » blastn suite

blastn blastp blastx tblastn tblastx

Standard Nucleotide BLAST

BLASTN programs search nucleotide databases using a nucleotide query.

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) ? [Clear](#)

>MH011443.1 Homo sapiens TP53 (TP53) gene, exon 5 and partial cds
TGGGTTGATTCCACACCCCGCCCGGCACCCGCGTCCGCGCCGTGGCC
ATCTACAAGCAGTCACAGCACA
TGACGGAGGTTGTGAGGCGCTGCCCCACCATGAGCGCTGCTCAGATAG

Query subrange ?

From

To

Or, upload file

浏览... 未选择文件。 ?

Job Title

TP53

Enter a descriptive title for your BLAST search ?

☐ Align two or more sequences ?

Choose Search Set

Database

☒ Standard databases (nr etc.): ☐ rRNA/ITS databases ☐ Genomic + transcript databases ☐ Betacoronavirus

Nucleotide collection (nr/nt) ?

Organism

Optional

Enter organism name or id—completions will be suggested ☐ exclude [Add organism](#)

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown ?

Exclude

Optional

☐ Models (XM/XP) ☐ Uncultured/environmental sample sequences

Limit to

Optional

Sequences from type material

Entrez Query

Optional

Enter an Entrez query to limit search ?

[YouTube](#) [Create custom database](#)

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

[← Edit Search](#) [Save Search](#) [Search Summary ▼](#)

Job Title	TP53
RID	K6VGX61M01R Search expires on 10-22 14:22 pm Download All ▼
Program	BLASTN ? Citation ▼
Database	nt See details ▼
Query ID	lcl Query_135291
Description	MH011443.1 Homo sapiens TP53 (TP53) gene, exon 5 an ...
Molecule type	dna
Query Length	123
Other reports	Distance tree of results MSA viewer ?

Descriptions

Graphic Summary

Alignments

Taxonomy



序列比对-数据库搜索

BLAST在线工具

Descriptions									
Sequences producing significant alignments									
Download Select columns Show 10									
select all 10 sequences selected									
GenBank Graphics Distance tree of results MSA Viewer									
	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	Homo sapiens TP53 (TP53) gene, exon 5 and partial cds	Homo sapiens	237	237	100%	5e-58	100.00%	123	MH011443.1
☒	Homo sapiens isolate A549DDP-2-1 tumor suppressor p53 gene, exons 5 and 6 and partial cds	Homo sapiens	231	231	100%	3e-56	99.19%	513	OQ503644.1
☒	Homo sapiens isolate A549DDP-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds	Homo sapiens	231	231	100%	3e-56	99.19%	493	OQ503643.1
☒	Homo sapiens isolate A549-C-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds	Homo sapiens	231	231	100%	3e-56	99.19%	495	OQ503641.1
☒	Homo sapiens isolate 549-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds	Homo sapiens	231	231	100%	3e-56	99.19%	521	OQ503633.1
☒	Homo sapiens tumor protein p53 (TP53), transcript variant 14, non-coding RNA	Homo sapiens	231	231	100%	3e-56	99.19%	2399	NR_176326.1
☒	Homo sapiens tumor protein p53 (TP53), transcript variant 12, mRNA	Homo sapiens	231	231	100%	3e-56	99.19%	2642	NM_001407269.1
☒	Homo sapiens tumor protein p53 (TP53), transcript variant 13, mRNA	Homo sapiens	231	231	100%	3e-56	99.19%	2658	NM_001407270.1
☒	Homo sapiens tumor protein p53 (TP53), transcript variant 9, mRNA	Homo sapiens	231	231	100%	3e-56	99.19%	2615	NM_001407262.1
☒	Homo sapiens tumor protein p53 (TP53), transcript variant 10, mRNA	Homo sapiens	231	231	100%	3e-56	99.19%	2522	NM_001407265.1


- E value: 表示随机匹配的可能性, E值越大, 随机匹配的可能性也越大。E值接近零或为零时, 基本上就是完全匹配了。



序列比对-数据库搜索

BLAST在线工具

➤ BLAST搜索结果——图形化概述





序列比对-数据库搜索

BLAST在线工具

Descriptions

Graphic Summary

Alignments

Taxonomy

Alignment view

Pairwise

☐ CDS feature

Restore defaults

Download

10 sequences selected

Download

GenBank

Graphics

▼ Next ▲ Previous << Descriptions

Homo sapiens TP53 (TP53) gene, exon 5 and partial cds

Sequence ID: [MH011443.1](#) Length: 123 Number of Matches: 1

Range 1: 1 to 123 [GenBank](#) [Graphics](#) ▼ Next Match ▲ Previous Match

Score	Expect	Identities	Gaps	Strand
237 bits(123)	5e-58	123/123(100%)	0/123(0%)	Plus/Plus
Query 1	TGGGTTGATTCCACACCCCGCCCGGCACCCGCGTCCGCGCCGTGGCCATCTACAAGCAG	60		
Sbjct 1	TGGGTTGATTCCACACCCCGCCCGGCACCCGCGTCCGCGCCGTGGCCATCTACAAGCAG	60		
Query 61	TCACAGCACATGACGGAGGTTGTGAGGCGCTGCCCCCACCATGAGCGCTGCTCAGATAGC	120		
Sbjct 61	TCACAGCACATGACGGAGGTTGTGAGGCGCTGCCCCCACCATGAGCGCTGCTCAGATAGC	120		
Query 121	GAT 123			
Sbjct 121	GAT 123			

BLAST搜索结果——具体比对序列

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

[Download](#) [GenBank](#) [Graphics](#)

Homo sapiens isolate A549DDP-2-1 tumor suppressor p53 gene, exons 5 and 6 and partial cds

Sequence ID: [OQ503644.1](#) Length: 513 Number of Matches: 1

Range 1: 150 to 272 [GenBank](#) [Graphics](#)

[Next Match](#) [Previous Match](#)

Score		Expect	Identities	Gaps	Strand
231 bits(120)		3e-56	122/123(99%)	0/123(0%)	Plus/Plus
Query	1	TGGGTTGATTCCACACCCCGCCCGGCACCCGCGTCCGCGCCGTGGCCATCTACAAGCAG			60
Sbjct	150	TGGGTTGATTCCACACCCCGCCCGGCACCCGCGTCCGCGCCATGGCCATCTACAAGCAG			209
Query	61	TCACAGCACATGACGGAGGTTGTGAGGCGCTGCCCCACCATGAGCGCTGCTCAGATAGC			120
Sbjct	210	TCACAGCACATGACGGAGGTTGTGAGGCGCTGCCCCACCATGAGCGCTGCTCAGATAGC			269
Query	121	GAT	123		
Sbjct	270	GAT	272		

BLAST搜索结果——具体比对序列

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Descriptions		Graphic Summary		Alignments		Taxonomy		
Reports		Lineage		Organism		Taxonomy		
10 sequences selected ?								
Description						Score	E value	Accession
Homo sapiens (human) [primates]						▼ Next	▲ Previous	◀ First
Homo sapiens TP53 (TP53) gene, exon 5 and partial cds						237	5e-58	MH011443
Homo sapiens isolate A549DDP-2-1 tumor suppressor p53 gene, exons 5 and 6 and partial cds						231	3e-56	OQ503644
Homo sapiens isolate A549DDP-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds						231	3e-56	OQ503643
Homo sapiens isolate A549-C-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds						231	3e-56	OQ503641
Homo sapiens isolate 549-2 tumor suppressor p53 gene, exons 5 and 6 and partial cds						231	3e-56	OQ503633
Homo sapiens tumor protein p53 (TP53), transcript variant 14, non-coding RNA						231	3e-56	NR_176326
Homo sapiens tumor protein p53 (TP53), transcript variant 12, mRNA						231	3e-56	NM_001407269
Homo sapiens tumor protein p53 (TP53), transcript variant 12, mRNA						231	3e-56	NM_001407268
Homo sapiens tumor protein p53 (TP53), transcript variant 13, mRNA						231	3e-56	NM_001407270
Homo sapiens tumor protein p53 (TP53), transcript variant 13, mRNA						231	3e-56	NM_001407271
Homo sapiens tumor protein p53 (TP53), transcript variant 9, mRNA						231	3e-56	NM_001407262
Homo sapiens tumor protein p53 (TP53), transcript variant 9, mRNA						231	3e-56	NM_001407263
Homo sapiens tumor protein p53 (TP53), transcript variant 10, mRNA						231	3e-56	NM_001407265
Homo sapiens tumor protein p53 (TP53), transcript variant 10, mRNA						231	3e-56	NM_001407264

BLAST搜索结果——分类学描述

明德至诚 博学远志



BLAST在线工具

实例2：多结构域蛋白 (H1N1) 的BLAST检索

Chain A, COVID-19 MAIN PROTEASE

```
>pdb|7DAV|A Chain A, COVID-19 MAIN PROTEASE  
SGFRKMAFPSGKVEGCMVQVTCGTTTLNGLWLDDVVYCPRHVICTSED  
MLNPNYEDLLIRKSNHNFLVQA  
GNVQLRVIGHSMQNCVLKLKVD TANPKTPKYKFVRIQPGQTFSVLACY  
NGSPSGVYQCAMRPNFTIKGSF  
LNGSCGSVGFNIDYDCVSFCYMHMELPTGVHAGTDLEGNFYGPFVDR  
QTAQAAGTDTTITVNVLAWLYA  
AVINGDRWFLNRFTTTLNDFNLVAMKYNYEPLTQDHVDILGPLSAQTGIA  
VLDMCASLKELLQNGMNGRT  
ILGSALLEDEFTPFDVVRQC SGVTFQ
```



序列比对-数据库搜索

BLAST在线工具

Standard Protein BLAST

blastn **blastp** blastx tblastn tblastx

BLASTP programs search protein databases using a protein query. more...

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) [?](#) [Clear](#)

>pdb|7DAV|A Chain A, COVID-19 MAIN PROTEASE
SGFRKMAFPSGKVEGCMVQVTCGTTTLNGLWLDVVYCPRHVICTSEDML
NPNYEDLLIRKSNHNFVLQA
GNVQLRVIGHSMQNCVLKLVDTANPKTPKYKFVRIQPGQTFVLACYNGSP

Query subrange [?](#)

From

To

Or, upload file 未选择文件 [?](#)

Job Title

Enter a descriptive title for your BLAST search [?](#)

☐ Align two or more sequences [?](#)

Choose Search Set

Databases ☒ Standard databases (nr etc.): **New** ☐ Experimental databases

Compare ☐ Select to compare standard and experimental database [?](#)

Standard

Database [?](#)

Organism Optional ☐ exclude [Add organism](#)

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown [?](#)

Exclude Optional ☐ Models (XM/XP) ☐ Non-redundant RefSeq proteins (WP) ☐ Uncultured/environmental sample sequences

Program Selection

Algorithm

☒ Quick BLASTP (Accelerated protein-protein BLAST)

☒ blastp (protein-protein BLAST)

☐ PSI-BLAST (Position-Specific Iterated BLAST)

☐ PHI-BLAST (Pattern Hit Initiated BLAST)

☐ DELTA-BLAST (Domain Enhanced Lookup Time Accelerated BLAST)

Choose a BLAST algorithm [?](#)



序列比对-数据库搜索

BLAST在线工具

BLAST® » blastp suite » results for RID-K6WG4B5P013

[Home](#) [Recent Results](#) [Saved Strategies](#) [Help](#)

Check out the ClusteredNR database on BLAST+

[Learn more](#)

[Give us feedback](#)

[< Edit Search](#)

[Save Search](#)

[Search Summary](#) ▼

[? How to read this report?](#)

[BLAST Help Videos](#)

[↶ Back to Traditional Results Page](#)

Job Title	COVID-19 chain A		
RID	K6WG4B5P013	Search expires on 10-22 14:39 pm	Download All ▼
Program	BLASTP ?	Citation	▼
Database	nr	See details	▼
Query ID	lcl Query_21446		
Description	pdb 7DAV A Chain A, COVID-19 MAIN PROTEASE		
Molecule type	amino acid		
Query Length	306		
Other reports	Distance tree of results	Multiple alignment	MSA viewer ?

Filter Results

Organism *only top 20 will appear*

☐ exclude

Type common name, binomial, taxid or group name

[+ Add organism](#)

Percent Identity

E value

Query Coverage

to

to

to

[Filter](#)

[Reset](#)

BLAST搜索结果——结果页面

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Descriptions

Graphic Summary

Alignments

Taxonomy

Sequences producing significant alignments

Download

Select columns

Show10

☒ select all

10 sequences selected

GenPept

Graphics

Distance tree of results

Multiple alignment


MSA Viewer

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4402	QVP06846.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4402	QRW91276.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4402	UHW23923.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4366	UFG36395.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4402	QVD88708.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4389	UGZ70179.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4404	UAM67509.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4402	QUV52576.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4350	UAM25291.1
☒	ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	Severe acute respiratory syndrome coronavirus 2	652	652	100%	0.0	100.00%	4405	WFJ56175.1



序列比对-数据库搜索

BLAST在线工具



BLAST搜索结果——图形化概述

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Descriptions

Graphic Summary

Alignments

Taxonomy

Alignment view

Pairwise

Restore defaults

10 sequences selected

Download

GenPept

Graphics

ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]
Sequence ID: [QVP06846.1](#) Length: 4402 Number of Matches: 1
[See 4 more title\(s\)](#) [See all Identical Proteins\(IPG\)](#)

Range 1: 3264 to 3569

GenPept

Graphics

Next Match

Previous Match

Score	Expect	Method	Identities	Positives	Gaps
652 bits(1682)	0.0	Compositional matrix adjust.	306/306(100%)	306/306(100%)	0/306(0%)
Query 1	SGFRKMAFP	SGKVEGCMVQVTCGTTTLNGLWLDDVVYCPRHVICTSEDMLNPNYEDLLIR	60		
Sbjct 3264	SGFRKMAFP	SGKVEGCMVQVTCGTTTLNGLWLDDVVYCPRHVICTSEDMLNPNYEDLLIR	3323		
Query 61	KSNHNFLVQAGNVQLRVIGHSMQNCVLKLVDTANPKTPKYKFVRIQPGQTF	SVLACYNG	120		
Sbjct 3324	KSNHNFLVQAGNVQLRVIGHSMQNCVLKLVDTANPKTPKYKFVRIQPGQTF	SVLACYNG	3383		
Query 121	SPSGVYQCAMPNFTIKGSFLNGSCG	SVGFNIDYDCVSFCYMHMELPTGVHAGTDLEGN	180		
Sbjct 3384	SPSGVYQCAMPNFTIKGSFLNGSCG	SVGFNIDYDCVSFCYMHMELPTGVHAGTDLEGN	3443		
Query 181	FYGPFDVDRQTAQAAGTDTTITVNVLAWLAAVINGDRWFLNRFTTTLNDFNLVAMKYNYE	240			
Sbjct 3444	FYGPFDVDRQTAQAAGTDTTITVNVLAWLAAVINGDRWFLNRFTTTLNDFNLVAMKYNYE	3503			
Query 241	PLTQDHDVILGPLSAQTGIAVLDMCASLKELLQNGMNGRTILGSALLEDEFTPF	DVVRQC	300		
Sbjct 3504	PLTQDHDVILGPLSAQTGIAVLDMCASLKELLQNGMNGRTILGSALLEDEFTPF	DVVRQC	3563		
Query 301	SGVTFQ	306			
Sbjct 3564	SGVTFQ	3569			

BLAST搜索结果——具体比对序列

明德至诚 博学远志



序列比对-数据库搜索

BLAST在线工具

Descriptions

Graphic Summary

Alignments

Taxonomy

Reports

Lineage

Organism

Taxonomy

10 sequences selected

?

Description	Score	E value	Accession
Severe acute respiratory syndrome coronavirus 2 [viruses]	▼ Next	▲ Previous	◀ First
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QVP06846
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QVP06882
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UBE83355
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UCI64070
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UCI64174
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QRW91276
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UHW23923
ORF1a polyprotein, partial [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UFG36395
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QVD88708
ORF1a polyprotein, partial [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UGZ70179
ORF1a polyprotein, partial [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UAM67509
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QUV52576
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	QXG91296
ORF1a polyprotein, partial [Severe acute respiratory syndrome coronavirus 2]	652	0.0	UAM25291
ORF1a polyprotein [Severe acute respiratory syndrome coronavirus 2]	652	0.0	WFJ56175

BLAST搜索结果——分类学描述

明德至诚 博学远志



三种BLAST算法

特性	标准BLAST	PSI-BLAST	PHI-BLAST
主要目标	快速比对高度相似序列	检测远缘同源序列	搜索包含特定模式的相似序列
算法核心	种子-延伸策略	迭代构建PSSM	模式搜索+局部比对
敏感性	较低	较高	中等
适用场景	基因注释、进化分析	蛋白质家族分析、远缘同源检测	功能域分析、模式搜索
输入要求	查询序列	查询序列	查询序列+特定模式
计算复杂度	低	高	中等




序列比对-数据库搜索

三种BLAST算法

PSI BLAST



BLAST



PHI BLAST





序列比对-多序列比对

多序列比对简介

- **多序列比对**：对两个以上字符序列进行比对，逐列比较其字符的异同，使得每一列的字符尽可能一致，以发现其共同的结构特征的方法
- **多序列比对目标**：使参与比对的序列间有尽可能多的列具有相同的字符，即，使得相同残基的位点位于同一列，以便于发现不同序列间的相似部分，从而推断它们在结构和功能上的相似关系，主要用于分子进化关系，预测蛋白质的二级结构和三级结构、估计蛋白质折叠类型的总数，基因组序列分析等。



序列比对-多序列比对

多序列比对简介

- 多序列比对主要涉及四个要素：
 - 选择一组能进行比对的序列（要求是同源序列）；
 - 选择一个实现比对与计分的算法与软件；
 - 确定软件的参数；
 - 合理地解释比对的结果；



序列比对-多序列比对

多序列比对简介

➤ 多序列全局比对

- 假定序列中所有对应字符均可以匹配，所有字符具有同等的重要性，空格的插入是为了使整个序列得到比对，包括使两端对齐。
- 把整个序列当成一个保守的区段，关心的是序列整体上的可比性与相似度，常用于外显子测序、RNA序列和蛋白质序列的比对。

➤ 多序列局部比对



- 不假定整个序列可以匹配，重在考虑序列中能够高度匹配的一个区段，可赋予该区段更大的计分权值，空格的插入是为了使高度匹配的区段得到更好的比对。
- 关心序列中某个保守区段之间的可比性与相似度，常用于揭示多个序列中的一个保守区段。



序列比对-多序列比对

多序列全局比对

1. 动态规划法



- (A) 计算三个序列间的一个比对单元 (i, j, k) 依赖于其7个前导项;
- (B) 计算 $u = \text{ATGTTAT}$, $v = \text{ATCGTAC}$, $w = \text{ATGC}$ 三序列比对的三维得分矩阵。



序列比对-多序列比对

多序列全局比对

2.渐进多序列比对

➤ 步骤

- ① 使用动态规划法对每两个序列进行配对比对，该步多使用距离矩阵来描述序列间的关联性
- ② 由距离矩阵构造一棵指导树(guide tree),反映序列间的关联情况
- ③ 以计分最高的配对比对作为“种子”，根据指导树逐渐向多序列比对中加入序列

➤ 代表算法：**ClustalW/ ClustalX**

➤ 优点：能处理高达数百个序列的比对

➤ 缺点：不保证产生全局最优的比对，容易陷入局部最优解（坏种子；序列加入顺序；失配传播）



序列比对-多序列比对

多序列全局比对


2. 渐进多序列比对

两两比对
构建距离矩阵

Hbb_Human	1	-					
Hbb_Horse	2	.17	-				
Hba_Human	3	.59	.60	-			
Hba_Horse	4	.59	.59	.13	-		
Myg_Phyca	5	.77	.77	.75	.75	-	
Glb5_Petma	6	.81	.82	.73	.74	.80	-
Lgb2_Luphu	7	.87	.86	.86	.88	.93	.90
		1	2	3	4	5	6

Pairwise alignment:
Calculate distance matrix

构建指导树
(guide tree)



Rooted neighbor-joining
tree (guide tree)

将距离最近的两条
序列用动态规划的
算法进行比对；

“渐进”的加上其
他的序列

```
-----VHLTPEEKSAVTALWKN--DDEVGGEALGRLLVNPTQFFESFGDLST
-----VQLSGEKAALALWKN--EEVVGGEALGRLLVNPTQFFESFGDLST
-----VLSPADKTNVKAAGKVGAGAGEYGAELERMFLOPTTKTYFPHFDLS--
-----VLSAADKTNVKAAGKVGAGAGEYGAELERMFLOPTTKTYFPHFDLS--
-----VLSGGEWQLVHVAWAKVADVAGHGQDILRLFKSHETLEKFDKFKHLKT
PIVOTGSVAPLSAAEKTIRSAWAPVYSTVETSGVDILVKFPTSTPAQEPFPPKFGLT
-----GALTESQAALVKSSEEFNANIPKTHREFFILVLETPAAKILFSFLKGTSE
```

Progressive
alignment:
Align following
the guide tree

```
PDVAMGNPKVKANGKKVLGAFSDGIDHLD----NLKGTFAATLSELHCKLHVDPENFRL
PGAVMGNPKVKANGKKVLHSGEGVHLD----NLKGTFAALSELHCKLHVDPENFRL
---HGSAQVKGHGKKVADALTNAVAHVDDMPNALSALSDLHAHKLRLVPVNFKL
---HGSAQVKGHGKKVGDALTNAVAHVDDMPNALSALSDLHAHKLRLVPVNFKL
EAEMKASEDLKKHGVTVLTALGAILKKKG---HPEAELKPLAQSHATKHKIIEKYLEF
ADQLKKSADVRAAERTINAVNDVAVSMDOT--EKDSMKLRDLGSKHAKSFQVTPQYFKV
VP--QNNPELQAHAGKVKLVYEAATQLQVTVGVVVDATLKHLSGVIVSAG--VAHAHPFV
```

```
LGNLVLCVLAHHPGKEFTPPVQAAKYQKVAGVANALAHKYH-----
LGNLVVVLAAHPGKDFTPQLQASYQKVAGVANALAHKYH-----
LSHCLLVTLAAHLPAEFTPAVHAASLDFLASVSTVLTISKYR-----
LSHCLLVTLAAHLPNDFTPAVHAASLDFLASVSTVLTISKYR-----
ISEAIIHVLHSHHPGDFGADAQGANNALELFRKDIAPKTKELGYQG
LAAVIADTVAAQ-----DADPEKIMSMICILLRSAY
VKEAIIKTTKEVAGAKWSEELNSNTIAVDRLATVIRKENDAA--
```

@



序列比对-多序列比对

多序列全局比对

3. 迭代法

- 基本过程：先用渐进多序列比对产生一个初始结果，再对序列的不同子集进行反复比对并利用这些结果重新进行多序列比对，目标是改进多序列比对的总计分值。
- 迭代法常使用随机搜索或者通过对比对结果进行重排来寻找更优的解，直到计分值不再提高
- 常用算法：**MAFFT**



序列比对-多序列比对

多序列全局比对

4. 基于一致性的方法

- **一致性**：对于序列 X 、 Y 和 Z ，若 X_i 比对于 Z_k 且 Z_k 比对于 Y_j ，则 X_i 应比对于 Y_j 。
- **基本特点**：充分利用多个序列间的比对信息对配对比对进行更合理的计分。
- **代表算法**：**ProbCons**, **T-Coffee**



序列比对-多序列比对

多序列局部比对

- 待比对的多个序列长度相当且高度相似，全局比对与局部比对的结果基本相同
- 待比对的多个序列长度差异较大或亲缘关系较远，全局比对与局部比对的结果相差较大。

```
--T--CC-C-AGT--TATGT-CAGGGGACACG--A-GCATGCAGA-GAC
|  |  |  |  |  |  |  |  |  |  |  |  |  |  |  |  |  |
AATTGCCGCC-GTCGT-T-TTCAG----CA-GTTATG--T-CAGAT--C
```

```
          tccCAGTTATGTCAGgggacacgagcatgcagaga
          |||||
aattccgccgctcggttttcagCAGTTATGTCAGatc
```



序列比对-多序列比对

多序列局部比对

➤ 常用多序列局部比对软件

- **SAM**: 基于隐马尔可夫模型, 蛋白质结构预测
- **Mulan**: 发现进化上保守的功能元件



序列比对-多序列比对

Clustal Omega


- ClustalX和ClustalW是两个使用**最广泛**的多序列比对工具，均采用**渐进式多序列比对**算法。
- Clustal Omega是欧洲生物信息研究所（EBI）开发的多序列比对工具，现已经完全取代了之前ClustalW 的地位



序列比对-多序列比对

Clustal Omega

➤ <https://www.ebi.ac.uk/Tools/msa/clustalo/>



Tools > Multiple Sequence Alignment > Clustal Omega

Multiple Sequence Alignment

Clustal Omega is a new multiple sequence alignment program that uses seeded guide trees and HMM profile-profile techniques to generate alignments between **three or more** sequences. For the alignment of two sequences please instead use our pairwise sequence alignment tools.

Important note: This tool can align up to 4000 sequences or a maximum file size of 4 MB.

明德至诚 博学远志



序列比对-多序列比对

>sp_Q9BXR5 HUMAN TLR10 TIR

CLHPDLPWYLRMLGOCTOTWHRVRKTTQEQLKRNVRFHAFISYSEHDSLWVKNELIPNLEKEDGSILICLYESYFDPGKSISENIVSFIEKS
YKSIFVLSPNFV9NEWCHYEFYFAHHNLFHENS DHIILILLEPIPFYCIPTRYHKLKALLEKKAYLEWPKDRRKCGLFWANLRAAINVNVLA
TREMYELQTFTELNEESRGSTISLMRTDCL

>sp_Q9NR96 HUMAN TLR9 TIR

GNDLWYCHLCLAWLPRGRQSGRDEDALPYDAFVVFDKTQSAVADWVYNELRGQLEECRGRWALRLCLEERDWLPGKTLFENLWASVY
GSRKTLFVLAHTDRVSGLLRASFLLAQQRLLED RKDVLVILSPDGRRSRYVRLRQRLCRQSVLLWPHOPSGQRSFWAQLGMALTRDNHH
FYNRNFCOGPTAE

>sp_Q9NR97 HUMAN TLR8 TIR

HALFYWDVWFIYNVCLAKVKGYRSLSTSQTIFYDAYISYDTKDASVTDWVINELRYHLEESRDKNVLLCLEERDWD PGLAIIDNLMQSIN
QSKKTVFVLTKKYAKSWNFKTA FYLALQRLMDENMDVIIFILLEPVLQHSQYLLRORICKSSILQWPDNPKAEGLFWQTLRNVVLTENDS
RYNNMYVDSIKOY

>sp_Q9NYKI HUMAN_TLR7_TIR

HLYFWDWYIYHFCKAKIKGYORLISPDCCYDAPIVYDTKDPAVTEWVLAELVAKLEDPREKHFNLCLEERDLP GQPVLNLSQSIQLSKKT
VFVMTDKYAKTENFKIAFYLSHORLMDEKVDVIILIFLEKPFQKSKFLQLRKRLCGSSVLEWPTNPQAHPYFWQCLKNALATDNHVAYSQ
VEKETV

>sp_Q9Y2C9 HUMAN_TLR6_TIR

YLDLPWYLRMVCQWTQTRRRARNIPLEELRN LQFHAFISYSEHDSAWVKSELVPYLEKEDIQICLHERNFVPGKSIVENIINCIERSYKSIVL
SPNFVQSEWCHYELYFAHHNLFHEGISNNLILILLEPIPQNSIPNKYHKLKALMTORTYLQWPKEKSKRGLFWANIRAAFNMKLTLVTENN
DVKS

>sp_060602 HUMAN TLR5 TIR

TKFRGECEICKTAQRLVFKDHPQGTEPD MYKYDAYLCFSSKDFTWVQNALLKHLDTQYSDONRFNLCFEERDFVPGENRIANIQDAIWN
RKIVCLVSRHFLRDGCLEAFSYAQGRCLSD LNSALIMVVVGSLSQYOLMKHOSIRGFVOKQQYLRWPEDFQDVGWFLHKLSQQILKKEK
EKKKDNNILOTVATIS



序列比对-多序列比对

Clustal Omega

- 实例1：在基因重组人胰岛素面市之前，糖尿病患者所需胰岛素主要来自屠宰场的动物胰脏。请分析来源自猪、牛和羊的胰岛素哪一种最适于人使用，说明理由。

>AAA59172.1 insulin [Homo sapiens]

MALWMRLPLLLALLALWGPDPAAAFVNQHLCGSHLVEALYLVCGERGFFYTPKTRREAEDLQVGQVELGG
GPGAGSLQPLALEGSLQKRGIVEQCCTSIKSLYQLENYCN

>AAQ00954.1 preproinsulin [Sus scrofa]

MALWTRLPLLLALLALWAPAPAQAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREAENPQAGAVELGG
GLGGLQALALEGPPQKRGIVEQCCTSIKSLYQLENYCN

>AAA30722.1 insulin precursor [Bos taurus]

MALWTRLRPLLLALLALWPPPPARAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREVEGPQVGALELAG
GPGAGGLEGPQKRGIVEQCCASVCSLYQLENYCN

>sp|P01318.2|INS_SHEEP RecName: Full=Insulin; Contains: RecName: Full=Insulin B chain; Contains: RecName: Full=Insulin A chain;
Flags: Precursor

MALWTRLVPLLLALLALWAPAPAHAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREVEGPQVGALELAG
GPGAGGLEGPQKRGIVEQCCAGVCSLYQLENYCN



序列比对-多序列比对

Clustal Omega

➤ Step1: 输入待比对序列

STEP 1 - Enter your input sequences

Enter or paste a set of

PROTEIN

sequences in any supported format:

```
>AAQ00954.1 preproinsulin [Sus scrofa]
MALWTRLLPLLALLALWAPAPAQAFVNQHLGSHLVEALYLVCGERGFFYTPKARREAENPQAGAVELGG
GLGGLQALALEGPPQKRGIVEQCCTSICSLYQLENYCN
>AAA30722.1 insulin precursor [Bos taurus]
MALWTRLRPLLALLALWPPPPARAFVNQHLGSHLVEALYLVCGERGFFYTPKARREVEGPQVGALELAG
GPGAGGLEGPPQKRGIVEQCCASVCSLYQLENYCN
>sp|P01318.2|INS_SHEEP RecName: Full=Insulin; Contains: RecName: Full=Insulin B chain; Contains: RecName: Full=Insulin A chain; Flags: Precursor
MALWTRLVPLLALLALWAPAPAHAFVNQHLGSHLVEALYLVCGERGFFYTPKARREVEGPQVGALELAG
```

Or, upload a file: 未选择文件

[Use a example sequence](#) | [Clear sequence](#) | [See more example inputs](#)

明德至诚 博学远志



序列比对-多序列比对

Clustal Omega

- Step2: 参数设置。大多数情况下使用默认参数

STEP 2 - Set your parameters

OUTPUT FORMAT

ClustalW with character counts

The default settings will fulfill the needs of most users.

More options...

(Click here, if you want to view or change the default settings.)



序列比对-多序列比对

Clustal Omega

➤ Step3: 提交任务

STEP 3 - Submit your job

☐ Be notified by email (*Tick this box if you want to be notified by email when the results are available*)

Submit





序列比对-多序列比对

Clustal Omega

➤ 比对结果：“*”表示**比对上的位置**

Results for job clustalo-l20231021-082945-0319-66080987-p1m

Alignments

Result Summary

Guide Tree

Phylogenetic Tree

Results Viewers

Submission Details

Download Alignment File

Show Colors

CLUSTAL O(1.2.4) multiple sequence alignment

```
AAA59172.1      MALWMRLLPLLALLALWGPDPAAAFVNQHLCGSHLVEALYLVCGERGFFYTPKTRREAED 60
AAQ00954.1      MALWTRLLPLLALLALWAPAPAQAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREAEN 60
AAA30722.1      MALWTRLRPLLALLALWPPPPARAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREVEG 60
sp|P01318.2|INS_SHEEP MALWTRLVPLLALLALWAPAPAHAFVNQHLCGSHLVEALYLVCGERGFFYTPKARREVEG 60
**** * * **** * * ****

AAA59172.1      LQVGQVELGGGPGAGSLQPLALEGSLQKRGIVEQCCTSICSLYQLENYCN 110
AAQ00954.1      PQAGAVELGGGLG—GLQALALEGPPQKRGIVEQCCTSICSLYQLENYCN 108
AAA30722.1      PQVGALELAGGPG——AGGLEGPPQKRGIVEQCCASVCSLYQLENYCN 105
sp|P01318.2|INS_SHEEP PQVGALELAGGPG——AGGLEGPPQKRGIVEQCCAGVCSLYQLENYCN 105
*.* :*. ** * .*** *****.:*****
```

明德至诚 博学远志



序列比对-多序列比对

Clustal Omega

Results for job clustalo-l20231021-082945-0319-66080987-p1m

Alignments

Result Summary

Guide Tree

Phylogenetic Tree


Results Viewers

Submission Details

Download Guide Tree Data

Phylogram

Branch length: ☒ Cladogram ☐ Real



AAA59172.1 0.0881614

AAQ00954.1 0.0785714

AAA30722.1 0.0238095

sp|P01318.2|INS_SHEEP 0.0238095

Guide Tree

明德至诚 博学远志



序列比对-多序列比对

Clustal Omega

Results for job clustalo-l20231021-082945-0319-66080987-p1m

Alignments

Result Summary

Guide Tree

Phylogenetic Tree

Results Viewers

Submission Details

Download Phylogenetic Tree Data

Phylogenetic Tree

This is a Neighbour-joining tree without distance corrections.

Branch length: ☒ Cladogram ☐ Real



AAA59172.1 0.09339
AAQ00954.1 0.03624
AAA30722.1 0.02381
sp|P01318.2|INS_SHEEP 0.02381

明德至诚 博学远志