



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING


生物信息学

熊壮 博士

医工交叉研究院

Interdisciplinary Institute for Medical Engineering

bioinformatics_fzu@163.com



明德至诚 博学远志




序列比对-双序列比对算法

双序列全局比对

➤ Needleman-Wunsch算法

- a, b 是两条待比对序列
- $|a| = m, |b| = n$
- $S(i, j)$ 是按照指定替换打分矩阵得到的前缀 $a[1...i]$ 与 $b[1...j]$ 的最大相似性得分
- $w(c, d)$ 是字符 c 和 d 按照替换计分矩阵计算的得分
- $S(0, 0) = 0$

$$S(i, j) = \max \begin{cases} S(i-1, j-1) + w(a_i, b_j) & \text{匹配或失配} \\ S(i-1, j) + w(a_i, -) & a_i \text{ 比对到空格上} \\ S(i, j-1) + w(-, b_j) & b_j \text{ 比对到空格上} \end{cases}$$





序列比对-双序列比对算法

双序列全局比对

- 例题1：利用动态规划算法对序列 $a = \text{AGCACCA}$ 与序列 $b = \text{ACACTA}$ 进行全局比对。计分规则： $w(\text{匹配}) = +2$ ； $w(a, -) = w(-, b) = w(\text{失配}) = -1$



序列比对-双序列比对算法

双序列全局比对

➤ 矩阵初始化


	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1						
C	-2						
A	-3						
C	-4						
T	-5						
A	-6						

$$S(i, j) = \max \begin{cases} S(i-1, j-1) + w(a_i, b_j) & \text{匹配或失配} \\ S(i-1, j) + w(a_i, -) & \text{\textcolor{red}{a}_i 比对到空格上} \\ S(i, j-1) + w(-, b_j) & \text{\textcolor{red}{b}_j 比对到空格上} \end{cases}$$

➤ 计算比对得分

➤ $w(\text{匹配}) = +2$

➤ $w(a, -) = w(-, b)$
 $= w(\text{失配}) = -1$



双序列全局比对

	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1						
C	-2						
A	-3						
C	-4						
T	-5						
A	-6						



序列比对-双序列比对算法

双序列全局比对

➤ 回溯路径：从右下角向元素开始，回溯到当前单元格来源的单元格中值最大的单元格。

	—	A	G	C	A	C	A
—	0	-1	-2	-3	-4	-5	-6
A	-1	2 +	1 ←	0 ←	-1 ←	-2 ←	-3 ←
C	-2	1 ↑	1 +	3 +	2 ←	1 ←	0 ←
A	-3	0 +	0 ↑	2 ↑	5 +	4 ←	3 ←
C	-4	-1 ↑	-1 +	2 +	4 ↑	7 +	6 ←
T	-5	-2 ↑	-2 +	1 ↑	3 ↑	6 ↑	6 +
A	-6	-3 +	-3 ↑	0 ↑	3 +	5 ↑	8 +

A G C A C — A
A — C A C T A



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

第四章 多组学分析-基因组学

明德至诚 博学远志



1. 测序数据存储格式与质量控制
2. 基因与基因组的基本概念
3. 基因与基因组结构
4. 基因组测序 DNA-seq
5. 基因组变异
6. 基因组注释



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学

1. 测序数据存储格式与质量控制

明德至诚 博学远志



FASTA

测序数据存储格式

- **fasta格式**是一种非常简单的储存序列的格式，可以储存核酸序列（DNA/RNA）也可以储存蛋白质的氨基酸序列（Amino Acid sequence，简称AA序列）
- **“>”为开始的一行主要储存的是序列的描述信息**；剩下的是序列部分，中间，前后都可以有空格。

```
>sp|P69905|HBA_HUMAN Hemoglobin subunit alpha OS=Homo sapiens GN=HBA1  
MVLSPADKTNVKAAWGKVGAHAGEYGAEALERMFLSFPTTKTYFPHFDLSHGSAQVKGHG  
KKVADALTNAVAHVDDMPNALSALSDLHAHKLRVDPVNFKLLSHCLLVTLAAHLPAEFTP  
AVHASLDKFLASVSTVLTSKYR
```




测序数据存储格式与质量控制

FASTA

测序数据存储格式

```
>sp|P69905|HBA_HUMAN Hemoglobin subunit alpha OS=Homo sapiens GN=HBA1
MVLSPADKTNVKAAWGKVGAHAGEYGAEALERMFLSFPTTKTYFPHFDLSHGSAQVKGHG
KKVADALTNAVAHVDDMPNALSALSDLHAHKLRVDPVNFKLLSHCLLVTLAAHLPAEFTP
AVHASLDKFLASVSTVLTSKYR
```

人类血红蛋白 α 亚基

➤ **第一行：以”>”,包含了序列的描述信息。**

sp: 代表该序列来自Swiss-Prot 数据库; gi开头代表来自NCBI

P69905是这个序列在Swiss-Prot中的编号

HBA_HUMAN是这个序列的简称

Hemoglobin subunit alpha是全称

➤ **序列部分按照官方文档的说明应该是小于120就行，一般70到80左右。**



FASTA

测序数据存储格式

氨基酸字母简称对应表

A	alanine	P	proline
B	aspartate/asparagine	Q	glutamine
C	cystine	R	arginine
D	aspartate	S	serine
E	glutamate	T	threonine
F	phenylalanine	U	selenocysteine
G	glycine	V	valine
H	histidine	W	tryptophan
I	isoleucine	Y	tyrosine
K	lysine	Z	glutamate/glutamine
L	leucine	X	any
M	methionine	*	translation stop
N	asparagine	-	gap of indeterminate length

核酸字母简称对应表

A	adenosine	C	cytidine	G	guanine
T	thymidine	N	A/G/C/T (any)	U	uridine
K	G/T (keto)	S	G/C (strong)	Y	T/C (pyrimidine)
M	A/C (amino)	W	A/T (weak)	R	G/A (purine)
B	G/T/C	D	G/A/T	H	A/C/T
V	G/C/A	-	gap of indeterminate length		



测序数据存储格式与质量控制

FASTQ

测序数据存储格式

Illumina平台测序的真实数据，其中包含了1条reads的信息：

测序读段标识符

@ST-E00126:128:HJFLHCCXX:2:1101:7405:1133

TTGCAAAAATTCTCTCATTCTGTAGGTTGCCTGTTCACTCTGATGATAGTTTGT TTTTGG

+

FFKKKFKKFKF<KK<F,AFKKKKK7FFK77<FKK,<F7K,,7AF<FF7FKK7AA,7<FA,,

@

ST-E00126:128:HJFLHCCXX

2

1101

7405

1133

开始的标记符号

测序仪唯一的设备名称

lane的编号

tile的编号

在tile中的X坐标

在tile中的Y坐标



测序数据存储格式与质量控制

FASTQ

测序数据存储格式

Illumina平台测序的真实数据，其中包含了1条reads的信息：

```
@ST-E00126:128:HJFLHCCXX:2:1101:7405:1133
```

```
TTGCAAAAAATTTCTCTCATTCTGTAGGTTGCCTGTTCACTCTGATGATAGTTTGT TTTGG
```

测序序列

+

```
FFKKKFKKFKF<KK<F,AFKKKKK7FFK77<FKK,<F7K,,7AF<FF7FKK7AA,7<FA,,
```

测序得到的序列信息由 A、T、C、G、N 组成的字符串，N 表示无法确定的碱基（低质量或测序错误）。



测序数据存储格式与质量控制

FASTQ

测序数据存储格式

Illumina平台测序的真实数据，其中包含了1条reads的信息：

```
@ST-E00126:128:HJFLHCCXX:2:1101:7405:1133
```

```
TTGCAAAAAATTTCTCTCATTCTGTAGGTTGCCTGTTCACTCTGATGATAGTTTGT TTTTGG
```

分隔符

```
+
```

```
FFKKKFKKFKF<KK<F,AFKKKKK7FFK77<FKK,<F7K,,7AF<FF7FKK7AA,7<FA,,
```

以 + 开头，后面可以跟随与第一行相同的标识符（可选），一般为空



测序数据存储格式与质量控制

FASTQ

测序数据存储格式

Illumina平台测序的真实数据，其中包含了1条reads的信息：

```
@ST-E00126:128:HJFLHCCXX:2:1101:7405:1133
```

```
TTGCAAAAAATTTCTCTCATTCTGTAGGTTGCCTGTTCACTCTGATGATAGTTTGT TTTTGG
```

```
+
```

```
FFKKKFKKFKF<KK<F,AFKKKKKK7FFK77<FKK,<F7K,,7AF<FF7FKK7AA,7<FA,,
```

质量分数

由 ASCII 字符组成的字符串，每个字符对应第二行中一个碱基的**质量分数**，**质量分数**表示测序碱基的可靠性，使用 Phred 质量分数（Q score）编码。



FASTQ

测序数据存储格式

在测序仪进行测序的时候，会自动根据荧光信号的强弱给出一个参考的测序错误概率（error probability, P ）。
P值肯定是越小越好。

我们如何记录和存储呢？

$$\text{Solexa } Q = -10 * \log_{10} \frac{P}{1-P}$$

例如：某一个碱基的错误概率为 $P=0.01$

$$\text{Illumina } Q = -10 * \log_{10} P$$

1. 将 P 取 $\log_{10}$ 之后再乘以-10，得到的结果为 Q 。

$P=1\%$ ，那么对应的 $Q=-10*\log_{10}(0.01)=20$

2. 把这个 Q 加上33或者64转成一个新的数值，称为Phred，最后把Phred对应的ASCII字符对应到这个碱基。

如 $Q=20$ ， $\text{Phred} = 20 + 33 = 53$ ，对应的符号是"5"



测序数据存储格式与质量控制

FASTQ

测序数据存储格式

十六进制	十进制	字符	十六进制	十进制	字符	十六进制	十进制	字符	十六进制	十进制	字符
0	0	nul	20	32	sp	40	64	@	60	96	'
1	1	soh	21	33	!	41	65	A	61	97	a
2	2	stx	22	34	"	42	66	B	62	98	b
3	3	etx	23	35	#	43	67	C	63	99	c
4	4	eot	24	36	\$	44	68	D	64	100	d
5	5	enq	25	37	%	45	69	E	65	101	e
6	6	ack	26	38	&	46	70	F	66	102	f
7	7	bel	27	39	`	47	71	G	67	103	g
8	8	bs	28	40	(	48	72	H	68	104	h
9	9	ht	29	41	)	49	73	I	69	105	i
A	10	nl	2A	42	*	4A	74	J	6A	106	j
B	11	vt	2B	43	+	4B	75	K	6B	107	k
C	12	ff	2C	44	,	4C	76	L	6C	108	l
D	13	cr	2D	45	-	4D	77	M	6D	109	m
E	14	so	2E	46	.	4E	78	N	6E	110	n
F	15	si	2F	47	/	4F	79	O	6F	111	o
10	16	dle	30	48	0	50	80	P	70	112	p
11	17	dc1	31	49	1	51	81	Q	71	113	q
12	18	dc2	32	50	2	52	82	R	72	114	r
13	19	dc3	33	51	3	53	83	S	73	115	s
14	20	dc4	34	52	4	54	84	T	74	116	t
15	21	nak	35	53	5	55	85	U	75	117	u
16	22	syn	36	54	6	56	86	V	76	118	v
17	23	etb	37	55	7	57	87	W	77	119	w
18	24	can	38	56	8	58	88	X	78	120	x
19	25	em	39	57	9	59	89	Y	79	121	y
1A	26	sub	3A	58	:	5A	90	Z	7A	122	z
1B	27	esc	3B	59	;	5B	91	[	7B	123	{
1C	28	fs	3C	60	<	5C	92	\	7C	124	
1D	29	gs	3D	61	=	5D	93	]	7D	125	}
1E	30	re	3E	62	>	5E	94	^	7E	126	~
1F	31	us	3F	63	?	5F	95	_	7F	127	del



测序数据存储格式与质量控制

测序数据质量控制

- ◆ 测序结果的好坏会影响后续数据分析的可靠性，测序完成后的第一个步骤是对原始读段（raw read）进行质量评价，包括移除、修剪或校正不满足给定标准的read
- ◆ 一般情况下，质量控制包括碱基质量得分及核苷酸分布的可视化和基于碱基质量得分及序列质量（如引物污染、控制N含量和GC偏性等）进行read的修剪和过滤。
- ◆ 评估Illumina 测序结果的常用工具为 **FastQC**，工具 **NGSQC** 适用于所有测序平台



测序数据存储格式与质量控制

评估测序数据质量——FastQC

- ◆ FastQC是一款基于Java的软件，一般都是在linux环境下使用命令行运行，它可以快速多线程地对测序数据进行质量评估 (Quality Control)

```
[menghw@ ~]$ fastqc
Exception in thread "main" java.awt.HeadlessException:
No X11 DISPLAY variable was set, but this program performed an operation which requires it.
    at java.awt.GraphicsEnvironment.checkHeadless(GraphicsEnvironment.java:207)
    at java.awt.Window.<init>(Window.java:535)
    at java.awt.Frame.<init>(Frame.java:420)
    at java.awt.Frame.<init>(Frame.java:385)
    at javax.swing.JFrame.<init>(JFrame.java:174)
    at uk.ac.babraham.FastQC.FastQCApplication.<init>(FastQCApplication.java:63)
    at uk.ac.babraham.FastQC.FastQCApplication.main(FastQCApplication.java:332)
```



测序数据存储格式与质量控制

评估测序数据质量——FastQC

```
[menghw@ ~]$ fastqc --help

FastQC - A high throughput sequence QC analysis tool

SYNOPSIS

    fastqc seqfile1 seqfile2 .. seqfileN

    fastqc [-o output dir] [--(no)extract] [-f fastq|bam|sam]
           [-c contaminant file] seqfile1 .. seqfileN

DESCRIPTION

    FastQC reads a set of sequence files and produces from each one a quality
    control report consisting of a number of different modules, each one of
    which will help to identify a different potential type of problem in your
    data.
```

- ◆ -o --outdir FastQC生成的报告文件的储存路径，生成的报告的文件名是根据输入来定的
- ◆ --extract 生成的报告默认会打包成1个压缩文件，使用这个参数是让程序不打包
- ◆ -t --threads 选择程序运行的线程数，每个线程会占用250MB内存，越多越快咯
- ◆ -c --contaminants 污染物选项，输入的是一个文件，格式是Name [Tab] Sequence，里面是可能的污染序列，如果有这个选项，FastQC会在计算时候评估污染的情况，并在统计的时候进行分析，一般用不到

```
fastqc -o ./tmp.result/fastQC/ -t 6 ./tmp.data/fastq/H1EScell-dnase-2014-GSE56869_20151208_SRR1248176_1.fq
```



测序数据存储格式与质量控制

评估测序数据质量——FastQC

H1EScell-dnase-2014-GSE56869_20151208_SRR1248176_1.fq_fastqc.html

H1EScell-dnase-2014-GSE56869_20151208_SRR1248176_1.fq_fastqc.zip





测序数据存储格式与质量控制

评估测序数据质量——FastQC

Summary

- ✓ [Basic Statistics](#)
- ✓ [Per base sequence quality](#)
- ✓ [Per tile sequence quality](#)
- ✓ [Per sequence quality scores](#)
- ✗ [Per base sequence content](#)
- ! [Per sequence GC content](#)
- ✓ [Per base N content](#)
- ✓ [Sequence Length Distribution](#)
- ✓ [Sequence Duplication Levels](#)
- ✓ [Overrepresented sequences](#)
- ✓ [Adapter Content](#)
- ✗ [Kmer Content](#)

◆ **FastQC** 可通过输出摘要图表快速进行数据质量的评价

◆ 输出结果包含**12个部分**

- **绿色** ✓ : 质量达标, PASS
- **橙色** ! : 轻微失常, WARN
- **红色** ✗ : 严重失常, FAIL



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✓ Basic Statistics

Measure	Value
Filename	H1EScell-dnase-2014-GSE56869_20151208_SRR1248176_2.fq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	29494668
Sequences flagged as poor quality	0
Sequence length	101
%GC	43

Encoding 指测序平台的版本和相应的编码版本号，这个在计算Phred反推error P的时候有用

Total Sequences 记录了输入文本的reads的数量

Sequence length 是测序的长度


%GC 是我们需要重点关注的一个指标，这个值表示的是整体序列中的GC含量，这个数值一般是物种特异的，比如人类细胞就是42%左右



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✓ Per base sequence quality



图中蓝色的细线是各个位置的平均值的连线

一般要求此图中，所有位置的10%分位数大于20，也就是我们常说的Q20过滤

WARN 如果任何碱基质量低于10,或者是任何中位数低于25

FAIL 如果任何碱基质量低于5,或者是任何中位数低于20




测序数据存储格式与质量控制

评估测序数据质量——FastQC


Good

✓ Per base sequence quality



Poor

✗ Per base sequence quality




明德至诚 博学远志



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✔ Per tile sequence quality



横轴和之前一样，代表101个碱基的每个不同位置;纵轴是tile的Index编号

这个图主要是为了防止，在测序过程中，某些tile受到不可控因素的影响而出现测序质量偏低


蓝色代表测序质量很高，暖色代表测序质量不高，如果某些tile出现暖色，可以在后续分析中把该tile测序的结果全部都去除



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✓ Per sequence quality scores



假如我测的1条序列长度为101bp，那么这101个位置每个位置Q之的平均值就是这条reads的质量值

该图横轴是0-40,表示Q值;纵轴是每个值对应的reads数目

WARN: 峰值小于27

FAIL: 峰值小于20


我们的数据中，测序结果主要集中在高分中，证明测序质量良好！



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✖ Per base sequence content



横轴是1 - 101 bp; 纵轴是百分比

图中四条线代表A T C G在每个位置平均含量。

- **WARN**: 任一位置的A/T比例或者G/C比例相差超过10%
- **FAIL**: 任一位置的A/T比例或者G/C比例相差超过20%


明德至诚 博学远志



测序数据存储格式与质量控制

评估测序数据质量——FastQC

! Per sequence GC content



横轴是0 - 100%；纵轴是每条序列GC含量对应的数量

蓝色的线是程序根据经验分布给出的理论值，红色是真实值，两个应该比较接近才比较好

当红色的线出现双峰，基本肯定是混入了其他物种的DNA序列

- **WARN**: 偏离理论分布的read超过15%
- **FAIL**: 偏离理论分布的read超过30%




测序数据存储格式与质量控制

评估测序数据质量——FastQC



Per base N content




- 当测序仪器不能辨别read的某个位置到底是什么碱基时，就会产生“N”。
- 对所有read的每个位置，统计N的比例
- 正常情况下，N的比例应该很小
- **WARN**：任一位置N的比例超过5%
- **FAIL**：任一位置N的比例超过20%



测序数据存储格式与质量控制

评估测序数据质量——FastQC

Sequence Length Distribution



每次测序仪测出来的长度在理论上应该是完全相等的，但是总会有一些偏差

此图中，101bp是主要的，但是还是有少量的100和102bp的长度，不过数量比较少，不影响后续分析

当测序的长度不同时，如果很严重，则表明测序仪在此次测序过程中产生的数据不可信


- **WARN**: read长度不一致
- **FAIL**: 有长度为0的read



测序数据存储格式与质量控制

评估测序数据质量——FastQC

Sequence Duplication Levels




- 低水平的重复可能表明目标序列的覆盖率非常高，但高水平的重复更有可能表明某种富集偏差（例如 PCR 过度扩增）
- 统计序列完全一样的read的比例
- 测序深度越高，越容易产生一定程度的duplication，这是正常现象；但如果duplication程度很高，就提示可能有bias
- 横轴表示duplication的次数，纵轴表示duplicated read数目与unique read 总数的百分比
- **WARN**: duplicated read的比例超过20%
- **FAIL**: duplicated read的比例超过50%



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✓ Adapter Content




- Read中含有adapter的情况
- **WARN**: 含有adapter的read占总read的比例超过5%
- **FAIL**: 含有adapter的read占总read的比例超过5%
- 横轴: read的位置
- 纵轴: 含有adapter的序列占总序列的比例



测序数据存储格式与质量控制

评估测序数据质量——FastQC

✖ Kmer Content



这个图统计的是，在序列中某些特征的短序列重复出现的次数

1-8bp的时候图例中的几种短序列都出现了非常多的次数，一般来说，出现这种情况，要么是adapter没有去除干净，而又没有使用-a参数；要么就是序列本身可能重复度比较高，如建库PCR的时候出现了bias



测序数据存储格式与质量控制

测序数据质量控制方法

- ◆ 根据质量评估的结果来决定是否需要采取相关的手段，如去接头、过滤低质量 reads、截短序列(主要截断序列起始的接头或者低质量reads)等。
- ◆ 常用的工具有 **FASTX-Toolkit** 和 **Trimmomatic** 等。
- ◆ 如果经过处理之后测序结果评估仍然较差，说明该样本的测序质量较低，应慎重考虑是否用于后续数据分析



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学


2. 基因与基因组的基本概念

明德至诚 博学远志





基因与基因组的基本概念




<https://ib.bioninja.com.au/standard-level/topic-3-genetics/31-genes/genome.html>

明德至诚 博学远志



基因与基因组的基本概念

基因组“天书”



基因组 Genome	书 Book
染色体 Chromosome	章节 Chapter
基因 Gene	句子 Sentence
密码子 Codon	单词 Word
碱基 Base (4个)	字符 Letter (26个)

明德至诚 博学远志




基因与基因组的基本概念


基因

- **基因 (Gene) : 产生一条编码蛋白或RNA产物的核苷酸序列**

A gene is a sequence of nucleotides in DNA or RNA that encodes the synthesis of a gene product, either RNA or protein.




Wilhelm Johannsen
(1857–1927)
丹麦遗传学家
1909年发明gene一词



摩尔根1926年出版
《The Theory of the Gene》

<https://en.wikipedia.org>



潘光旦 (1899–1967)
社会生物学家
首次翻译为“基因”

1930年在“东方杂志”的
《文化的生物学观》一文
生动音译为“基因”，并
经谈家桢 (1909–2008)、
卢惠霖 (1900–1997) 等我
国遗传学先驱的推广延用
至今

<https://xsg.tsinghua.edu.cn/info/1004/1453.htm>

關於遺傳這一點，我們不預備多說。遺傳的幾條原則，甚麼孟德爾的
精實總與精實比較獨立說呀，孟特爾氏的三律呀，跟了韋氏的理論
而發生的新達爾文主義或後天習得性不遺傳說呀，杜勿黎的突變說
明，約翰生與雅爾更的「基因」遺傳說——是大多數生物學家會認
為有效，而且在生物學教本中已經數見不鮮的。人類既然是生物之一，
他當然逃不了這許多原則的支配。比較不適用的也許是杜勿黎氏的
特變一說，因為突變的發生似乎與一個種族的壽命有關，一個種族在
青年精壯氣旺的時候，突變多，過此就少。人類也許已經過了這血氣方
剛時期，不會產生許多突變了。但是對於這一點我們不敢斷定。有人說，
偉大的天才是一種突變，但安知他不是變異性趨極端的一個表示呢？

101



明德至誠 博學遠志



基因与基因组的基本概念

基因组

- **基因组 (Genome) : 生物体所有遗传物质的总和**

- 生物体遗传信息的 “总词典”
- 生物体控制发育的 “总程序”
- 生物演化历史的 “总档案”

Hans Winkler (1877–1945)

德国植物学家

1920年提出Genome:

GENe + chromosOME

核基因组 (nuclear)

线粒体基因组 (mitochondria)

叶绿体基因组 (chloroplast)

A genome is an organism's complete set of DNA(or RNA in RNA viruses), including both the genes (the coding regions) and the noncoding DNA, as well as mitochondrial DNA and chloroplast DNA.




基因与基因组的基本概念

基因组——生命科学的“元素周期表”



1																	2								
H																	He								
3	4																	5	6	7	8	9	10		
Li	Be																	B	C	N	O	F	Ne		
11	12																	13	14	15	16	17	18		
Na	Mg																	Al	Si	P	S	Cl	Ar		
19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36								
K	Ca	Sc	Ti	V	Cr	Mn	Fe	Co	Ni	Cu	Zn	Ga	Ge	As	Se	Br	Kr								
37	38	39	40	41	42	43	44	45	46	47	48	49	50	51	52	53	54								
Rb	Sr	Y	Zr	Nb	Mo	Tc	Ru	Rh	Pd	Ag	Cd	In	Sn	Sb	Te	I	Xe								
55	56	57	72	73	74	75	76	77	78	79	80	81	82	83	84	85	86								
Cs	Ba	La	Hf	Ta	W	Re	Os	Ir	Pt	Au	Hg	Tl	Pb	Bi	Po	At	Rn								
87	88	89	104	105	106	107	108	109	110																
Fr	Ra	Ac	Rf	Db	Sg	Bh	Hs	Mt	Uu																

元素周期表的发现奠定了二十世纪物理、化学研究和发展的基础！

58	59	60	61	62	63	64	65	66	67	68	69	70	71
Ce	Pr	Nd	Pm	Sm	Eu	Gd	Tb	Dy	Ho	Er	Tm	Yb	Lu
90	91	92	93	94	95	96	97	98	99	100	101	102	103
Th	Pa	U	Np	Pu	Am	Cm	Bk	Cf	Es	Fm	Md	No	Lr



人体解剖图奠定了现代医学发展的基础



“基因组”奠定二十一世纪生命科学研究和生物产业发展的基础！

明德至诚 博学远志



基因与基因组的基本概念


基因组学

基因组学 (Genomics)：以生物体全部基因为研究对象，研究基因组结构、功能、演化、组装、编辑等方面的交叉学科。

- 拼接组装生物体全部基因组序列
- 系统解析所有基因功能
- 明确基因之间的相互作用关系
- 揭示基因在生物体生长发育的调控
- 阐明基因组的演化规律

Thomas Roderick
(1930–2013)
美国遗传学家
1986年提出**Genomics**


Genomics is an interdisciplinary field of biology focusing on the structure, function, evolution, mapping, and editing of genomes.





基因与基因组的基本概念

遗传学vs基因组学



Fishing in a More Effective Way! 明德至诚 博学远志



基因与基因组的基本概念

基因组学与遗传学的区别

基因组学 – Genomics Thomas Roderick in 1986	遗传学 – Genetics Gregor Mendel in 1865
全基因组水平	单个基因水平
基因相互作用关系及其环境影响	基因从父代到子代的遗传机制
多基因导致的复杂疾病	单基因遗传及其性状

The main difference between genomics and genetics is that genetics scrutinizes the functioning and composition of the single gene, whereas genomics addresses all genes and their interrelationships in order to identify their combined influence on the growth and development of the organism.

<https://www.genomicseducation.hee.nhs.uk/education/core-concepts/what-is-genomics/>

 Genomics	VS	 Genetics
• The study of an organism's complete set of genetic information. • The genome includes both genes (coding) and non-coding DNA. • 'Genome': the complete genetic information of an organism.		• The study of heredity • The study of the function and composition of single genes. • 'Gene': specific sequence of DNA that codes for a functional molecule.

明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学

3. 基因与基因组结构

明德至诚 博学远志



基因与基因组结构

主要内容

- 基因组结构
 - 基因组大小
 - GC含量
 - 基因数量
 - 染色体
- 基因结构
 - 中心法则
 - 内含子、外显子、转座子 (transposon)
 - 可变剪切 (alternative splicing)
 - CpG岛 (CpG island)



基因与基因组结构

基因组大小

AGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCT
TCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATA
TCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAA
ATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTC
CCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAA
ATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGA
GATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAA
CACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCA
GTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGT
GGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGT
GTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCT
TTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAG
GAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAG
TTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGA
GTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGT
CTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCA
GTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAACATCTGCTATCGAG
TAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTGGAGGCAAATCTT
CGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAGATAAAAACTCTC
CAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTAAGTTTTTCATAAC
ATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTGGGACCCACAGGTG
GAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGGTCAGACGAGAAAG
ATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTGTCACAAGGAAACACCAATGGCTTCCCCGCGACAGCTTCCAATGACCTGAAGGCATTTACTGAAGGAGCTGTGTTA
AGTTTTTCATAACATCTGCTATCGAGTAAAACTGAAGAGTGGCTTTCACCTTGTCGAAAACCAGTTGAGAAAGAAATATTATCGAATATCAATGGGATCATGAAACCTGGTCTCAACGCCATCCTG
GGACCCACAGGTGGAGGCAAATCTTCGTTATTAGATGTCTTAGCTGCAAGGAAAGATCCAAGTGGATTATCTGGAGATGTTCTGATAAATGGAGCACCGCAGTGACGGCGACCAAACCCAGCTAGG
TCAGACGAGAAAGATAAAAACTCTCCAGATGTCTTCCAGTAATGTCGAAGTTTTTATCCCAGTG

基因组：A T G C四种，脱氧核苷酸排列组成 明德至诚 博学远志



基因组大小

**If you spoke
one 'letter' of DNA
per second**

24 hours a day,
it would take about
100 years

A, T, C, G, T, A, A, C, G, T



ATATCAATGGGATCATGAAACCTGGTCTCAACG
AGTGACGGCGACCAAACCCAGCTAGGTCTAGACG
GCATTACTGAAGGAGCTGTGTTAAGTTTTCAT
GCCATCCTGGGACCCACAGGTGGAGGCCAAATCT
GAGAAAGATAAAAACTCTCCAGATGTCTTCCAG
TAACATCTGCTATCGAGTAAACTGAAGAGTGG
TCGTTATTAGATGTCTTAGCTGCAAGGAAAGAT
TAATGTCGAAGTTTTTATCCAGTGTCTACAAGG
CTTCTACCTTGTCGAAAACCAGTTGAGAAAGA
TCCAAGTGGATTATCTGGAGATGTTCTGATAAA
GAAACACCAATGGCTTCCCCGCGACAGCTTCCA
AATATTATCGAATATCAATGGGATCATGAAACC
TGGAGCACCGCAGTGACGGCGACCAAACCCAGC
ATGACCTGAAGGCATTTACTGAAGGAGCTGTGT
CTGGTCTCAACGCCATCCTGGGACCCACAGGTG
CTAGGTCTAGACGAGAAAGATAAAAACTCTCCAG
TTAAGTTTTTCATAACATCTGCTATCGAGTAAAA
GAGGCAAATCTTCGTTATTAGATGTCTTAGCTG
ATGTCTTCCAGTAATGTCGAAGTTTTTATCCCA
CTGAAGAGTGGCTTTCTACCTTGTCGAAAACCA
GCAAGGAAAGATCCAAGTGGATTATCTGGAGAT

基因组：A T G C四种
脱氧核苷酸排列组成

人类基因组是由30亿个碱基 (base pair) 组成

30亿个碱基 = 3,000,000,000 = 3×10^9 = 3Gbp

明德至诚 博学远志



基因与基因组结构

基因组大小

中文	英文	缩写	数量
尧	yotta	Y	10^{24}
泽	zetta	Z	10^{21}
艾	exa	E	10^{18}
拍	peta	P	10^{15}
太	tera	T	10^{12}
吉	giga	G	10^9
兆	mega	M	10^6
千	kilo	K	10^3
			$10^0 = 1$
毫	milli	m	10^{-3}
微	micro	μ	10^{-6}
纳	nano	n	10^{-9}
皮	pico	p	10^{-12}

- 计算机计量：字节 Bytes (B)
- 生物计量：碱基对 base pair (bp)
- 人类基因组：3 Gbp (3吉)
- 水稻基因组：300 Mbp (300兆)



基因与基因组结构

基因组大小



大肠杆菌 (Escherichia coli)




6本新华字典

明德至诚 博学远志



基因与基因组结构

基因组大小



H7N9流感病毒

12页, 12K



小猫

3300本, 2.3G



西红柿

1100本, 823M



人类

4500本, 3.2G



糖松

38000本, 27.6G



墨西哥蝾螈

39000本, 28.2G

明德至诚 博学远志



基因组大小

物种拉丁名	物种常用名	物种类别	数据来源	Accession编号	基因组大小(Mb)	染色体数量
☐ Viscum album	European mistletoe	Plants	NCBI	GCA_963277665.1	94261.0411	49
☐ Viscum album	European mistletoe	Plants	NCBI	GCA_963082535.1	91113.7496	0
☐ Lepidosiren paradoxa	South American lungfish	Animals	NCBI	GCA_040581445.1	87218.8472	49
☐ Lepidosiren paradoxa	South American lungfish	Animals	NCBI	GCA_040438655.1	46159.9451	0
☐ Protopterus annectens	West African lungfish, Lepidosiren annec...	Animals	NCBI	GCA_040939525.1	40524.1737	27
☐ Protopterus annectens	West African lungfish, Lepidosiren annec...	Animals	NCBI	GCA_019279795.1	40054.3246	27
☐ Protopterus annectens	West African lungfish, Lepidosiren annec...	Animals	Direct submission	GWHANVS000000000	40054.3247	17
☐ Euphausia superba	Antarctic krill	Animals	NCBI	GCA_051903835.1	38150.9887	0
☐ Lilium regale	-	Plants	Direct submission	GWHEUVG000000000.1	35569.1944	41
☐ Neoceratodus forsteri	Australian lungfish, Ceratodus forsteri	Animals	NCBI	GCA_016271365.1	34557.6481	14



基因与基因组结构

肺鱼

- “活化石”：演化地位
- 平时用鳃呼吸，在干涸时用鳃当作肺呼吸
- 非洲和美洲肺鱼：双肺；澳洲肺鱼：单肺
- 夏眠，非洲肺鱼可离开水面不吃不喝休眠3~5年

Article | Open Access | Published: 18 January 2021

Giant lungfish genome elucidates the conquest of land by vertebrates

Axel Meyer , Siegfried Schloissnig, Paolo Franchini, Kang Du, Joost M. Woltering, Iker Irisarri, Wong, Sergej Nowoshilow, Susanne Kneitz, Akane Kawaguchi, Andrej Fabrizius, Peiwen Xiao, Dechaud, Herman P. Späink, Jean-Nicolas Volff, Oleg Simakov , Thorsten Burmester , E. & Manfred Scharlt 

Nature 590, 284–289(2021) | Cite this article

NCBI: https://www.ncbi.nlm.nih.gov/assembly/GCA_016271365.1/

澳洲肺鱼
34.55 Gb, 14条染色体
67.3% (24.65 Gb) repeats

RESOURCE | VOLUME 184, ISSUE 5, P1362–1376.E18, MARCH 04, 2021
PDF [11 MB] Figures
African lungfish genome sheds light on the vertebrate water-to-land transition

Kun Wang  • Jun Wang  • Chenglong Zhu  • ... Qiang Qiu  • Shunping He 
Wen Wang    • Show all authors • Show footnotes


Published: February 04, 2021 • DOI: <https://doi.org/10.1016/j.cell.2021.01.047> • 

非洲肺鱼
40.05 Gb, 17条染色体
61.7% (24.7 Gb) repeats

CNCB-NGDC : <https://ngdc.cncb.ac.cn/gwh/Assembly/9785/show>



From 百度百科



<https://www.nature.com/articles/s41586-021-03198-8>


<https://doi.org/10.1016/j.cell.2021.01.047>

明德至诚 博学远志



基因与基因组结构

人类基因组结构




Chr.	Mb
All	3.289
1	279
2	251
3	221
4	197
5	198
6	176
7	163
8	148
9	140
10	143
11	148
12	142
13	118
14	107
15	100
16	104
17	88
18	86
19	72
20	66
21	45
22	48
X	163
Y	51



基因与基因组结构

人类基因组中基因的数目




Between a chicken and a grape: estimating the number of human genes. Mihaela Pertea & Steven L Salzberg, *Genome Biology*. volume 11: 206 (2010)



基因与基因组结构

基因组结构：基因数目



Between a chicken and a grape: estimating the number of human genes. Mihaela Pertea & Steven L Salzberg, *Genome Biology*. volume 11: 206 (2010)

明德至诚 博学远志



基因与基因组结构

基因组结构：基因数目

bacteria			
<i>C. ruddii</i> (smallest genome of an endosymbiont bacteria)	160 kbp	182	1
<i>M. genitalium</i> (smallest genome of a free living bacteria)	580 kbp	470	1
<i>H. pylori</i>	1.7 Mbp	1,600	1
<i>Cyanobacteria S. elongatus</i>	2.7 Mbp	3,000	1
methicillin-resistant <i>S. aureus</i> (MRSA)	2.9 Mbp	2,700	1
<i>B. subtilis</i>	4.3 Mbp	4,100	1
<i>S. cellulosum</i> (largest known bacterial genome)	13 Mbp	9,400	1
archaea			
<i>Nanoarchaeum equitans</i> (smallest parasitic archaeal genome)	490 kbp	550	1
<i>Thermoplasma acidophilum</i> (flourishes in pH<1)	1.6 Mbp	1,500	1
<i>Methanocaldococcus (Methanococcus) jannaschii</i> (from ocean bottom hydrothermal vents; pressure >200 atm)	1.7 Mbp	1,700	1
<i>Pyrococcus furiosus</i> (optimal temp 100°C)	1.9 Mbp	2,000	1
eukaryotes - multicellular			
pufferfish <i>Fugu rubripes</i> (smallest known vertebrate genome)	400 Mbp	19,000	22
poplar <i>P. trichocarpa</i> (first tree genome sequenced)	500 Mbp	46,000	19
corn <i>Z. mays</i>	2.3 Gbp	33,000	20 (2n)
dog <i>C. familiaris</i>	2.4 Gbp	19,000	40
chimpanzee <i>P. troglodytes</i>	3.3 Gbp	19,000	48 (2n)
wheat <i>T. aestivum</i> (hexaploid)	16.8 Gbp	95,000	42 (2n=6x)
marbled lungfish <i>P. aethiopicus</i> (largest known animal genome)	130 Gbp	unknown	34 (2n)
herb plant <i>Paris japonica</i> (largest known genome)	150 Gbp	unknown	40 (2n)



基因与基因组结构

基因组结构：基因数目

organism	genome size (base pairs)	protein coding genes	number of chromosomes
model organisms			
model bacteria <i>E. coli</i>	4.6 Mbp	4,300	1
budding yeast <i>S. cerevisiae</i>	12 Mbp	6,600	16
fission yeast <i>S. pombe</i>	13 Mbp	4,800	3
amoeba <i>D. discoideum</i>	34 Mbp	13,000	6
nematode <i>C. elegans</i>	100 Mbp	20,000	12 (2n)
fruit fly <i>D. melanogaster</i>	140 Mbp	14,000	8 (2n)
model plant <i>A. thaliana</i>	140 Mbp	27,000	10 (2n)
moss <i>P. patens</i>	510 Mbp	28,000	27
mouse <i>M. musculus</i>	2.8 Gbp	20,000	40 (2n)
human <i>H. sapiens</i>	3.2 Gbp	21,000	46 (2n)
viruses			
hepatitis D virus (smallest known animal RNA virus)	1.7 Kb	1	ssRNA
<i>HIV-1</i>	9.7 kbp	9	2 ssRNA (2n)
<i>influenza A</i>	14 kbp	11	8 ssRNA
bacteriophage λ	49 kbp	66	1 dsDNA
<i>Pandoravirus salinus</i> (largest known viral genome)	2.8 Mbp	2500	1 dsDNA



基因与基因组结构

病毒基因组

- 病毒基因组是由核酸构成，核酸是病毒遗传和感染的物质基础。
- 迄今所发现的各种病毒仅含有一种核酸，要么是DNA，要么是RNA。
- 地球上病毒数量极多，文献报道总量达 10^{31} ，已知的仅有5000 余种。
- 研究病毒基因组的核酸组成和基因组结构，可揭示病毒基因组转录、复制和表达的调控机制，阐明病毒感染和致病的分子基础。

Here a virus, there a virus, everywhere the same virus? Trends in Microbiology 2005

<https://doi.org/10.1016/j.tim.2005.04.003>



病毒基因组分类

巴尔的摩病毒分类系统：一种由美国病毒学家David Baltimore建立的以**基因组**和**病毒转录mRNA方式**为区分的病毒分类系统。

转录方式	中文	英文	代表性病毒
DNA	双链DNA病毒	dsDNA	疱疹病毒、天花病毒
	单链DNA病毒	ssDNA	细小病毒
RNA	双链RNA病毒	dsRNA	呼肠孤病毒
	正义单链RNA病毒	(+)ssRNA	冠状病毒 (SARS、MERS、SARS-CoV-2)
	反义单链RNA病毒	(-)ssRNA	狂犬病毒、流感病毒、埃博拉病毒
逆转录	单链RNA逆转录病毒	ssRNA-RT	HIV
	双链DNA逆转录病毒	dsDNA-RT	乙肝病毒



基因与基因组结构

病毒基因组大小

Giant viruses open Pandora's box

Genome of largest viruses yet discovered hints at 'fourth domain' of life.


Ed Yong

18 July 2013

 Rights & Permissions

The organism was initially called NLF, for “new life form”. Jean-Michel Claverie and Chantal Abergel, evolutionary biologists at Aix-Marseille University in France, found it in a water sample collected off the coast of Chile, where it seemed to be infecting and killing amoebae. Under a microscope, it appeared as a large, dark spot, about the size of a small bacterial cell.

Later, after the researchers discovered a similar organism in a pond in Australia, they realized that both are viruses — the largest yet found. Each is around 1 micrometre long and 0.5 micrometres across, and their respective genomes top out at 1.9 million and 2.5 million bases — making the viruses larger than many bacteria and even some eukaryotic cells.



Chantal Abergel/Jean-Michel Claverie

Pandoraviruses infect amoebae and are larger than some bacteria.

- 基因组大小反映了基因组结构的差异，Pandoravirus salinus, 2473870 bp, 1647个基因。

<https://www.ncbi.nlm.nih.gov/genome/22431>

- Rice yellow mottle virus satellite, 220 bp, 1个基因。

<https://www.ncbi.nlm.nih.gov/genome/4366>


<https://doi.org/10.1038/nature.2013.13410>

明德至诚 博学远志




基因与基因组结构

病毒基因组结构及其宿主分布



The Baltimore Classification of Viruses 50 Years Later: How Does It Stand in the Light of Virus Evolution?
Microbiology and Molecular Biology Reviews 2021
<https://doi.org/10.1128/MMBR.00053-21>





基因与基因组结构

病毒基因组结构



大家好！今天咱们来聊聊病毒的基因组

明德至诚 博学远志



基因与基因组结构



原核生物基因组结构

- 原核生物(Prokaryote) = 细菌(Bacteria) + 古细菌(Archaea)
- 基因组大小和基因数目远少于真核生物
- 基因组结构
 - 基因组紧凑
 - 基因连续编码，不含内含子 (Intron)
 - 极少出现重复序列
 - 重复基因数量也远小于真核生物
- 遗传物质
 - 染色体：大多数为环状DNA，位于细菌核质区，包含细菌生存的必需基因，只有一个复制起始点，大多数只含有单条染色体
 - 质粒：也是双链环状DNA，能在同种或异种细菌中转移，是附加遗传物质



基因与基因组结构

质粒





Escherichia coli

- 质粒 (Plasmid) 一般是小分子DNA，通常为环状，与细菌染色体共存于细胞内
- 有些质粒可整合于主基因组，有的独立存在
- 通常情况下，质粒携带非必需基因，可以跨种属从一个细胞转移到另一个细胞
- 细菌中存在超大型质粒



基因与基因组结构

细菌基因组大小：free-living vs. parasitic



https://www.macmillanhighered.com/BrainHoney/Resource/6716/digital_first_content/trunk/test/hillis2e/hillis2e_ch19_5.html

The Nature and Dynamics of Bacterial Genomes. Science
2006 <https://doi.org/10.1126/science.1119966>

明德至诚 博学远志



基因与基因组结构

真核生物基因组结构

- **真核生物：动物、植物、真菌、原生生物**
 - 有数量不等的染色体
 - 几乎所有的真核生物都有线粒体
 - 植物细胞中有叶绿体
 - 线粒体基因组和叶绿体基因组都呈环状
 - 基因组中有大量重复序列
- **线粒体和叶绿体都是半自主性细胞器**
 - 含有各自基因组能够独立复制
 - 可以均等分裂，产生完全相同子代
 - 有相对独立的复制体系和翻译系统
 - 复制和翻译体系不完全独立，受核基因组控制



基因与基因组结构

真核生物基因组结构

- 人类基因组：核基因组+线粒体基因组
 - 核基因组DNA呈线性，总长为~3Gbp，由46条染色体构成，22对为常染色体(autosome)，一对性染色体(X、Y)
 - 线粒体基因组为环状DNA分子，长度为16569bp，编码37个基因，每个细胞有约800个线粒体，每个线粒体含2~10个拷贝
- 植物线粒体基因组
 - 高等植物线粒体中含有多个线性和环状DNA
 - 不同种属之间线粒体基因组变化很大，在120-2500kb之间
 - 含有大量短序列的正向、反向重复序列
- 叶绿体基因组
 - 叶绿体基因组较紧凑，基因间很少非编码序列
 - 种属间基因组恒定，约120kb，很少发生重组



基因与基因组结构

基因组大小计量方式

中文	英文	缩写	数量
太	tera	T	10^{12}
吉	giga	G	10^9
兆	mega	M	10^6
千	kilo	K	10^3
			$10^0 = 1$
毫	milli	m	10^{-3}
微	micro	μ	10^{-6}
纳	nano	n	10^{-9}
皮	pico	p	10^{-12}

Genome size is the total amount of DNA contained within one copy of a single complete genome. It is typically measured in terms of mass in picograms (pg), or as the total number of nucleotide base pairs (bp).

$$1 \text{ pg} = 978 \text{ Mb}$$

人类基因组


- 碱基数量: ~3 Gb
- 碱基质量: ~3 pg

明德至诚 博学远志



基因与基因组结构

动物基因组



南极磷虾 (*Euphausia superba*)
体重不超过2克，基因组~48G





大理石肺鱼 (*Protopterus aethiopicus*)
基因组~130 Gb

明德至诚 博学远志



基因与基因组结构

南极磷虾 Antarctic krill (*Euphausia superba*)



72.15% of the genome was identified as repetitive sequence using standard repeat-masking procedures and reached up to 92.45% after additional repeat annotation

The enormous repetitive Antarctic krill genome reveals environmental adaptations and population insights. *Cell* 2023

<https://doi.org/10.1016/j.cell.2023.02.005>

明德至诚 博学远志



基因与基因组结构

植物基因组

拟南芥



100Mb

水稻



400Mb

二倍体短柄草



300Mb

高粱



700Mb

大豆



1,150Mb

玉米



2,700Mb

大麦



5,000Mb

小麦



16,000Mb

杉树、杨树等




18,200 – 33,500Mb

明德至诚 博学远志



基因与基因组结构

人类基因组结构：非编码序列98%




NONPROTEIN-CODING SEQUENCES make up only a small fraction of the DNA of prokaryotes. Among eukaryotes, as their complexity increases, generally so, too, does the proportion of their DNA that does not code for protein. The noncoding sequences have been considered junk, but perhaps it actually helps to explain organisms' complexity.

基因表达产物多层次多维度的加工修饰及非编码序列的复杂调控在生物表型形成中发挥重要作用。



基因与基因组结构

基因组结构：染色体






基因与基因组结构

基因组结构：基因数目


- 真核生物核基因组均由一定数目的染色体组成
- 单倍体细胞所含有的全套染色体称为染色体组
- 真核生物染色体数与生物复杂性及其在进化中的地位没有必然联系
- 瓶尔小草属 (*Ophioglossum*) 是已知生物中染色体最多的，有高达1,260条染色体





基因与基因组结构

基因组染色体



Each human chromosome has a **short arm** ("p" for "**p**etit") and **long arm** ("q" for "**q**ueue"), separated by a **centromere**.

Repeats are added by a specific **telomere**.

5' – (TxGy)n


3' – (AxCy)n

x, y = 1~4, n=repeat times



基因与基因组结构

染色体结构：DNA packaging






基因与基因组结构

染色体带型命名方法


- 深色区与浅色区相间分布
- 以着丝粒为中心向两侧延伸
- 长短臂：短臂p，长臂q
- 区-亚区
- 带-亚带-次亚带





基因与基因组结构

人类基因组染色体异常



Down syndrome (DS or DNS, discovered by Dr. John Langdon Down in 1866), also known as trisomy 21:
a genetic disorder caused by the presence of all or part of a third copy of chromosome 21.



基因与基因组结构

染色体结构异常：21三体综合症

- 21三体综合症，又称先天愚型或唐氏综合症
- 新生儿发病率：1:600 ~ 1000
- 临床特征：
 - 智能落后
 - 生长发育迟缓
 - 伴有多发畸形
- 主要诱因
 - 高龄产妇
 - 遗传
 - 致畸物质





基因与基因组结构

真核原核基因组比较

补点芝士 bilibili

大家好

明德至诚 博学远志



什么是基因

- One gene – one enzyme (Beadle & Tatum 1940): “Every gene encodes the information for one enzyme”
- One gene – one protein: “One gene contains information for one protein (structural proteins included) one gene – one polypeptide
- Current definition: A piece of DNA (or in some cases RNA) that contains the primary sequence to produce a functional biological gene product (RNA, protein).

储存有功能的蛋白质多肽链或RNA序列信息，以及表达这些信息所必需的全部核苷酸序列所构成的遗传单位。



基因与基因组结构

什么是基因



明德至诚 博学远志



基因与基因组结构

基因的结构


内含子Intron

- Non-coding DNA
- Present between two exons
- Removed by RNA splicing

外显子Exon

- Coding DNA
- Encode a part of the final mature RNA
- Translate into amino acids and proteins

The production of a functional protein involves the **transcription** of the gene from DNA into RNA, the **removal of introns and splicing together of exons**, the **translation** of the spliced RNA sequences into a chain of amino acids, and the **posttranslational modification** of the protein molecule.



© 2013 Encyclopædia Britannica, Inc.

明德至诚 博学远志



基因与基因组结构

内含子vs外显子

Item	Intron	Exon
What are they?	Nucleotide sequence that is present between the two exons	Nucleotide sequence that is responsible for the synthesis of proteins
Coding / non-coding DNA	Non-coding	Coding
Species	Commonly found in eukaryotes	Found in both prokaryotes and eukaryotes
Sequence Conservation	Less conserved	Relatively conserved
Presence in the Genome	DNA and pre-mRNA	DNA and mature mRNA

Across all eukaryotic genes in GenBank, there were (in 2002), on average, **5.48 exons per gene**. The average exon encoded 30-36 amino acids. The **longest** exon in the human genome is **11555 bp long**.


<https://vivadifferences.com/introns-vs-exons/>

明德至诚 博学远志



基因与基因组结构


不同物种的基因结构





基因与基因组结构

人类基因组结构






基因与基因组结构


重复序列

串联重复

Minisatellite: Variable Number Tandem Repeats (VNTR)




Microsatellite: Short Tandem Repeats (STR) – Simple Sequence Repeats (SSR)





基因与基因组结构

假基因



A portion of an mRNA transcript is reverse transcribed back into DNA and inserted into the chromosomal DNA.

17463 pseudogenes in human

https://www.ncbi.nlm.nih.gov/datahub/gene/taxon/9606/?gene_x0002_type=Pseudogenes


<https://ib.bioninja.com.au/standard-level/topic-3-genetics/31-genes/pseudogenes.html>

明德至诚 博学远志



基因与基因组结构

假基因



基因小知识 bilibili

这样它假基因被定义为功能基因的拷贝NA片段

明德至诚 博学远志




基因与基因组结构

转座子Transposon

DNA转座子

- 通过“剪切-粘贴”机制移动。转座子编码转座酶，直接将DNA序列从原位置切下并插入到新位置
- 通常具有末端反向重复序列 (Terminal Inverted Repeats, TIRs)



逆转录转座子

- 通过“复制-粘贴”机制移动。转座子被转录为RNA，然后通过逆转录酶将RNA逆转录为DNA，再插入到基因组的新位置
- LTR 逆转录转座子：具有长末端重复序列 (Long Terminal Repeats)
- 非LTR 逆转录转座子：如 LINEs (长散布核元件) 和 SINEs (短散布核元件)



基因与基因组结构


为什么蛋白质的种类大于基因数

Type	Name	RefSeq	INSDC	Size (Mb)	GC%	Protein	rRNA	tRNA	Other RNA	Gene	Pseudogene
Chr	1	NC_000001.11	CM000663.2	248.96	42.3	11,086	17	90	4,468	5,100	1,408
Chr	2	NC_000002.12	CM000664.2	242.19	40.3	8,442	-	7	3,797	3,879	1,201
Chr	3	NC_000003.12	CM000665.2	198.3	39.7	7,198	-	4	2,800	2,990	909
Chr	4	NC_000004.12	CM000666.2	190.22	38.3	4,622	-	1	2,229	2,439	805
Chr	5	NC_000005.10	CM000667.2	181.54	39.5	4,796	-	17	2,234	2,594	789
Chr	6	NC_000006.12	CM000668.2	170.81	39.6	5,618	-	138	2,528	3,019	892
Chr	7	NC_000007.14	CM000669.2	159.35	40.7	5,212	-	22	2,401	2,773	914
Chr	8	NC_000008.11	CM000670.2	145.14	40.2	4,090	-	4	2,000	2,175	680
Chr	9	NC_000009.12	CM000671.2	138.4	42.3	4,652	-	3	2,242	2,271	723
Chr	10	NC_000010.11	CM000672.2	133.8	41.6	5,420	-	3	2,160	2,180	643
Chr	11	NC_000011.10	CM000673.2	135.09	41.6	6,710	-	13	2,400	2,924	833
Chr	12	NC_000012.12	CM000674.2	133.28	40.8	5,957	-	9	2,501	2,537	698
Chr	13	NC_000013.11	CM000675.2	114.36	40.2	2,019	-	4	1,239	1,379	475
Chr	14	NC_000014.9	CM000676.2	107.04	42.2	3,493	-	18	1,716	2,063	586
Chr	15	NC_000015.10	CM000677.2	101.99	43.4	3,548	-	9	1,785	1,827	564



基因与基因组结构

基因结构复杂多样性：可变剪接



Alternative splicing is a regulated process during gene expression that results in a single gene coding for multiple proteins.

明德至诚 博学远志



基因与基因组结构

可变剪接

- **"One gene – many polypeptides"**: a *D. melanogaster* gene called Dscam, which could potentially have 38,016 splice variants.
- **Higher efficiency**: information can be stored much more economically.
- **Evolutionary flexibility**: vertebrates have higher rates of alternative splicing than invertebrates
- **Functional diversity**: reflected by a rich diversity of expression patterns by coding and non-coding splice variants
- **Phenotypic complexity**: preceded multicellularity in evolution, aiding in the development of multicellular organisms.
- **Human diseases**: caused by RNA mis-splicing

Alternative splicing of *Drosophila* Dscam generates axon guidance receptors that exhibit isoform-specific homophilic binding. *Cell* 2004

明德至诚 博学远志



基因与基因组结构

CpG岛



- CpG: C—phosphate(磷酸盐)—G
- CpG island: a region with high frequency of CpG sites
- 基因组中富含双碱基CpG的序列，主要存在于脊椎动物中
- CpG岛主要位于基因的启动子和外显子区域
- 人类基因组CpG岛约为28890个，大部分染色体每1Mb就有5-15个CpG岛，平均值为每Mb含10.5个CpG岛，CpG岛的数目与基因密度有良好的对应关系
- 正常细胞的CpG岛由于被保护而处于非甲基化状态
- 在癌症中基因表达往往受到抑制，主要通过甲基化启动子区的CpG岛





CpG岛

CCCGGGTCCGGGCGGGGAAGAGCCGCTCAACGCGCAGGGGCCATCCGCGAGAGGCCAGCGCCCCCGGCGGTCCAGCCCAGGCCCGCGCGCTCCGCGCCTGGGCTGCTCCCTCCGGGGCCCTG
CACCGCCCTCCTGCTACTTGGACCGCTTCCTCA CGCCCTTCTCCACCCCGCGCGCCAGCCTCCCGCGCGCAGCGTGGGGATCTCGGCCAATAAAGGAGAAAGGGCGCGGCCCCGTACGCGCG
CCAGGTCCGTGGGCGAGACCAGCTCA CGCCCCCTCCTCCAGCCGCCAAGGCCCGGCCACAGCTGCCTGGCTGCAGTCAGAAGCGTAGCCCGAGACAAGGAAGGGCGCCTTGACTCGCACT
TTTGTCCGGTTTCAAAGCTTCTGCTCAGTGGTGGTGAATGCGAGCGCGTCTTAAATCGATGGCGCCTAGGAGTCCATGAAATACCGGTACAGGCTTCCGCGCGACGGATGCCCCCGCCCCCTC
ACCCACGCTCCGCGCCTCCGGGGATGCCCCACCCCTCGTGGCGGTCCCGCGCGTCCCGCGCAGGCGCGCTCGGGCTGCCGCTGGCTCTTCGACCGCGGCCATGGCCGACTCCGAGCTGCAG
CTGGTTGAGCAGCGGATCCGCGAGCTTCCCGCACTTCCCCACCCAGGCGTGGTATTAGGTGCA CGCACAGGC CGCCTCGTGGCGCCCGACCTCGGGCCTACGGATGGGAGCGCGTGG
CCCGCGACCTCCGGGCGGGCGGGGCGGGAACCCCTCGTCTTTCCGCCCCCGGGGCCCTGCCCTCCTTCGGCCCCCGCGTCACCAGGCCTGTCCTTGGGTCCAGGGACATCTCGCCCGTCCTGA
AGGACCCCGCCTCCTTCGCGCGCGCCATCGGCCTCCTGGCGCGACACCTGAAGGCGACCCA CGGGGGCGCATCGACTACATCGCAGGCGAGTGCCAGTGGCGCGATCTAGGGCGCTTCC
GCCTCTCGCGCGCGCGAGGGCAGCA CGTGGGCTCTCGCGCTCTGCTTGGGGGAGGGCCCTTTGGGGTGCTTCAGGGGGCGCGCGGACCGCGCGCTGCTTGGGTCCGCGCGGAAGGGTTGTG
AGATTGAGCCCCCGAGGCGCGCGCGCTGTGCAGGCGTCTTCCCGCAGGTTCCGGGTCCCAGCCCAGGACAGGCGTGACCGAGTTGCGGGGTGAGTTGGTCTCCCTGGAGTGCCCAAGCT
GAATCCACAGGGCCCAGCTGCCTTGCTTCTTGTCTTCTGCGAGCTGGTATTGAGCGCCTGCCACGAGCCAGGCCTTCCCTGGTGAAGATCA CGGAATGCCACCCAGGGAAGGGAGGCC
TGGAGGCCCTCCGGGAGAGCCCAAGAGGTGGCCAGGGAGAACAGAGTGTTCTGGGCGCTCTGCTTCCCTAGGGGTGTGACAGCCCACTCCCTGGACACTGCCCTGAGGAAAGCGCCAGCT
CTTGCTGGAGCCACAACACTGCCAGAGCTCCCTTCTCACCTCCTGCAGGAAGCCCTCCCTGACCTCTGTCAGGC CGGGGCAGGGTTTCCCTGAGCGTCCCCCAACCATCACAGCTCAGGC
CACCTCGAGAGACTCCCTTTTTAGACAGAAGCCCTGGTGCAGAGCTGCCTTTGAGAGTAAGCTGAGGCCTGTCAGGTTTCTACCAGCCCAGTTACAGATGGGCTGCTCAGCTCAGAGAGAG
GGGTGGTGACTCCCTTAGGAACACACAGCTAAGAAGTGGTCCCTTAAAAGACAGACCCAGGTCTGCACTCTGACCTGGAAGCAGCTCCGCGGTAGGTGATGGGTAAACATTCCTTAAATGGTG
CATGTCACTGGCCTTTTCAGCTGGGAGCCAACCAGGTACCCCTTGCCACCGGCCAACCTGGCCCCCTGGGGATTCCCATGCTGCCGAGTCACTCCTGTCACTTACCCTGACAGGCCTAGACT
CCCGAGGCTTCTCTTTGGCCCCCTCCCTGGCCCAGGAGCTTGACTGGGCTGCGTGTCTCATCCGAAAGCGGGGAAGCTGCCAGGCCCACTCTGTGGGCCTCCTATTCCCTGGAGTACGG
GAAGGTAAGAGGGCTGGGGTGGCCAGAGGAAGGGCAGGGCCAGGCCACCGTGGCCACTCTCCCCAGTTCTAAAAGGCCTTCCAGGCGTGTCAAGTGGAGCTGCTGTGGTTACAGTGGCC
TTGGGAGCTCAGAGAGGTTGAGACATAGGCTGGGCTCACACAGCCAGGTAACAGCAAGGTGGGGTTGGAGTCAGGGTCTAGGGTGGCAGCTGCCAAGCTGTGCAACAAAGCTGTTTTCTGCG
GGGAGGCTGAGGACCACACACCCTTCCACTCCAGGCTGAGCTGGAGATTAGAAAGA CGCCTGGAGCCAGGACAGAGGGTGGTCCGTCCGTGGATGATCTGCTGGCCACTGGTGGTAAGG
GTCTCCC CGCAGCCAACCTGCTGTGGCTCCAAGGGCCTGGTGGGAGTGGGACAGGACCTCGCTGTGTGACATGGGATGCAGCTTACTGTTGTCCAGAGGGTGCCTGGTGGCCAGGC CGACAC
CTTCCTCTCCCATGCCTTCCCCTCCCCAACCCAGGGGCTGGCCTGGAGCACCTGCTCTCTGCAGCCAGGCCAACTGGGGACCTACCCCTCCCATCCCCAGGAACCATGAACCGCTGCCTG
TGAGCTGCTGGGC CGCCTGCAGGCTGAGGTCTGGAGTGCGTGAGCCTGGTGGAGCTGACCTCGCTTAAGGGCAGGGAGAAGCTGGCACCTGTACCCCTTCTCTCTCCTGCAGTATGAG
TGACCACAGGGCCTCCAGCCCAACATCTCCAGCTGGATCCAGGGGAAATATCAGCCTTGGGCAACTGCAGTGACCAGGGGCACCGGCTGCCACAGGGAACACATTCCTTTGCTGGGGTT
CAGCGCCTCTCCTGGGGCTGGAAGTGCCAAAGCCTGGGGCAAAGCTGTGTTTACGCCACACTGAACCAATTACACACAGCGGGAGAACCGAGTAAACAGCTC



基因与基因组结构

CpG区域易发生甲基化



Distinct DNA methylation profiles in normal and cancer genomes

明德至诚 博学远志



CpG岛


2017-09-20 14:00 bilibili

CpG site



基因与基因组结构

基因中各种序列功能



大家都知道



测序数据存储格式与质量控制

FASTA、FASTQ

FastQC

基因与基因组的基本概念

基因 (Gene)： 产生一条编码蛋白或RNA产物的核苷酸序列

基因组 (Genome)： 生物体所有遗传物质的总和

基因与基因组结构

致谢：本节PPT参考了国家生物信息中心章张研究员课件

明德至诚 博学远志



基因与基因组结构
