



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING


生物信息学

熊壮 博士

医工交叉研究院

Interdisciplinary Institute for Medical Engineering

bioinformatics_fzu@163.com



明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

第四章 多组学分析-基因组学

明德至诚 博学远志



主要内容

1. 测序数据存储格式与质量控制
2. 基因与基因组的基本概念
3. 基因与基因组结构
- 4. 基因组测序 DNA-seq**
- 5. 基因组变异**
- 6. 基因组注释**



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学

4. 基因组测序DNA-seq

明德至诚 博学远志



基因组测序概述

◆ 全外显子组测序 (Whole exome sequencing, WES)

- WES is a genomic technique for sequencing all of the protein-coding regions of genes in a genome (Wikipedia)
- 利用序列捕获技术将【全基因组的外显子区域DNA】捕获富集后进行高通量测序，能够直接发现与蛋白质功能变异相关的遗传变异SNP
- 相比全基因组测序，外显子组测序只需针对外显子区域的DNA即可，覆盖度更深、数据准确性更高，更加简便、经济、高效
- 可用于寻找复杂疾病如癌症、糖尿病、肥胖症的致病基因和易感基因等的研究



基因组测序概述

◆ 全基因组测序 (Whole genome sequencing, WGS)

- WGS is the process of determining the entirety, or nearly the entirety, of the DNA sequence of an organism's genome at a single time (Wikipedia)
- 对基因组整体进行高通量测序，分析不同个体间的差异，同时完成SNP及基因组结构注释
- 覆盖全基因组，包含外显子测序不能得到的更多信息，在鉴定SNP、插入和缺失突变 (Indel) 时更有优势

◆ 全基因组重测序 (Whole genome re-sequencing, WGRS)

- ◆ 对已知参考基因组和注释的物种进行不同个体间的WGS，并在此基础上对个体或群体进行差异性分析，鉴定出与某类表型相关的SNP
- ◆ 覆盖全基因组，是WGS在不同样本上的重复



基因组测序 DNA-seq

Read 比对 (mapping)

- ◆ reads比对指的是**将reads匹配到参考基因组上**
- ◆ 当reads经过处理**满足一定的质量标准**后，需要将其比对到参考基因组上
- ◆ 截止到目前，研究人员已经开发出了多种比对程序及软件对数以百万记的短读段进行有效的比对
- ◆ 常用工具：**Bowtie, Bowtie2, BWA, MAQ**





Read 比对算法BWT

- BWT (Burrows-Wheeler Transform) 是一种用于数据压缩和字符串匹配的算法。
- 由 Michael Burrows 和 David Wheeler 于 1994 年提出。
- BWT 的核心思想是通过对字符串进行重排，使其更易于压缩，同时保留原始字符串的所有信息。
- BWT 在生物信息学中被广泛应用于短读段比对（如将测序 reads 比对到参考基因组），尤其是在 Bowtie、BWA 等比对工具中。



Read 比对算法BWT

- BWT算法可以分为编码和解码两部分：编码后，原始字符串中的相似字符会处在比较相邻的位置；解码就是将编码后的字符串重新恢复成原始字符串的过程
- BWT的一个特点就是经过编码后的字符串可以完全恢复成原始字符串

BWT编码分为以下几步：

- 输入一个字符串 s ，假设其中所有字符都介于a-z之间。
- 在 s 的末尾加上一个标记字符，该字符要比 s 中的所有字符都要小。比如\$字符。这样将末尾加上标记的新字符串记为 s' 。
- 重复地将 s' 中的最后一个字符转移到开头，每转移一次就得到一个新的字符串。
- 将上一步得到的所有新字符串从小到大排序，排序后的字符串数组记为 M 。
- M 中每个字符串的第一个字符构成 F 列， M 中每个字符串的最后一个字符构成 L 列。
- 输出 L 列。



基因组测序 DNA-seq

Read 比对算法BWT

输入	加标记	循环转移	M数组	F列	L列	输出
ababc	→ ababc\$	\$ababc	\$ababc	\$	c	c
		c\$abab	ababc\$	a	\$	\$
		bc\$aba	abc\$a	a	b	b
		abc\$ab	babc\$a	b	a	a
		babc\$a	bc\$ab	b	a	a
		ababc\$	c\$abab	c	b	b



Read 比对算法BWT

BWT解码分为以下几步：

- 输入 L 列。
- 对 L 列进行从小到大排序得到 F 列。
- L 列的第一个字符是原始字符串的最后一个字符。
- 根据 L 列的字符 L_i 找到 F 列中的相同字符 F_j ，然后得到 F_j 所在行的最后一个字符 L_j 。将 L_j 记录下来。
- 重复上面一步，直到 F_j 等于标记字符为止。
- 按照上述步骤找到的各个 L_j 进行反向排列，得到字符串 r 。
- 输出字符串 r 。



Read 比对算法BWT

- Step1: 输入L列; 对L列进行从小到大排序得到F列。

输入		F列		L列
c		\$		c
\$		a		\$
b	→	a	&	b
a		b		a
a		b		a
b		c		b



Read 比对算法BWT

➤ Step2: 循环解码

根据 L 列的字符 L_i 找到 F 列中的相同字符 F_j ，然后得到 F_j 所在行的最后一个字符 L_j 。将 L_j 记录下来；重复上面一步，直到 F_j 等于标记字符为止；按照上述步骤找到的各个 L_j 进行反向排列，得到字符串 r 。



Read 比对算法BWT

Step2-1:

L列的第一个字符c是原始字符串的最后一个字符。

输入	F列	L列
c	\$	c 1
\$	a	\$
b	a	b
a	b	a
a	b	a
b	c	b

原始字符串: c




基因组测序 DNA-seq

Read 比对算法BWT

Step2-2:

根据 L 列中第一行 L_1 的 c 这个字符找到 F 列中同样字符所在的行。由于 F 列中只有一个 c ，所以就是最后一行，对应的 F_6 。

根据 F_6 找到同一行的 L_6 ，即字符 b 。



原始字符串: bc

明德至诚 博学远志



Read 比对算法BWT

Step2-3:

根据 L_6 的 b 这个字符找到 F 列中同样字符所在的行。由于 F 列中有两个 b ，那选择哪一个呢？

一般地，如果 L_i ($i = 1, 2, \dots, n$)这个字符在 F 列中出现过多次，分别是 $F_j, F_{j+1}, \dots$ ；并且假设 L_1 到 L_i 里这 i 个字符中一共有 k 个($k \leq i$)字符等于 L_i 这个字符，那么我们要为 L_i 在 F 列中找的对应的字符就是 F_{j+k-1} 。

比如对应到这一步， $i = 6$ ， L_6 是字符 b ，而 F 列中共有2个 b ： F_4 和 F_5 ， L_6 对应哪一个呢？我们看到 L_1 到 L_6 中共有2个 b ，按照上面说的，选择 F_{4+2-1} ，即 F_5 。

根据 F_5 找到同一行的 L_5 ，即字符 a 。

输入	F列	L列
c	\$	(c) 1
\$	a	\$
b	a	b
a	b	a
a	b	(a) 3
b	c	(b) 2

原始字符串: abc



基因组测序 DNA-seq

Read 比对算法BWT

Step2-4:

根据 L_5 的 a 这个字符找到 F 列中同样字符所在的行。由于 F 列中有两个 a ，那选择哪一个呢？

同样地， F 列中共有2个 a ： F_2 和 F_3 ；而 L_1 到 L_5 中共有2个 a ，按照上面说的，选择 F_{2+2-1} ，即 F_3 。

根据 F_3 找到同一行的 L_3 ，即字符 b 。

输入	F列	L列
c	\$	(c) 1
\$	a	\$
b	a	(b) 4
a	b	a
a	b	(a) 3
b	c	(b) 2

原始字符串: **babc**

明德至诚 博学远志



基因组测序 DNA-seq

Read 比对算法BWT

Step2-5:

根据 L_3 的 b 这个字符找到 F 列中同样字符所在的行。 F 列中共有2个 b : F_4 和 F_5 ; 而 L_1 到 L_3 中共有1个 b , 按照上面说的, 选择 F_{4+1-1} , 即 F_4 。

根据 F_4 找到同一行的 L_4 , 即字符 a 。

输入	F列	L列
c	\$	(c) 1
\$	a	\$
b	a	(b) 4
a	b	(a) 5
a	b	(a) 3
b	c	(b) 2

原始字符串: ababc

博学远志



Read 比对算法BWT

Step2-6:

根据 L_4 的 a 这个字符找到 F 列中同样字符所在的行。 F 列中共有2个 a : F_2 和 F_3 ; 而 L_1 到 L_4 中共有1个 a , 按照上面说的, 选择 F_{2+1-1} , 即 F_2 。

根据 F_2 找到同一行的 L_2 , 即字符 $\$$ 。至此, 解码结束。

输入	F列	L列
c	\$	(c) 1
\$	a	(\$) 6
b	a	(b) 4
a	b	(a) 5
a	b	(a) 3
b	c	(b) 2

原始字符串: \$ababc



基因组测序 DNA-seq

Read 比对算法BWT

Step3: 输出原始字符串。

输入	F列	L列	输出
c	\$	(c) 1	→ \$ababc
\$	a	(\$) 6	
b	a	(b) 4	
a	b	(a) 5	
a	b	(a) 3	
b	c	(b) 2	



Read 比对文件格式

- ◆ reads 比对的结果文件为SAM(sequence alignment map)文件
- ◆ SAM 文件由**注释信息(header section)**和**比对结果 (alignment section)**两部分组成。
- ◆ 注释信息必须处于对齐部分之前，以 “@”符号开始，与比对结果区分开来。
- ◆ 注释信息用不同的tag表示不同的信息，主要有以下几种格式：
 - @HD, 说明符合标准的版本、对比序列的排列顺序。VN是格式版本；SO表示比对排序的类型，有unknown (default) , unsorted, queryname和coordinate几种。
 - @SQ, 参考序列说明。SN: 参考序列名字。LN: 参考序列长度。这些参考序列决定了比对结果sort的顺序
 - @RG, 比对上的序列 (read) 说明。Read Group。1个sample的测序结果为1个Read Group。
 - @PG, 使用的程序说明。比对所使用的软件及版本，例如hisat2、bwa等
 - @CO, 任意的说明信息



Read 比对文件格式

◆ 比对结果部分由 11个顺序固定的必需字段及相应的可选字段组成。

QNAME	比对read的名称信息
FLAG	位标识，表明比对类型：paring，strand，mate strand等
RNAME	比对上的参考序列名
POS	position缩写，read比对到参考序列上，第一个碱基所在的位置，没匹配上设置为0
MAPQ	Mapping quality缩写，比对的质量分数，越高说明位置越唯一且可信度越高
CIGAR	Compact Idiosyncratic Gapped Alignment Report, 简要比对信息表达式，其以参考序列为基础，使用数字加字母表示比对结果，比对结果信息,匹配碱基数，可变剪接等
RNEXT	下一个片段比对上的参考序列的编号，没有另外的片段，这里是*，同一个片段，用=**
PNEXT	下一个片段比对上的位置，如果不可用，此处为0
TLEN	观察到的Template的长度，最左边得为正，最右边的为负，中间的不用定义正负，不可用为0
SEQ	序列片段的序列信息，如果不存储此类信息设置为*
QUAL	序列的质量信息，格式同FASTQ一样，read质量的ASCII编码


```
@HD VN:1.6 S0:coordinate
@SQ SN:chr1 LN:248956422
@RG ID:sample1 SM:sample1
read1 99 chr1 100 60 50M = 200 150 ACGTACGT... !'!*((!!+
read2 147 chr1 200 60 50M = 100 -150 ACGTACGT... !'!*((!!+
```



基因组测序 DNA-seq

Read 比对文件格式

- ◆ SAM 文件的二进制形式是 **BAM 文件**，相当于**压缩的 SAM 文件**。
- ◆ 对比对结果文件进行**分析和编辑**：**SAMtools**软件
- ◆ 比对结果的**可视化**：**IGV**(integrative genomics viewer)、**Genome Maps** 和 **Savant**





Read 比对结果评估

- ◆ **reads 匹配百分比**: 用来评估总测序精确度和 DNA 污染程度
- ◆ **reads 随机性分布**: 以reads 在参考基因组上的分布来评估RNA打断的随机性程度, reads在参考基因组上分布比较均匀说明打断随机性较好。
- ◆ **匹配reads的GC含量**与PCR偏差相关。
- ◆ 评估工具:
 - RSeQC
 - Qualimap



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学

5. 基因组变异

明德至诚 博学远志



研究内容

- 自然变异

- 全基因组复制 (Whole genome duplication)
- 染色体异常 (Chromosome abnormality)
- 基因获得和缺失 (Gene gain and loss)
- 碱基突变/点突变 (Point mutation)

- 人工变异

- 基因编辑 (Gene editing)



全基因组复制 (Whole genome duplication)



基因组变异


全基因组复制概念

日本遗传学家与演化生物学家Susumu Ohno (1928-2000)在1970年提出

- 基因复制 (Gene Duplication)
- 全基因组复制 (Whole Genome Duplication, WGD)
- 脊椎动物**两轮WGD假说** (2 rounds of WGD) , 2R hypothesis
- 新遗传物质产生的主要机制
- 基因功能分化
- 基因丢失
- 新物种形成

大多数真核生物是
二倍体(diploid)

Ohno, S. **Evolution by Gene Duplication**
(Allen and Unwin, London, 1970)




多倍体Polyploid

- | | |
|--------------------------------|-------------------------------|
| ❖ Monoploid (one copy) | ❖ Hexaploid (six copies) 小麦 |
| ❖ Diploid (two copies) 有性生殖物种 | ❖ Heptaploid (seven copies) |
| ❖ Triploid (three copies) 无籽西瓜 | ❖ Octaploid (eight copies) 草莓 |
| ❖ Tetraploid (four copies) 马铃薯 | ❖ Nonaploid (nine copies) |
| ❖ Pentaploid (five copies) | ❖ Decaploid (ten copies) |



基因组变异

2R全基因组复制



Two Rounds of Whole Genome Duplication in the Ancestral Vertebrate. *PLoS Biology* 2015



整倍体基因组加倍

- **染色体组**：一组完整的非同源染色体，在形态和功能上各不相同且互相协助，携带着控制生物生长、发育、遗传和变异的全部信息
- **整倍体 (Euploid) 变异**：以染色体组（全部染色体）为单位进行复制或减少
- **多倍体 (Polyploid)**：具有三个或三个以上染色体组的整倍体（普通小麦是六倍体， $6x=42$)
 - 同源多倍体 (autopolyploid)：增加的染色体组来自同一物种
 - 异源多倍体 (allopolyploid)：增加的染色体组来自不同物种，生物进化、新物种形成的重要因素
 - 古多倍体 (Paleopolyploidy)：在进化历史中经历了基因组多倍化，但随后通过基因的丢失和重排重新二倍化
 - 新多倍体 (Neopolyploidy)：新形成的，基因组未发生重排，仍然保持多倍体形式的物种
- **全基因组复制**：又称多倍化事件，在植物、动物、真菌中都有发生




多倍体

- 多倍体：具有2套以上染色体组的细胞或个体
- 染色体加倍：可自然发生，也可人工诱发（秋水仙素等）
- 显花植物中有许多物种是多倍体
- 单子叶植物中多倍体物种占90%

无籽西瓜三倍体：二倍体 ($2x=22$) + 四倍体
(二倍体WGD, $4x=44$)

- 同源多倍体—少见：月见草（夜来香）
- 异源多倍体—常见：新种产生的重要途径，如西瓜、小麦、香蕉等

远缘杂交：杂交种后代育性低，在减数分裂中染色体无法配对。经过染色体加倍，解决了配对的问题，改进了育性。






基因组变异


古多倍体Paleopolyploidy

Known Paleopolyploidy in Eukaryotes
双子叶植物 单子叶植物 木兰 裸子植物



多倍体在生物界广泛存在，
常见于植物界

<https://en.wikipedia.org/wiki/Paleopolyploidy>




The Case of the Missing Ancient Fungal Polyploids. *The American Naturalist* 2016

明德至诚 博学远志



基因组变异

全基因组复制的证据




Proof and evolutionary analysis of ancient genome duplication in the yeast *Saccharomyces cerevisiae*. *Nature* 2004

明德至诚 博学远志



基因组变异

全基因组复制 (WGD)





七鳃鳗 (Lamprey)

- 比恐龙还早的**史前生物**，最古老的脊椎动物，重要进化节点物种
- 无颌（顎）“圆口类”动物，嘴呈圆筒形，口内有锋利的牙，吸血寄生
- **神经系统可再生**，用于研究人类神经障碍类疾病
- 基因组存在**大量重复片段**，GC含量高
- 染色体数目多，Northern lampreys有**164–174条染色体**

Sequencing of the sea lamprey (*Petromyzon marinus*) genome provides insights into vertebrate evolution.
Nature Genetics 2013




明德至诚 博学远志



基因组变异

鱼类进化与全基因组复制





基因组变异

六倍体小麦

野生一粒小麦
Triticum monococcum
AA (2n=14)



拟斯卑尔脱山羊草
Aegilops speltoides
BB (2n=14)



不育
WGD

野生二粒小麦
T. dicoccoides
AABB (2n=28)



栽培种
T. turgidum
AABB (2n=28)



粗山羊草
Ae. tauschii
DD (2n=14)



ABD

WGD 不育



普通小麦
T. aestivum

AABBDD (2n=42)



Molecular Basis of Evolutionary Events
That Shaped the Hardness Locus in
Diploid and Polyploid Wheat Species
(*Triticum* and *Aegilops*). *Plant Cell* 2015


<https://eol.org>

明德至诚 博学远志




基因组变异

六倍体小麦



<http://www.wheatgenome.org>

Shifting the limits in wheat research and breeding using a fully annotated reference genome. *Science* 2018



From Hong-Qing Ling, Institute of Genetics and Developmental Biology, Chinese Academy of Sciences


明德至诚 博学远志



基因组变异

全基因组复制 (WGD)：新品种和新物种

- 异源八倍体的小黑麦是我国鲍文奎用普通小麦和黑麦杂交，并经全基因组加倍而后培育而成。





染色体变异/异常 (Chromosome Abnormality)




基因组变异

染色体变异/异常 (Chromosome Abnormality)

- **数量变异 (Numerical Variation)**：非整倍体/异倍体 (aneuploid) 变异，染色体组非成倍增加或减少，只增加或减少一条或几条
 - 缺失：染色体数目减少
 - 增加：染色体数目增加
- **结构变异 (Structural Variation)**
 - 拷贝数变异 (CNV)
 - 插入 (Insertion)
 - 缺失 (Deletion)
 - 重复 (Duplication)
 - 倒位 (Inversion)
 - 易位 (Translocation)

SV: 1Kb ~ 3Mb, 现今扩展到大于50bp



<https://www.genome.gov/about-genomics/fact-sheets/Chromosome-Abnormalities-Fact-Sheet>



染色体异常：数量变异


- **13-三体综合征**：Patau综合征，新生儿发病率为1/4000 ~ 10000，女性明显多于男性，特征为严重智能低下，面容、手足及生殖器畸形，90%一岁内死亡。
- **18-三体综合征**：爱德华氏综合征，常会有宫内生长受限及先天性心脏病，小头、下颌较小、持续地紧握拳头并指头重叠，有严重智能障碍，患者至1岁的存活率只有约7.5%。
- **45,X**：特纳氏综合征，是雌性个体因X染色体缺失而引发的疾病，性腺发育不良且不孕，身材矮小，且患有先天性心脏病、糖尿病以及甲状腺功能低下症的几率较正常人高，大部分智力水平正常，平均寿命较短。
- **47,XXY**：克氏综合征，俗称次雄性综合征，是一系列由于男性有两条或两条以上的X染色体所导致的疾病，主要特征是不孕，先天性睾丸发育不全，新生男童中的发生率介于1/500 ~ 1000。
- **47,XYY**：超雄综合征，发病率是1/500到1/1000，患者身材高大，智力一般与正常人没有过大的差别。没有经过诊断，患者往往不知道自己XYY，有医学专家建议不能算是一种疾病。
- **47,XXX**：超雌性综合征，患者的外观正常，能正常发育成熟，有正常的生育能力；估计约有90%的患者并未被确诊，因为症状很少甚至没有。



From wikipedia



染色体异常的相关因素：生育年龄






染色体结构变异：倒位 (Inversion)

- 倒位的类型：
 - 臂内倒位Paracentric
 - 臂间倒位Pericentric
- 倒位是物种进化的重要因素之一，可能导致新物种的产生

Paracentric inversions do not include the centromere and both breaks occur in one arm of the chromosome.


Pericentric inversions include the centromere and there is a break point in each arm.

https://en.wikipedia.org/wiki/Chromosomal_inversion






人类与黑猩猩存在大量染色体倒位事件



An alignment-free method to find and visualise rearrangements between pairs of DNA sequences. *Scientific Reports* 2015




倒位事件：人类与黑猩猩7号染色体区域





基因组变异

染色体结构变异：易位 (Translocation)





慢性粒细胞白血病


Chronic Myeloid Leukemia

一种影响血液及骨髓的恶性肿瘤，产生大量不成熟的白细胞并在骨髓内聚集，抑制骨髓的正常造血，导致出现贫血、容易出血、感染及器官浸润。



大约90~95%的CML病人出现费城染色体

费城染色体 (Philadelphia chromosome)，是一种与CML相关的特殊染色体易位现象。其中，9号染色体长臂与22号染色体长臂进行相互易位，具体定义为 $t(9;22)(q34;q11)$ 。



1960年，两位美国费城的科学家：宾夕法尼亚大学教授Peter Nowell和Fox Chase癌症中心的David Hungerford首次发现此染色体变异



基因组变异

染色体易位导致多种人类疾病

ALL – [Acute lymphoblastic leukemia](#)


AML – [Acute myeloid leukemia](#)

CML – [Chronic myelogenous leukemia](#)

DFSP – [Dermatofibrosarcoma protuberans](#)

突起性皮肤纤维肉瘤

https://en.wikipedia.org/wiki/Chromosomal_translocation



明德至诚 博学远志



基因组变异

染色体异常




明德至诚 博学远志



基因组变异


染色体异常





染色体融合 (Fusion)

人类染色体: $2n=46$ vs 类人猿染色体: $2n=48$




https://www.mun.ca/biology/scarr/Human_Ape_chromosomes.htm



基因组变异

染色体异常导致多种人类疾病

- 已发现人类染色体数目变异和结构变异3000余种
- 目前已确认染色体病综合征大约有100余种
- 大部分染色体病的共同特征是智力低下和生长发育迟滞



明德至诚 博学远志



基因获得和缺失 (Gene gain and loss)



复制形成基因家族


- 基因家族 (Gene family) : 来源于同一个祖先, 通过复制 (Duplication) 而产生两个或更多的拷贝而构成的一组同源基因 (Homologous genes, duplicates)
- 复制类型: 基因复制、基因家族复制
- 家族成员: 经过突变 (Mutation) 和分化 (Divergence), 在结构和功能上具有明显的相似性, 各自具有不同的表达调控模式
- 染色体位置: 分散在同一染色体的不同位置, 或者存在于不同染色体上




基因组变异

球蛋白基因家族

球蛋白（Globin）超基因家族：脊椎动物氧呼吸代谢过程，主要包括血红蛋白（Hemoglobin）、肌红蛋白（Myoglobin）



血红蛋白基因家族：运载氧




http://www.mun.ca/biology/scarr/Globin_gene_families.html



基因组变异

血红蛋白基因家族



Globin Alignment of Globin Amino Acid Sequences

α ₁	1	MVLSPADKTNVKAAWGKVGAHAGEYGAEL
ζ	1	MSLTKTERTIIVSMWAKISTQADTIGTETL
α ₁	31	ERMFLSFPTTKTYFPHFDLSH-GSAQVKGH
ζ	31	ERLFLSHPQTKTYFPHFDL-HPGSAQLRAH
α ₁	61	GKKVADALTNAVAHVDDMPNALSALSDLHA
ζ	61	GSKVVAAVGDAVKISIDDIGGALSKLSELHA
α ₁	91	HKLRVDPVNFKLLSHCLLVTLAAHLPAEFT
ζ	91	YILRVDPVNFKLLSHCLLVTLAARFPADFT
α ₁	121	PAVHASLDKFLASVSTVLTISKYR
ζ	121	AEAHAAWDKFLSVSVLTISKYR

Amino Acid Identity Table									
α Family					β Family				
		α ₁ (alpha 1)	α ₂ (alpha 2)	ζ (zeta)	β (beta)	δ (delta)	ε (epsilon)	A _γ (gamma A)	G _γ (gamma G)
α Family	α ₁	-----	100	61	45	44	39	42	42
	α ₂		-----	61	45	44	39	42	42
	ζ			-----	38	40	41	41	41
β Family	β				-----	93	76	73	73
	δ					-----	73	71	72
	ε						-----	80	80
	A _γ							-----	99
	G _γ								-----

基因家族成员：

复制、突变、分化

beta血红蛋白基因家族：人与黑猩猩分子序列完全一样


<https://abt.ucpress.edu/content/72/4/252>

明德至诚 博学远志



同源基因：直系同源、旁系同源

- **同源基因 (Homolog / Homologous gene)**：具有一个共同祖先的多个基因
- **直系同源基因 (Ortholog / Orthologous gene)**：由**物种分化**所产生同源基因。基因功能保守，进化缓慢，且序列变化速度与进化距离相当，大多数直系同源基因功能相同或相近，调控途径也相似
- **旁系同源基因 (Paralog / Paralogous gene)**：由同一物种内的**基因复制**而产生的同源基因。基因复制后，其中一条基因丢失或发生沉默，都能促使旁系同源基因分化，产生新特性或新功能






Hox基因家族

- **同源异形基因 (Hox基因)** 是生物体内一类重要的发育调控基因家族，专门调控生物形体，一旦这些基因发生突变，就会使身体的一部分变形，在个体胚胎发育中起着重要调控作用。
- Hox基因是**生物体形体结构“建筑师”**，大多数动物皆拥有类似的Hox基因排列方式、产物与作用方式，经历了几十亿年的长期演化但功能类似。
- 进化上**高度保守**，在染色体上**排列成簇**，**排列顺序**与它们所控制的胚胎发育密切相关，称之为**共线性规则**。这些基因按顺序活化，保证器官以及各部位骨骼依据发育模式，前后轴（anterior-posterior axis，从头到脚）排列。

https://en.wikipedia.org/wiki/Hox_gene






基因组变异

人类Hox基因

- 人类Hox基因有39个，果蝇有8个
- 人类Hox基因分成4个基因簇，分别位于染色体7、17、12和2

染色体	基因簇	影响头部	影响颈部	影响躯干	影响四肢
7	HOXA	HOXA1 HOXA2 HOXA3 HOXA4	HOXA5 HOXA6	HOXA7	HOXA9 HOXA10 HOXA11 HOXA13
17	HOXB	HOXB1 HOXB2 HOXB3 HOXB4	HOXB5 HOXB6	HOXB7 HOXB8	HOXB9
12	HOXC	HOXC4	HOXC5 HOXC6	HOXC8	HOXC9 HOXC10 HOXC11 HOXC12 HOXC13
2	HOXD	HOXD1 HOXD3 HOXD4		HOXD8	HOXD9 HOXD10 HOXD11 HOXD12 HOXD13

<https://socratic.org/biology/reproduction-development/hox-genes>




明德至诚 博学远志



基因组变异

HOX基因家族：WGD引发基因复制

哺乳动物、两栖动物、爬行动物、鸟类：大部分有4个Hox基因簇




A new look at an old question: when did the second whole genome duplication occur in vertebrate evolution? *Genome Biology* 2018

明德至诚 博学远志



基因组变异

多物种Hox基因





序列插入


- 串联重复序列 (Tandem repeat) : 以相对恒定的短序列为重复单位, 首尾相接, 串联连接形成的重复序列, 又称卫星DNA (Satellite DNA)
 - 小卫星DNA (Minisatellite)
 - 微卫星DNA (Microsatellite), 又称短串联重复 (Short tandem repeat, STR), 简单序列重复 (Simple sequence repeat, SSR)
- 散在重复序列 (Interspersed repeat) ——转座子 (Transposon) : 是一种跳跃基因, 可以由基因组的一个位置跳跃 (插入) 到另一个位置
 - I型转座子: 又叫反转座子 (retrotransposon) : “复制-粘贴”型转座元件, 通过RNA的媒介作用, 通过RNA的反转录获得DNA, 从而转移到其他基因组位置。包括: 长末端重复LTR (long terminal repeat)、LINE/SINE (long/short interspersed nuclear element)
 - II型转座子: 也叫做转座子 (transposon) : “剪切-粘贴”型转座元件。在转座酶的作用下, II型转座子从原来的位置解离下来, 再重新插入到染色体上



简单序列重复与人类疾病

亨廷顿舞蹈症 Huntington's Disease

- 一种常染色体致命性遗传病，临床症状复杂多变，以舞蹈样动作伴进行性认知、精神功能障碍终至痴呆为主要特征。
- 由发生扩增的三核苷酸重复序列CAG引起，发病年龄与扩增的重复序列的长度呈负相关，影响不同的分子通路，最终导致神经功能失调和退化。






基因组变异

散在重复序列：转座子

玉米：反转录转座子49-78%

小麦：重复序列约90%，转座子68%

人类：42%反转录转座子，2-3%DNA转座子



DNA Transposons and the Evolution of Eukaryotic Genomes. *Annu Rev Genet* 2007

明德至诚 博学远志



碱基突变/点突变 (Point mutation)



基因组变异

基因突变


• 突变类型

- 替换: $ATG \Rightarrow ACG$, 假如某单核苷酸替换在群体发生的频率大于1%, 该替换称为**单核苷酸多态性** (Single Nucleotide Polymorphism, 简称**SNP**)
- 插入: $ATG \Rightarrow ATCG$
- 删除: $ATG \Rightarrow AG$
- 倒位: $ATG \Rightarrow AGT$

• 替换类型 发生频率: 转换 > 颠换

- 转换(Transition): 嘌呤(A/G)间或嘧啶(T/C)间的替换
- 颠换(Transversion): 嘌呤与嘧啶之间的替换

细胞分裂时遗传基因的复制发生错误、或受化学物质、基因毒性、辐射或病毒的影响




<https://en.wikipedia.org/wiki/Transversion>



基因组变异

核苷酸突变：影响密码子编码氨基酸

三个核苷酸组成一个密码子
(Codon)，共 $4^3=64$ 个



Ribonucleic acid

碱基1	碱基2								碱基3	
	U		C		A		G			
U	UUU	(Phe/F) 苯丙氨酸	UCU	(Ser/S) 丝氨酸	UAU	(Tyr/Y) 酪氨酸	UGU	(Cys/C) 半胱氨酸	U	
	UUC		UCC		UAC		UGC		C	
	UUA	(Leu/L) 亮氨酸	UCA		UAA	终止 (赭石)	UGA	终止 (蛋白石)	A	
	UUG		UCG		UAG	终止 (琥珀)	UGG	(Trp/W) 色氨酸	G	
C	CUU	(Leu/L) 亮氨酸	CCU	(Pro/P) 脯氨酸	CAU	(His/H) 组氨酸	CGU	(Arg/R) 精氨酸	U	
	CUC		CCC		CAC		CGC			C
	CUA		CCA		CAA	(Gln/Q) 谷氨酰胺	CGA			A
	CUG		CCG		CAG		CGG			G
A	AUU	(Ile/I) 异亮氨酸	ACU	(Thr/T) 苏氨酸	AAU	(Asn/N) 天冬酰胺	AGU	(Ser/S) 丝氨酸	U	
	AUC		ACC		AAC		AGC		C	
	AUA		ACA		AAA	(Lys/K) 赖氨酸	AGA	(Arg/R) 精氨酸	A	
	AUG	(Met/M) 甲硫氨酸	ACG		AAG		AGG		G	
G	GUU	(Val/V) 缬氨酸	GCU	(Ala/A) 丙氨酸	GAU	(Asp/D) 天冬氨酸	GGU	(Gly/G) 甘氨酸	U	
	GUC		GCC		GAC		GGC			C
	GUA		GCA		GAA	(Glu/E) 谷氨酸	GGA			A
	GUG		GCG		GAG		GGG			G

氨基酸生化性质

非极性

极性

碱性

酸性

终止密码子

明德至诚 博学远志



点突变

- **同义突变 (synonymous/silent)** : 不改变编码氨基酸
TT**A** (Leu) <-> TT**G** (Leu)
- **非同义突变 (nonsynonymous)** : 改变编码的氨基酸
TT**A** (Leu) <-> TT**T** (Phe)
- **无义突变 (nonsense)** : 某一氨基酸的密码子变为终止密码子
TT**A** (Leu) <-> T**A**A (Stop)
- **连读突变 (read-through)** : 终止密码子变成某一氨基酸的密码子
T**A**A (Stop) <-> TT**A** (Leu)




点突变

- 突变是生物进化的基本动力
- 突变具有普遍性、随机性、低频性、可逆性等特点
- 发生条件：细胞分裂时遗传基因的复制发生错误、或受化学物质、基因毒性、辐射或病毒的影响
 - 自发突变 (spontaneous mutation)：在自然条件下，有机体由于与环境随机相互作用或偶然的复制错误而发生的突变
 - 诱发突变 (induced mutation)：使用诱变剂处理生物体而产生的突变
- 每个基因都有积累突变的风险



单核苷酸突变导致人类疾病

- 镰刀型红细胞贫血症 (Sickle Cell Anemia) 是一种常染色体隐性基因遗传病，血液红细胞呈镰刀状，其携带氧的功能只有正常红细胞的一半。
- 目前没有特效治疗手段，主要靠输血维持，患者多在成年前死亡，2015年全球患者440万人。
- 由血红蛋白 β 链基因点突变引起，正常 β 基因的第7个密码子为GAG编码谷氨酸，突变后为GTG编码缬氨酸，致使载氧血红蛋白异常，红血球会变成坚硬的镰刀型。




Sequence for Wild-Type Hemoglobin												
ATG	GTG	CAC	CTG	ACT	CCT	GAG	GAG	AAG	TCT	GCC	GTT	ACT
Start	Val	His	Leu	Thr	Pro	Glu	Glu	Lys	Ser	Ala	Val	Thr
Sequence for Mutant (Sickle-Cell) Hemoglobin												
ATG	GTG	CAC	CTG	ACT	CCT	GTG	GAG	AAG	TCT	GCC	GTT	ACT
Start	Val	His	Leu	Thr	Pro	Val	Glu	Lys	Ser	Ala	Val	Thr

<https://www.nature.com/scitable/topicpage/genetic-mutation-441/>




基因组变异

镰刀型红细胞贫血症



<https://www.synthego.com/crispr-sickle-cell-disease>



“.....every year approximately 300,000 infants are born with sickle cell anemia and that this number could rise to 400,000 by 2050.....”

Sickle Cell Disease. *N Engl J Med* 2017



明德至诚 博学远志



单核苷酸突变导致人类疾病

疟疾与遗传病镰刀形红细胞贫血症（SCA）协同进化

- 疟疾是由人类疟原虫感染引起的寄生虫病，主要由雌性按蚊叮咬传播，常流行在非洲。已知寄生于人体的疟原虫有五种，且目前尚无疫苗。
- β 珠蛋白突变的单个拷贝导致镰状性状，并对严重疟疾和疟疾死亡提供了实质性保护。




Simultaneous adjunctive treatment of malaria and its coevolved genetic disorder sickle cell anemia. *Blood Adv* 2023.



基因组变异

突变：生殖细胞 vs 体细胞

- **生殖细胞(germline)突变**：发生在生殖细胞中的突变，可通过有性生殖遗传给后代，并存在于子代的每个细胞中。
- **体细胞(somatic)突变**：发生在体细胞中的突变，不会传递给子代，但可传递给由突变细胞分裂所形成的子细胞，在局部形成突变细胞群，可能成为病变甚至癌变的基础。




The mutation rate in human evolution and demographic inference. Current Opinion in Genetics & Development 2016

明德至诚 博学远志



基因组变异


突变率





基因组变异

小结





基因组变异

基因编辑



明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-基因组学

6. 基因组注释

明德至诚 博学远志



研究内容

- 基因组注释的定义
- 基因组注释的复杂性：原核生物 vs 真核生物
- 基因组结构注释
 - 原核生物
 - 真核生物
- 基因组功能注释
 - 序列比对
 - 基因本体论和代谢途径
 - 基因功能富集



基因组注释的定义



基因组注释

基因组测序完成 → 基因组注释开始

ACACTCGCTTCTGGAACGTCTGAGGTTATCAATAAGCTCCTAGTCCAGACGCCATGGGTCATTTACAGAGGAGGACAAGGCTACTATCACAAAGCCTGTGGGGCA
AGGTGAATGTGGAAGATGCTGGAGGAGAAACCTGGGAAGGCTCCTGGTTGTCTACCCATGGACCCAGAGGTTCTTTGACAGCTTTGGCAACCTGTCCTCTGCCT
CTGCCATCATGGGCAACCCCAAAGTCAAGGCACATGGCAAGAAGGTGCTGACTTCCTTGGGAGATGCCACAAAGCACCTGGATGATCTCAAGGGCACCTTTGCCC
AGCTGAGTGAAGTGCAGTGTGACAAGCTGCATGTGGATCCTGAGAACTTCAAGCTCCTGGGAAATGTGCTGGTGACCGTTTTGGCAATCCATTTTCGGCAAAGAAT
TCACCCCTGAGGTGCAGGCTTCCTGGCAGAAGATGGTGACTGCAGTGGCCAGTGCCCTGTCCTCCAGATACCACTGAGCTCACTGCCCATGATTCAGAGCTTTCA
AGGATAGGCTTTATTCTGCAAGCAATACAAATAATAAATCTATTCTGCTGAGAGATCACACATTTGCTTCTGACACAACCTGTGTTCACTAGCAACCTCAAACAGA
CACCATGGTGCATCTGACTCCTGAGGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGTGAACGTGGATGAAGTTGGTGGTGAGGCCCTGGGCAGGCTGCTGGT
GGTCTACCCCTTGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGTCCACTCCTGATGCTGTTATGGGCAACCCTAAGGTGAAGGCTCATGGCAAGAAAGTGCT
CGGTGCCTTTAGTGATGGCCTGGCTCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGCTGCACTGTGACAAGCTGCACGTGGATCCTGAGAACTT
CAGGCTCCTGGGCAACGTGCTGGTCTGTGTGCTGGCCCATCACTTTGGCAAAGAATTCACCCACACAGTGCCAGGCTGCCTATCAGAAAGTGGTGGCTGGTGTGGC
TAATGCCCTGGCCCACAAGTATCACTAAGCTCGCTTTCTTGCTGTCCAATTTCTATTAAAGGTTCCCTTTGTTCCCTAAGTCCAACCTACTAAACTGGGGGATATTA
TGAAGGGCCTTGAGCATCTGGATTCTGCCTAATAAAAAACATTTATTTTCATTGCACACTCGCTTCTGGAACGTCTGAGGTTATCAATAAGCTCCTAGTCCAGAC
GCCATGGGTCATTTACAGAGGAGGACAAGGCTACTATCACAAAGCCTGTGGGGCAAGGTGAATGTGGAAGATGCTGGAGGAGAAACCTGGGAAGGCTCCTGGTT
GTCTACCCATGGACCCAGAGGTTCTTTGACAGCTTTGGCAACCTGTCCTCTGCCATCATGGGCAACCCCAAAGTCAAGGCACATGGCAAGAAGGTGCTG
ACTTCCTTGGGAGATGCCACAAAGCACCTGGATGATCTCAAGGGCACCTTTGCCAGCTGAGTGAAGTGCAGTGTGACAAGCTGCATGTGGATCCTGAGAACTTC
AAGCTCCTGGGAAATGTGCTGGTGACCGTTTTGGCAATCCATTTTCGGCAAAGAATTCACCCCTGAGGTGCAGGCTTCCTGGCAGAAGATGGTGACTGCAGTGGCC
AGTGCCCTGTCCTCCAGATACCACTGAGCTCACTGCCCATGATTCAGAGCTTTCAAGGATAGGCTTTATTCTGCAAGCAATACAAATAATAAATCTATTCTGCTG
AGAGATCACACATTTGCTTCTGACACAACCTGTGTTCACTAGCAACCTCAAACAGACACCATGGTGCATCTGACTCCTGAGGAGAAGTCTGCCGTTACTGCCCTGT
GGGGCAAGGTGAACGTGGATGAAGTTGGTGGTGAGGCCCTGGGCAGGCTGCTGGTGGTCTACCCCTTGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGT

明德至诚 博学远志




基因组注释 (Genome annotation)

- **定义：**利用生物信息学方法和工具，对基因组所有基因的生物学功能进行高通量注释，是当前功能基因组学研究的一个热点。
 - **结构注释** (Structural annotation)：基因位置及其结构等
 - **功能注释** (Functional annotation)：基因功能及其调控等
- **目的：**识别基因组序列中存在的基因和其他多种功能元件（包括编码基因、非编码RNA、转座子等重复序列、调控元件等），并推测其生物学功能（例：ENCODE）。
- **意义：**基因组注释是生物学研究的基础，一个基因组的价值取决于该基因组注释的质量，基因组注释建立了从未知功能的基因组序列到该物种生物学研究的桥梁。



基因组注释计划：ENCODE



ENCODE Encyclopedia Version 2: Genomic and Transcriptomic Annotations



The goal of ENCODE is to build a comprehensive parts list of functional elements in the human genome, including elements that act at the protein and RNA levels, and regulatory elements that control cells and circumstances in which a gene is active.

The ENCODE has two levels of annotations:

- **Integrative-level annotations** integrate multiple types of experimental data and ground level annotations.
- **Ground-level annotations** are derived directly from the experimental data, typically produced by uniform processing pipelines.

Genome annotation: from sequence to biology. *Nature Reviews Genetics* 2001



基因组注释

 National Library of Medicine

HomeWrite to the Help Desk

NLM Support Center > Knowledge Base > KA-03574

What is genome annotation?

★★★★★

Views: 3746

Genome annotation is the process of finding and designating locations of individual genes and other features on raw DNA sequences, called assemblies. Annotation gives meaning to a given sequence and makes it much easier for researchers to view and analyze its contents. To visualize what annotation adds to our understanding of the sequence, you can compare the [raw sequence \(in FASTA format\)](#) with the [GenBank](#) or [Graphics](#) formats, both of which contains annotations. In both instances note the placement of individual genes and other features on the sequence.

When a group of researchers assemble a genome, they may also — with processes they establish themselves — annotate it at the same time. In the past, an assembly with annotation was known as a build. These days, the term build is rarely used, as the genome assembly process and its annotation process are often completely uncoupled. They can be conducted at different times by different parties. For example, the [Genome Reference Consortium \(GRC\)](#) is maintaining and updating the human [reference assembly](#). GRC releases assembly (sequence) updates and deposits these to the [International Nucleotide Sequence Database Collaboration \(INSDC\)](#) without annotation. GRC prepared the latest major assembly update (major release designated as GRCh38) in December 2013 and it has since followed with several minor updates (patches). In further processing of an assembly update, the NCBI staff creates a RefSeq version of the submitted INSDC assembly. Following that, NCBI annotates the RefSeq version of the assembly. Each annotation release has its own designation and time stamp. For example, the latest (as of May 2021) NCBI annotation release is designated as [Release 109.20210514](#).

In addition of the human reference genome, NCBI staff annotate numerous eukaryotic genomes via the powerful [Eukaryotic Genome Annotation Pipeline](#). Visit the [Eukaryotic Genome Annotation at NCBI](#) page to start exploring extensive documentation on the annotation process, and to follow the progress of individual genome annotation.

NCBI staff have also developed the [Prokaryotic Genome Annotation Pipeline](#) that is available as a [service to GenBank submitters](#) and also as a [stand-alone software package](#).



基因组注释

识别基因组中编码基因、非编码基因及调控区域


ACACTCGCTTCTGGAACGTCTGAGGTTATCAATAAGCTCCTAGTCCAGACGCCATGGGTCATTTACAGAGGAGGACAAGGCTACTATCACAAAGCCTGT
GGGGCAAGGTGAATGTGGAAGATGCTGGAGGAGAAACCCCTGGGAAGGCTCCTGGTTGTCTACCCATGGACCCAGAGGTTCTTTGACAGCTTTGGCAACC
TGTCTCTGCCTCTGCCATCATGGGCAACCCCAAAGTCAAGGCACATGGCAAGAAGGTGCTGACTTCCTTGGGAGATGCCACAAAGCACCTGGATGATC
TCAAGGGCACCTTTGCCAGCTGAGTGAAGTGCACCTGTGACAAGCTGCATGTGGATCCTGAGAAGCTTCAAGCTCCTGGGAAATGTGCTGGTGACCGTTT
TGGCAATCCATTTTCGGCAAAGAATTCACCCCTGAGGTGCAGGCTTCCTGGCAGAAGATGGTGACTGCAGTGGCCAGTGGCCCTGTCCTCCAGATACCACT
GAGCTCACTGCCCATGATTCAGAGCTTTCAAGGATAGGCTTTTATTCTGCAAGCAATAACAATAATAAATCTATTCTGCTGAGAGATCACACATTTGCTT
CTGACACAACCTGTGTTCACTAGCAACCTCAAACAGACACCGTGGATGAAGTTGGTGTTGAGGCCCTGGGCAGGCTGCTC
TGCTGTTATGGGCAACCCTAAGGTGAAGGCTCATGGCAACCTGACACACTGAGTGAGCTGCACCTGTGACAAGCTGCACGT
TGGCAAAGAATTCACCCACCAAGTGCAGGCTGCCTATCACTGCTGTCCAATTTCTATTAAAGGTTCCCTTTGTTCCCTAA
AAAAACATTTATTTTCATTGCACACTCGCTTCTGGAACCAAGGCTACTATCACAAAGCCTGTGGGGCAAGGTGAATGTG
TTCTTTGACAGCTTTGGCAACCTGTCCTCTGCCTCTGCCGCCACAAAGCACCTGGATGATCTCAAGGGCACCTTTGCC
GGAAATGTGCTGGTGACCGTTTTGGCAATCCATTTTCGGCGCCCTGTCTCCAGATACCACTGAGCTCACTGCCCATGA
CTGAGAGATCACACATTTGCTTCTGACACAACCTGTGTTCTGCCCCCTGTGGGGCAAGGTGAACGTGGATGAAGTTGGTG
TTGGGGATCTGTCCACTCCTGATGCTGTTATGGGCAACCTTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGC
TCTGTGTGCTGGCCCATCACTTTGGCAATAAATCTATTCTGCTGAGAGATCACACATTTGCTTCTGACACAACCTGTGTTCACTAGCAACCTCAAACAGA
CACCATGGTGATCTGACTCCTGAGGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGTGAACGTGGATGAAGTTGGTGGTGAGGCCCTGGGCAGGCT
GCTGGTGGTCTACCCTTGGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGTCCACTCCTGATGCTGTTATGGGCAACCTAAGGTGAAGGCTCATGG
CAAGAAAGTGCTCGGTGCCTTTAGTGATGGCCTGGCTCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGACTTGGGAACGTCAACCGTTTA





基因组注释

基因组注释：结构注释和功能注释



A beginner's guide to
eukaryotic genome annotation.
Nature Reviews Genetics 2012

Like parenthood, genome annotation responsibilities do not end with birth.

— 基因组注释不能 “管生不管养”

Ten steps to get started in
Genome Assembly and
Annotation. *F1000Research* 2018

Successful genome annotation projects do not just end with the publication of a paper; they should produce sustainable resources to promote, extend and improve the genome annotation life cycle.

明德至诚 博学远志




基因组注释的复杂性

原核生物 vs 真核生物




基因组注释

基因结构



原核生物基因结构




真核生物基因结构



基因组注释

原核生物基因组注释流程




NCBI NR (Non-Redundant Protein Sequence Database)

明德至诚 博学远志



基因组注释

真核生物基因组注释流程





原核生物基因组结构注释



基因预测的方法

- **湿性实验手段**：通过实验分析，看其是否能表达基因产物；通量低、成本高
- **干性实验预测**：通过计算机对DNA序列进行特征搜寻，分析寻找基因；通量高、成本低（生物信息学）
 - 基于基因结构特征搜寻
 - 基于同源基因搜索

基因组序列




基因结构





方法一：基于基因结构特征搜寻

基因的核苷酸序列并非随机排列，而是具有明显特征，可基于开放读码框（Open reading frame, ORF）预测基因。





方法二：基于同源基因搜索

通过将数据库中的基因序列与待查的基因组序列进行比较，从中查找可与之匹配的碱基序列及其比例，用于界定基因的方法称为**同源搜索**。

同源基因有以下几种情况：

- DNA序列某些片段完全相同
- ORF排列类似
- ORF翻译成的氨基酸序列相同
- 模拟多肽高级结构相似




原核生物编码基因预测

- 原核生物基因的各种信号位点（如启动子和终止子信号位点）特异性较强且容易识别，因此相应的基因预测方法已经基本成熟。Prodigal和Glimmer是应用最为广泛的原核生物基因结构预测软件，准确度高。

- 原理: 通过扫描基因组，找到从ATG (少数GTG、TTG)开始的位置，直到TGA、TAG、TAA。

- 多顺反子: 在原核细胞中，通常是几种不同的mRNA连在一起，位于同一转录单位内，相互之间由一段短的不编码蛋白质的间隔序列所隔开，享有同一起点和终点。





原核生物编码基因预测软件

- Glimmer: 采用内插**马尔科夫模型** (IMM) 来识别编码区域和非编码区域。一般使用三种方法创建训练模型 (Delcher et al. 2007. PMID: 17237039) :
 - 用亲缘关系很近的物种基因
 - 用自身序列创建的ORF数据
 - 用基因组本身的已知信息 (常采用自身数据作为训练数据)
- Prodigal: 原核的**动态编程**基因查找算法, 针对原核生物的基因预测工具, 尤其是高GC的基因组, 同时也适用于宏基因组 (Hyatt et al. 2010. PMID: 20211023)
- GeneMark: 原理是使用**统计学模型**的从头预测(ab initio)方法, 不依赖任何先验知识和经验参数, 通过描述DNA序列中核苷酸的离散模型, 利用编码区和非编码区的核苷酸分布概率不同来进行基因预测 (Besemer, et al. 2001. PMID: 11410670)




真核生物基因组结构注释



Kozak序列规则

- Kozak序列是存在于真核生物mRNA的一段序列，位于mRNA 5' 端帽子结构后面的一段核酸序列，通常是GCCRCCATGG，其在翻译的起始中有重要作用。



- 起始密码子：ATG/GTG
 - 第一个ATG的确定可依据Kozak规则，即第一个ATG侧翼序列的碱基分布所满足的统计规律，若将第一个ATG中的碱基A，T，G分别标为1，2，3位，则Kozak规则可描述如下：
 - (1)第4位的偏好碱基为G
 - (2)ATG的5' 端约15bp范围的侧翼序列内不含碱基T
 - (3)在-3，-6和-9位置，G是偏好碱基
 - (4)除-3，-6和-9位，在整个侧翼序列区，C是偏好碱基
 - 终止密码子：TAA，TAG，TGA
 - GC%=50% 终止密码子每64bp出现一次
 - GC%>50% 终止密码子每100-200bp出现一次

The Kozak sequence is a nucleic acid motif that functions as the protein translation initiation site in most eukaryotic mRNA transcripts, which was determined by sequencing of 699 vertebrate mRNAs and named after the scientist who discovered it, Marilyn Kozak.

https://en.wikipedia.org/wiki/Kozak_consensus_sequence

明德至誠 博學遠志



重复序列

重复序列可分为串联重复序列 (Tandem repeat) 和散在重复序列 (Interspersed repeat) 两大类:

- 串联重复序列: 微卫星序列、小卫星序列等
- 散在重复序列: 又称转座子元件TE
 - DNA转座子
 - 反转录转座子 (retrotransposon)
 - LTR
 - LINE
 - SINE



重复序列注释方法

识别重复序列的方法分为两类：

- **序列比对方法**：一般采用Repeatmasker软件，**识别与已知重复序列相似的序列**，并对其进行分类。常用Repbased重复序列数据库。
- **从头预测方法**：利用重复序列或转座子自身的序列或结构特征构建从头预测算法或软件对序列进行识别。从头预测方法的优点在于能够根据转座子元件自身的结构特征进行预测，**不依赖于已有的转座子数据库，能够发现未知的转座子元件**。常见的从头预测方法有Recon、RepeatModeler等。




基于转录本注释基因结构

PASA是一种真核生物基因组注释工具，它利用表达的转录序列的剪接排列来自动建模基因结构，并保持基因结构注释与测序数据一致。PASA还识别并分类了转录本比对支持的所有剪接变体。

PASA的注释功能还包括：

- 注释 UTR 区域
- 外显子的添加、删除、边界调整
- 增加可变剪接变体
- 注释基因的polyA位点
- 识别反义转录本
- 识别并分类所有发现的剪接变异

Gene Structure Annotation and Analysis Using PASA



PASA, acronym for Program to Assemble Spliced Alignments (and pronounced 'pass-uh'), is a eukaryotic genome annotation tool that exploits spliced alignments of expressed transcript sequences to automatically model gene structures, and to maintain gene structure annotation consistent with the most recently available experimental sequence data. PASA also identifies and classifies all splicing variations supported by the transcript alignments.


<http://pasapipeline.github.io/>



基因组注释

三种方法的整合

通过整合软件预测、基于同源注释和转录本预测三种方法的预测结果，得到最终的基因结构模型



A beginner's guide to eukaryotic genome annotation. *Nature Reviews Genetics* 2012

明德至诚 博学远志



基因组注释

基因功能注释



基因功能注释

基因功能注释：通过比对的方法根据已知功能的蛋白质编码基因序列预测未知蛋白质编码基因的功能。

- 功能序列 (Functional Motif Detection)
- 基因本体 (Gene Ontology Annotation)
- 代谢通路 (KEGG Enrichment Analysis)





基因功能注释


普遍采用BLAST比对方法对预测出来的编码基因进行功能注释，通过与各种功能数据库（NCBI nr、Swiss-Prot 等）进行蛋白质比对，获取该基因的功能信息。

- Swiss-Prot是经过注释的蛋白质序列数据库，由欧洲生物信息学研究所（EBI）维护。数据库由蛋白质序列条目构成，每个条目包含蛋白质序列、引用文献信息、分类学信息、注释等。
- NCBI nr 是非冗余的蛋白序列数据库，主要数据来源为GenBank CDS translations+PDB+SwissProt+PIR+PRF。



基因组注释

基因功能注释





基因本体论和代谢途径



本体论 (Ontology)

- Ontology 是特定领域信息组织的一种形式，是**领域知识规范的抽象和描述**，是表达、共享、重用知识的方法。
- Ontology 是**知识体系构建的关键技术**，知识图谱是一种人工智能技术，它的关键在于让计算机能够处理人类的知识。然而，人类脑海中的知识通常是直觉性的，我们无法将这种直觉性的知识直接输入给计算机，Ontology 就是一种对知识建模，使计算机能够识别人类知识的方法。
- 本体 (Ontology) 通过对于**概念 (Concept)、术语 (Terminology) 及其相互关系 (Relation, Property) 的规范化 (Conceptualization) 描述**，勾画出某一领域的基本知识体系和描述语言。



基因本体 (Gene Ontology)

基因本体 (Gene Ontology, 简称GO) 是一种系统地对物种基因及其产物属性进行注释的方法和过程。基因本体知识库是世界上最大的基因功能信息资源。这些知识既是**人类可读的**，又是**机器可读的**，是生物医学研究中大规模分子生物学和遗传学实验的计算分析的基础。其目标是：

- 维护和发展基因及其产物属性描述的词汇；
- 注释基因及其产物，传播注释数据；
- 提供方便的工具访问数据；
- 实现在实验数据的基础上，使用GO进行程式解析，例如基因富集组分分析。

<http://geneontology.org>



A resource with **controlled vocabulary** to describe the function of genes and gene products

Founded in 1998 when researchers studying the genome of three model organisms—*Drosophila melanogaster* (fruit fly), *Mus musculus* (mouse), and *Saccharomyces cerevisiae* (brewer's or baker's yeast)



GO的组成

- GO中最基本的概念是term
- GO里的每条记录(entry) 都有一个唯一的编号GO:NNNNNNNN, 对应一个term, 比如
“cell” 、 “DNA binding” 、 “signal transduction” • 每个term属于一个ontology, 总共有3个ontology:

1. 分子功能 (Molecular Function)

由基因产物进行的分子水平的活动。分子功能术语描述在分子水平上发生的活动, 如 “催化” 或 “运输” 。

2. 细胞组件 (Cellular Component)

细胞的组成 (如线粒体) 或稳定的大分子复合物 (如核糖体) 。

3. 生物过程 (Biological Process)

由多个分子活动完成的过程, 例如: DNA修复、信号转导。

注意, 一个生物过程并不等同于一个途径。



金久实 (Minoru Kanehisa)
日本京都大学

- 1948 年出生于日本长崎
- 1976 年在东京大学获物理系博士学位，之后在霍普金斯医学院从事博士后研究
- 1981年成为阿拉莫斯国家实验室的研究科学家，在此期间参与GenBank数据库开发
- 1995年至今，研发KEGG，发表20多篇数据库文章
- 2018年，被美国科睿维安列为可能获诺贝尔奖人选之一


KEGG Pathway代谢途径

KEGG (Kyoto Encyclopedia of Genes and Genomes)代谢路径数据库是一组手工绘制的图形图，称为KEGG路径图，表示代谢、遗传信息处理、环境信息处理、细胞过程、组织系统、人类疾病和药物开发的分子路径。KEGG中存在三大类代谢图，每个数据路的pathway都有相应的唯一编号。

- reference pathway：根据已有的知识绘制的的具有一般参考意义的代谢图。通路图中的小框都是白色，在KEGG中名字以map开头，比map00010。
- species-specific pathway：物种特有代谢通路图。绿色小框为该物种特有的基因或酶。名字为特定物种种属英文缩写，比如人的糖酵解通路图hsa00010。
- 以ko/ec/rn开头的Reference pathway：ko通路中的节点只代表基因；ec通路中的节点只代表相关的酶；rn通路中的节点只表示该点参与的某个反应、反应物及反应类型。底色以蓝色表示。



主要代谢途径





KEGG PATHWAY代谢途径

1. Metabolism

一级

1.0 Global and overview maps

二级


- 01100 Metabolic pathways
- 01110 Biosynthesis of secondary metabolites *Major update!*
- 01120 Microbial metabolism in diverse environments
- 01130 Biosynthesis of antibiotics
- 01200 Carbon metabolism
- 01210 2-Oxocarboxylic acid metabolism
- 01212 Fatty acid metabolism
- 01230 Biosynthesis of amino acids
- 01220 Degradation of aromatic compounds

1.1 Carbohydrate metabolism

- 00010 Glycolysis / Gluconeogenesis
- 00020 Citrate cycle (TCA cycle)
- 00030 Pentose phosphate pathway
- 00040 Pentose and glucuronate interconversions
- 00051 Fructose and mannose metabolism
- 00052 Galactose metabolism
- 00053 Ascorbate and aldarate metabolism
- 00500 Starch and sucrose metabolism
- 00520 Amino sugar and nucleotide sugar metabolism
- 00620 Pyruvate metabolism
- 00630 Glyoxylate and dicarboxylate metabolism
- 00640 Propanoate metabolism
- 00650 Butanoate metabolism
- 00660 C5-Branched dibasic acid metabolism
- 00562 Inositol phosphate metabolism

1.2 Energy metabolism

- 00190 Oxidative phosphorylation
- 00195 Photosynthesis
- 00196 Photosynthesis - antenna proteins
- 00710 Carbon fixation in photosynthetic organisms
- 00720 Carbon fixation pathways in prokaryotes
- 00680 Methane metabolism
- 00910 Nitrogen metabolism
- 00920 Sulfur metabolism



<https://www.kegg.jp/kegg/pathway.html>



基因注释和功能富集



GO/KEGG富集分析

由于GO/KEGG中每种功能类别/代谢途径中的背景基因数量不同，因此基因的绝对数量不能用来衡量基因在某种类别中的富集程度，需要通过统计算法来进行富集分析。

问题：在哪个类别中更富集？

	某物种所有基因	候选基因集
GO类别1	1000	50
GO类别2	10	5



DAVID Bioinformatics Resources

**DAVID Bioinformatics Resources 6.8**
Laboratory of Human Retrovirology and Immunoinformatics (LHRI)

[Home](#) [Start Analysis](#) [Shortcut to DAVID Tools](#) [Technical Center](#) [Downloads & APIs](#) [Term of Service](#) [About DAVID](#) [About LHRI](#)

Overview

The **D**atabase for **A**nnotation, **V**isualization and **I**ntegrated **D**iscovery (**DAVID**) v6.8 [comprises a full Knowledgebase update to the sixth version](#) of our original web-accessible programs. DAVID now provides a comprehensive set of functional annotation tools for investigators to understand biological meaning behind large list of genes. For any given gene list, DAVID tools are able to:

Hot Links

 **Multiple research positions available in LHRI** 
The Laboratory of Human Retrovirology and Immunoinformatics (LHRI) is a translational research laboratory (Bench-to-Bed side research) under the Clinical Services Program in Applied and Development Research Directorate. Researchers in the LHRI

Systematic and integrative analysis of large gene lists using DAVID bioinformatics resources

[BT Sherman](#), RA Lempicki - Nature protocols, 2009 - nature.com

DAVID bioinformatics resources consists of an integrated biological knowledgebase and analytic tools aimed at systematically extracting biological meaning from large gene/protein lists. This protocol explains how to use DAVID, a high-throughput and integrated data-mining environment, to analyze gene lists derived from high-throughput genomic experiments. The procedure first requires uploading a gene list containing any number of common gene identifiers followed by analysis using one or more text and pathway-mining ...

★  Cited by 26197 Related articles All 12 versions

Bioinformatics enrichment tools: paths toward the comprehensive functional analysis of large gene lists

[DW Huang](#), [BT Sherman](#), RA Lempicki - Nucleic acids research, 2009 - academic.oup.com

Functional analysis of large gene lists, derived in most cases from emerging high-throughput genomic, proteomic and bioinformatics scanning approaches, is still a challenging and daunting task. The gene-annotation enrichment analysis is a promising high-throughput strategy that increases the likelihood for investigators to identify biological processes most pertinent to their study. Approximately 68 bioinformatics enrichment tools that are currently available in the community are collected in this survey. Tools are uniquely categorized into ...

☆  Cited by 10862 Related articles All 27 versions

<https://david.ncifcrf.gov>



DAVID Bioinformatics Resources

DAVID Bioinformatics Resources 6.8
Laboratory of Human Retrovirology and Immunoinformatics (LHRI)

Home | Start Analysis | Shortcut to DAVID Tools | Technical Center | Downloads & APIs | Term of Service | Why DAVID? | About Us

Shortcut to DAVID Tools

- Functional Annotation** (功能注释)
- Gene Functional Classification** (功能分类)
- Gene ID Conversion** (基因ID转换)
- Gene Name Batch Viewer** (基因名称查阅)

Upload Gene List

Demolist 1 Demolist 2
Upload Help

Step 1: Enter Gene List
A: Paste a list
基因ID列表
Clear

Or
B: Choose From a File
ID列表文件
Multi-List File

Step 2: Select Identifier
AFFYMETRIX_3PRIME_IVT_ID
选择ID类型

Step 3: List Type
Gene List
Background

Step 4: Submit List
Submit List

Gene List Manager

Select to limit annotations by one or more species Help

- Use All Species -
Homo sapiens(149)
Unknown(15)
Select Species

List Manager Help
demolist1

Select List to:
Use Rename
Remove Combine
Show Gene List
View Unmapped Ids

Annotation Summary Results

Current Gene List: demolist1
Current Background: Homo sapiens
145 DAVID IDs
Check Defaults

☒ Disease (1 selected)
☒ Functional_Categories (3 selected)
☒ Gene_Ontology (3 selected)
☐ General_Annotations (0 selected)
☐ Literature (0 selected)
☐ Main_Accessions (0 selected)
☒ Pathways (3 selected)
☒ Protein_Domains (3 selected)
☐ Protein_Interactions (0 selected)
☐ Tissue_Expression (0 selected)

Red annotation categories denote DAVID defined defaults

Combined View for Selected Annotation

Functional Annotation Clustering
Functional Annotation Chart
Functional Annotation Table

139 record(s) Download File

37166_at	3-hydroxyanthranilate 3,4-dioxygenase(HAAO)	Related Genes	Homo sapiens
GOTERM_BP_DIRECT	tryptophan catabolic process, response to zinc ion, quinolinate biosynthetic process, 'de novo' NAD biosynthetic process from tryptophan, anthranilate metabolic process, response to cadmium ion, quinolinate metabolic process, oxidation-reduction process, neuron cellular homeostasis,		
GOTERM_CC_DIRECT	cytosol, extracellular exosome,		
GOTERM_MF_DIRECT	3-hydroxyanthranilate 3,4-dioxygenase activity, iron ion binding, protein binding, ferrous iron binding, electron carrier activity,		
INTERPRO	3-hydroxyanthranilic acid dioxygenase, RmlC-like cupin domain, RmlC-like jelly roll fold, 3-hydroxyanthranilate 3, 4-dioxygenase, azoan,		
KEGG_PATHWAY	tryptophan metabolism, Metabolic pathways,		
PIR_SUPERFAMILY	3-hydroxyanthranilate 3,4-dioxygenase, animal type,		
UP_KEYWORDS	3D-structure, Alternative splicing, Complete proteome, Cytoplasm, Dioxygenase, Iron, Metal-binding, Oxidoreductase, Polymorphism, Proteomics identification, Pyridine nucleotide biosynthesis, Reference proteome,		
UP_SEQ_FEATURE	binding site:Dioxygen, binding site:Substrate, chain:3-hydroxyanthranilate 3,4-dioxygenase, helix, metal ion-binding site:Iron; catalytic, sequence variant, splice variant, strand, turn,		

<https://david.ncifcrf.gov>



基因组注释

DAVID Bioinformatics Resources

Functional Annotation Clustering

[Help and Manual](#)

Current Gene List: demolist1

Current Background: Homo sapiens

145 DAVID IDs

Options Classification Stringency Medium

Rerun using options

Create Sublist

33 Cluster(s)

功能类别

基因数量 富集程度

[Download File](#)

Annotation Cluster 1		Enrichment Score: 5.37			Count	P-Value	Benjamini
☐	GOTERM_CC_DIRECT	extracellular space	RT		32	7.1E-9	1.2E-6
☐	GOTERM_CC_DIRECT	extracellular region	RT		32	4.1E-7	3.5E-5
☐	UP_KEYWORDS	Disulfide bond	RT		47	1.3E-6	3.5E-4
☐	UP_SEQ_FEATURE	signal peptide	RT		46	1.6E-6	1.0E-3
☐	UP_KEYWORDS	Secreted	RT		33	1.7E-6	2.3E-4
☐	UP_SEQ_FEATURE	disulfide bond	RT		42	1.9E-6	5.9E-4
☐	UP_KEYWORDS	Signal	RT		49	4.5E-5	4.1E-3
☐	UP_KEYWORDS	Glycoprotein	RT		50	2.2E-4	1.5E-2
☐	UP_SEQ_FEATURE	glycosylation site:N-linked (GlcNAc...)	RT		44	2.3E-3	3.7E-1

Functional Annotation Chart

[Help and Manual](#)

Current Gene List: demolist1

Current Background: Homo sapiens

145 DAVID IDs

Options

Rerun Using Options

Create Sublist

220 chart records


[Download File](#)

Sublist	Category	Term	RT	Genes	Count	%	P-Value	Benjamini
☐	GOTERM_CC_DIRECT	extracellular space	RT		32	22.1	7.1E-9	1.2E-6
☐	GOTERM_CC_DIRECT	extracellular region	RT		32	22.1	4.1E-7	3.5E-5
☐	UP_KEYWORDS	Disulfide bond	RT		47	32.4	1.3E-6	3.5E-4
☐	UP_SEQ_FEATURE	signal peptide	RT		46	31.7	1.6E-6	1.0E-3
☐	UP_KEYWORDS	Secreted	RT		33	22.8	1.7E-6	2.3E-4
☐	UP_SEQ_FEATURE	disulfide bond	RT		42	29.0	1.9E-6	5.9E-4
☐	UP_KEYWORDS	Signal	RT		49	33.8	4.5E-5	4.1E-3
☐	GOTERM_BP_DIRECT	defense response to fungus	RT		5	3.4	5.6E-5	5.6E-2

明德至诚 博学远志




基因组注释



Original database/resource where the terms orient

Enriched terms associated with your gene list

Related



EASE Score, the modified Fisher Exact P-Value. They are identical to that in the Chart Report. The smaller, the more enriched.



基因组注释

|



总结

基因组测序 DNA-seq

- Read 比对算法BWT

基因组变异

- 基因组 (Whole genome duplication)
- 染色体 (Chromosome abnormality)
- 基因 (Gene gain and loss)
- 碱基 (Point mutation)

基因组注释

- 基因组注释：结构注释、功能注释
- 基因组注释：原核生物、真核生物
- 结构预测：软件预测、同源预测、转录本预测
- 功能预测：基因本体GO、代谢KEGG、功能富集分析、DAVID