



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING


生物信息学

熊壮 博士

医工交叉研究院

Interdisciplinary Institute for Medical Engineering

bioinformatics_fzu@163.com



明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

生物信息学

第四章 多组学分析-转录组学

明德至诚 博学远志



1. RNA及转录组概论
2. 转录组测序
3. 基因表达定量
4. 差异表达分析
5. 基于多组学数据的疾病分类



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

1. RNA及转录组概论


明德至诚 博学远志



RNA及转录组概论

RNA


- 核糖核酸（缩写为RNA，即Ribonucleic Acid），存在于生物细胞以及部分病毒、类病毒中的遗传信息载体。
- RNA由核糖核苷酸经磷酸二酯键缩合而成长链状分子。
- RNA的碱基有四种，即A腺嘌呤、U尿嘧啶、G鸟嘌呤、C胞嘧啶，其中，U取代了DNA中的T。





RNA及转录组概论

RNA






RNA及转录组概论

RNA与DNA区别

项目	DNA	RNA
名称	脱氧核糖核酸 DeoxyriboNucleic Acid	核糖核酸 Ribonucleic Acid
五碳糖种类	脱氧核糖	核糖
骨架结构	双螺旋结构	单链结构
碱基种类	腺嘌呤 (A) 胸腺嘧啶 (T) 胞嘧啶 (C) 鸟嘌呤 (G)	腺嘌呤 (A) 尿嘧啶 (U) 胞嘧啶 (C) 鸟嘌呤 (G)
五碳糖2位 碳连接组分	氢原子	羟基
存在	细胞核 (少量存在于线粒体、叶绿体)	细胞质

RNA与DNA结构、碱基组成





RNA发现史

RNA领域重要发现

- 1868年，Friedrich Miescher首次在真核细胞核中发现
- 1939年，Torbjörn Caspersson 发现RNA在蛋白质合成中扮演重要角色
- 1967年，**Carl Woese**提出**RNA世界学说**，指出最早的生命形式可能依赖于RNA，携带遗传信息和催化生化反应
- 1976年，Walter Fiers确定RNA病毒完整基因组碱基序列

RNA研究相关诺贝尔奖

年份	获奖原因
1959	发现RNA和DNA的生物合成机制
1968	发现tRNA
1975	发现逆转录病毒及逆转录酶
1989	发现RNA具有催化特性*
1993	发现RNA剪接
2006	发现RNA干扰现象
2009	解析核糖体（Ribosome）的结构与功能*
2023	mRNA新冠疫苗

*诺贝尔化学奖



RNA及转录组概论

三个老爸实验室吖 bilibili



下面张图



RNA及转录组概论

RNA世界假说


- **RNA世界假说 (RNA world hypothesis)**：认为RNA是地球早期生命分子，这些早期RNA分子同时拥有**DNA遗传信息储存功能**，及**蛋白质的催化能力**，从而支持早期细胞或前细胞生命的运作。
 - 1962年，Alexander Rich首次提出RNA世界的类似想法
 - 1968年，**卡尔·沃斯**在《遗传密码》建立RNA生命型态的概念
 - 1986年，诺奖得主**沃特·吉尔伯特** (Walter Gilbert) 正式提出
- **RNA 作为酶**
 - 可自我复制
 - 可催化简单化学反应
 - 可催化肽键形成
- **RNA 作为信息存储介质**
 - 比较脆弱，易水解
 - 不稳定，变异可能性大
- **RNA作为调控物质**
 - 核糖开关 (Riboswitch)：基因表达的调控物质之一，在细菌、植物和古菌中发现，改变其二级结构以响应所结合的代谢物，从而影响转录
 - RNA温度计 (RNA thermometer)：受温度变化而调节基因表达



RNA及转录组概论

RNA thermometer


- RNA温度计 (RNA thermometer) 是一类**对温度敏感的非编码RNA**，能**随温度变化调控基因表达**。主要调控与**热休克和冷休克**反应有关的基因，与致病性、饥饿状态等过程相关的基因调控也有关系。
- **二级结构随温度变化而改变**，使RNA上核糖体结合位点 (RBS) 等重要区域暴露或遮蔽，**进而改变对应编码基因的翻译速率**。
- 一般认为，在早期的RNA世界中，RNA温度计的作用是对其他的RNA分子进行**温度依赖性的调控**。在现代生物中，RNA温度计可以说是一个RNA世界的良好分子化石。





RNA及转录组概论

RNA World



<https://ib.bioninja.com.au/standard-level/topic-1-cell-biology/15-the-origin-of-cells/rna-world-hypothesis.html>




RNA及转录组概论

RNA复杂性

- 遗传信息传递与功能执行载体
- RNA生命动态
 - ✓ RNA合成
 - ✓ 调控
 - ✓ 加工修饰
 - ✓ 转运
 - ✓ 降解
 - ✓ 逆转录
- RNA类型与功能多样
- 与多种生物大分子存在交互作用

转录组 (Transcriptome)：所有转录产物的集合，包括信使RNA、核糖体RNA、转运RNA及非编码RNA。

RNA组：全生命周期合成的RNA分子和共价结构集合




明德至诚 博学远志



RNA及转录组概论

RNA主要类型

- 在细胞生物中，mRNA为遗传讯息的传递者，指导蛋白质合成，被称为**编码RNA** (coding RNA)
- 没有编码蛋白质能力的RNA则被称为**非编码RNA** (non-coding RNA)
- 非编码RNA通过催化生化反应，或调控、参与基因表达过程而发挥相应的生理功能
- 功能：蛋白合成、调控、修饰、复制等



Current Biology



RNA代表类型及功能

RNA类型	缩写	功能
Messenger RNA (信使RNA)	mRNA	蛋白编码
Ribosomal RNA (核糖体RNA)	rRNA	核糖体结构功能组成部分
Transfer RNA (转运RNA)	tRNA	翻译过程中接附氨基酸
MicroRNA (微RNA)	miRNA	mRNA降解与翻译抑制
Long non-coding RNA (长非编码RNA)	lncRNA	基因调控
Small interfering RNA (小分子干扰RNA)	siRNA	转录后基因沉默
Circular RNA (环形RNA)	circRNA	基因调控
.....		

https://en.wikipedia.org/wiki/List_of_RNAs



RNA及转录组概论

非编码RNA

	Type	Length (nt)	Function
Small ncRNAs (<200 nt)	MicroRNA (miRNA)	18–22	RNAi; Protein translation regulation
	Small interfering RNA (siRNA)	20–25	RNAi; Antiviral defense
	Piwi RNA (piRNA)	26–31	Regulation of transposable elements
	Trans-activating CRISPR (tracr) RNA	~65	CRISPR/Cas adaptive immunity in bacteria
	Small nuclear RNA (snRNA)	100–300	Intron splicing; RNA processing
	U-rich snRNA (snRNA)	100–300	snRNA subclass; intron splicing
	Small nucleolar RNA (snoRNA)	60–200	rRNA processing
	Signal recognition particle RNA (7SL)	300	RNA component of the signal recognition particle; protein synthesis
	Y RNAs	80–120	Components of ribonucleoproteins; DNA replication & RNA processing
	Small Cajal body-specific RNA (scaRNA)	200–300	Biogenesis of small nuclear ribonucleoproteins
Long ncRNAs (>200 nt)	Long intergenic ncRNA (lincRNA)	1 kb	Protein scaffolding
	Natural antisense transcript (NAT)	>200	RNAi, alternate splicing, genome imprinting
	Circular RNA (circRNA)	100–999	miRNA decoy, protein regulation
Housekeeping ncRNAs	Ribosomal RNA (rRNA)	>1,500	Protein synthesis
	Transfer RNA (tRNA)	76–90	Protein synthesis

<https://www.bio-rad.com/en-uk/applications-technologies/coding-non-coding-rna?ID=Q1070M70KWE7>

明德至诚 博学远志



RNA及转录组概论

RNAs in human

Table 1. Human Genes

Class	Abbreviation	Function	Estimated Number
Messenger RNA	mRNA	protein coding	20,078 ^a
Ribosomal RNA	rRNA	structural and functional component of ribosome	531 ^a
Transfer RNA	tRNA	translational adaptor molecule	512 ^b
Small nuclear RNA	snRNA	processing of pre-mRNA	1,923 ^a
Small nucleolar RNA	snoRNA	processing of rRNA, tRNA, and snRNA	1,529 ^a
Antisense RNA	aRNA	gene regulation	4,424 ^a
Long noncoding RNA	lncRNA	gene regulation	12,933 ^a
MicroRNA	miRNA	translational inhibition and mRNA degradation	>500 ^c
Small interfering RNA	siRNA	posttranscriptional gene silencing	n/a ^d
Piwi-interacting RNA	piRNA	protect genome integrity	n/a ^e
Enhancer RNA	eRNA	unknown	variable ^f

^aGENCODE (Harrow et al., 2012).

^bHGNC database (Seal et al., 2011; <http://www.genenames.org>).

^c2,000–3,000 putative miRNA have been annotated (Harrow et al., 2012), but the majority are not validated.

^dHuman endogenous siRNA are rare and have not been systematically identified.

^ePiwi-interacting RNA (piRNA) have not been systematically identified, although estimates indicate that hundreds of piRNAs are derived from each of more than 100 loci (Aravin et al., 2006; Brennecke et al., 2007; Girard et al., 2006).


^fEnhancer RNAs (eRNAs) are generated from active enhancers, thus the number of eRNAs depends on the set of active enhancers in a cell (Kim et al., 2010; Wang et al., 2011). Current estimates indicate that 25%–80% of active enhancers generate eRNAs.



RNA及转录组概论

信使RNA (Messenger RNA)

- **信使RNA (mRNA)**：单链RNA，携带遗传信息，利用遗传密码将每个碱基三联体（或密码子）翻译成相应氨基酸，将遗传信息从DNA传递到核糖体，指导蛋白质合成
- mRNA占细胞总RNA的2%~5%，种类多，代谢活跃，半衰期短，合成后数分钟至数小时即被分解






RNA及转录组概论

核糖体RNA (Ribosomal RNA)

- **核糖体RNA (rRNA)**，转录自核糖体DNA，分子质量大，结构复杂，是细胞内含量最多的一类RNA，占RNA总量的82%左右
- 功能为**在mRNA的指导下将氨基酸合成为肽链**，rRNA与多种蛋白质结合成**核糖体 (Ribosome)**，作为**蛋白质生物合成的“装配机”**

生物种类	类型	大亚基	小亚基
原核生物	70S	50S (5S: 120nt, 23S: 2906nt)	30S (16S: 1542nt)
真核生物	80S	60S (5S: 121nt, 5.8S: 156nt, 28S: 5070nt)	40S (18S: 1869nt)

S: 沉降系数 (斯韦德伯格Svedberg单位)，S为大分子物质在超速离心沉降中的一个物理学单位，可间接反映分子量的大小。



Three-dimensional views of the ribosome, showing rRNA in dark blue (small subunit) and dark red (large subunit).

Lighter colors represent ribosomal proteins.

https://en.wikipedia.org/wiki/Ribosomal_RNA


明德至诚 博学远志




RNA及转录组概论

转运RNA (Transfer RNA)

- **转运RNA (tRNA)**，由70-90个核苷酸组成，折叠成三叶草形状
- **氨酰-tRNA合成酶**催化tRNA 3'端接附特定种类氨基酸
- 翻译过程中，tRNA**反密码子**识别mRNA的**密码子**，将密码子所对应**氨基酸转运至核糖体合成多肽链**
- 由于**遗传密码简并性**，存在多种tRNA与一种氨基酸接附现象
- 1968年，罗伯特·W·霍利因其首次分离tRNA，并阐明其序列与结构而获得诺贝尔生理学或医学奖




Common ways of illustrating tRNA





RNA及转录组概论

蛋白合成：mRNA、rRNA、tRNA





RNA及转录组概论

微小RNA (miRNA)


微小RNA (microRNA, miRNA)

内生小非编码RNA分子, ~22 nt


• miRNA大多具有茎环结构, 其加工过程包括三个阶段:

- ✓ 原始pri-miRNA (300~1000nt)
- ✓ 前体pre-miRNA (70~90nt)
- ✓ 成熟miRNA (20~24nt)

• **miRNA在RNA沉默和基因表达转录后调控中发挥作用**, 通过与mRNA互补配对, 诱导mRNA链被切割, 或促使mRNA缩短其poly(A)尾巴而降低稳性, 或降低mRNA翻译成蛋白质的效率



动植物、病毒
红色部分显示成熟
miRNA



明德至诚 博学远志



RNA及转录组概论


miRNA: from biology to cancer

miRNA的功能

生物学过程	代表性miRNA	靶基因/功能
细胞增殖	miR-21	抑制PTEN (促癌)
凋亡	miR-34	抑制BCL-2 (促凋亡)
分化	let-7	抑制RAS (抑制干细胞特性)
免疫	miR-155	调控炎症反应
代谢	miR-122 (肝脏特异)	维持胆固醇稳态

致癌miRNA (OncomiR) : 如miR-21 (抑制抑癌基因)、miR-17-92簇 (促增殖)。

抑癌miRNA (TS-miRNA) : 如miR-34 (激活p53通路)、let-7 (抑制RAS)。



明德至诚 博学远志




RNA及转录组概论

长非编码RNA (lncRNA)

- 长链非编码RNA (Long non-coding RNA, lncRNA) 是长度大于200个核苷酸的非编码RNA
- 在表观遗传调控、细胞周期调控和细胞分化调控等众多生命活动中发挥重要作用，是目前研究热点

lncRNA分类

- 反义长lncRNA
- 内含子lncRNA
- 基因间lncRNA
- 启动子相关lncRNA
- 非翻译区lncRNA



95243 lncRNA genes & 323950 transcripts in human (LncBook数据库)

Front. Genet., 15 October 2018 |
<https://doi.org/10.3389/fgene.2018.00471>

明德至诚 博学远志



RNA及转录组概论


LncRNA与染色体失活



毛色：黑色、橙色、白色

雌性三色猫的斑驳毛色是X失活的表现

Xist (~17kb), involved in X inactivation (Nature 1991)




Xist包覆失活的X染色体，抑制基因表达使其成为异染色质



RNA及转录组概论

小干扰RNA (siRNA)

- 小干扰RNA (Small interference RNA, siRNA), 也称短干扰RNA或沉默RNA, 是一类双链非编码RNA分子, 长度为20-25个核苷酸对
- 与miRNA相似, siRNA在RNA干扰(RNA interference, RNAi)通路中起作用
- siRNA干扰具有互补核苷酸序列的特定基因的表达, 降解转录后mRNA, 从而阻止蛋白翻译过程





RNA及转录组概论

RNA干扰 (RNAi)

- RNA干扰 (RNA interference, RNAi) 是指一种分子生物学上由双链RNA诱发的基因沉默现象，其机制是通过阻碍特定基因的转录或翻译来抑制基因表达。
- RNAi机制普遍存在于动植物，尤其是低等生物中，被认为是进化上相对保守的基因表达调控机制
- 1990年Jorgensen研究查尔酮合成酶对花青素合成速度的影响，得到了白色和白紫杂色的矮牵牛花。
- 1992年，Romano和Macino在粉色面包霉菌中发现外源导入基因可抑制具有同源序列的内源基因表达。
- 1998年，Fire和Mello在线虫中发现，双链RNA相比正义或反义RNA显示出了更强的抑制效果 (*Nature* 1998)。



矮牵牛花中所观察到的RNA干扰现象



Andrew Fire
(1959-) Stanford



Craig Mello
(1960-) UMass

2006 Nobel Prize in Physiology or Medicine


明德至诚 博学远志



RNA及转录组概论

环形RNA (circRNA)

- **环形RNA** (Circular RNA) 是一种单链RNA，分子呈封闭环状结构，表达稳定，不易降解，是RNA领域最新研究热点
- 功能上，circRNA分子富含miRNA结合位点，在细胞中起到**miRNA海绵** (miRNA sponge) 的作用，可解除miRNA对其靶基因的抑制作用，称为竞争性内源RNA (ceRNA) 机制
- 人类：768986 circRNAs (circAtlas数据库)



Circular RNA biogenesis

A. mRNA splicing, with alternative splice variants. All mRNAs have cap and polyA tail


B. CircRNA formation via backsplicing

明德至诚 博学远志



RNA及转录组概论

Coding and noncoding RNAs



Noncoding RNA:RNA Regulatory Networks in Cancer.
International Journal of Molecular Sciences 2018

明德至诚 博学远志




RNA及转录组概论

RNA合成（转录Transcription）

转录：在RNA聚合酶（RNA Polymerase）的催化作用下，遗传信息由DNA到RNA的过程，一般分为**启动、延伸、终止**三个阶段

- **启动：**转录起始于RNA聚合酶和通用转录因子与启动子的结合
- **延伸：**转录启动后，DNA双螺旋链解开，RNA聚合酶以其中一条DNA链作为模板链。RNA聚合酶以3' -5' 端的方向读取模板链，并以5' -3' 端的方向合成与之反向平行互补的RNA链，也称转录本（Transcript）
- **终止：**转录终止于DNA非编码序列末端附近的终止子处





RNA及转录组概论

转录调控

- **转录调控 (Transcriptional regulation)**：指通过改变转录效率从而调控RNA转录本表达水平的过程。转录调控可以控制基因的**时空动态表达**。原核与真核生物具有不同的转录调控机制。
- **顺式作用元件 (cis-regulatory elements, CRE)**：位于基因旁侧序列中能影响基因表达的DNA序列，可影响基因转录活性。
- **反式作用元件 (trans-regulatory elements, TRE)**：转录模板上游基因编码的一类蛋白调节因子，又称转录因子(Transcription Factors)，通过与特异的顺式作用元件相互作用反式激活基因转录，分为两类：①**通用转录因子**：所有mRNA转录启动共有。②**特异转录因子**：个别基因转录所必需，决定基因的时空特异性表达。

CRE are present on the same molecule of DNA as the gene they regulate, whereas TRE can regulate genes distant from the gene from which they were transcribed.



RNA及转录组概论

原核生物转录调控


• 原核生物转录调控规律

- 营养和环境因素影响转录调控
- 多个基因可位于同一转录单元上，称为**操纵子** (operon)
- 同一操纵子中基因受到相同的转录调控，翻译过程相互独立

• 原核生物转录调控机制类型

- 代谢产物对基因活性的调节
- 弱化子对基因活性的调节
- 降解物对基因活性的调节
- 细菌的应激反应

乳糖操纵子基本结构及调控过程




明德至诚 博学远志



RNA及转录组概论

真核生物转录调控

真核转录调控示意图



<http://bruneaulab.gladstone.org/transcriptional-regulation>

真核生物转录调控特点

- 几种调控水平相互作用：**局部调控**特定细胞单个基因的打开或关闭，**全局调控**维持染色质水平的基因表达模式
- 转录调控元件包括**顺式元件**及**反式因子**，作用方式更为复杂
- **通用转录因子**和**RNA聚合酶**组成基础转录复合体，**转录激活因子**和**阻遏因子**与其作用激活或抑制转录
- **增强子**远离其所控制基因，与转录激活因子结合增强基因转录。**沉默子**作为负调控序列，与阻遏因子结合，抑制基因转录


明德至诚 博学远志



RNA及转录组概论

转录因子

- **Transcription Factor (TF):** a type of protein that binds to a specific DNA sequence and regulates gene transcription—**turn on & off**—that gene are **expressed at the right time and in the right amount**.
 - ✓ There are **1665** TFs and **1025** TF cofactors in the human genome (AnimalTFDB as of Mar 2025).
 - ✓ Only a subset of TFs may be expressed in a given cell at a given time point.
 - ✓ TFs are essential for gene expression regulation in all living organisms.
 - ✓ TFs are of clinical significance because TF mutations can cause specific diseases, and medications can be potentially targeted toward them.
- **Transcription Factor Binding Sites (TFBS):** 4-20bp short DNA sequences where TFs bind.
 - ✓ There are millions of TF binding sites in the human genome.





RNA及转录组概论

转录后加工与修饰

真核细胞中，将初级RNA转录本转化为成熟RNA的加工过程

加工修饰类型

- 5'端加帽 (5' Capping)
- 3' 端加尾 (Cleavage and polyadenylation)
- 剪接 (Splicing)
- 化学修饰 (Chemical modification)
- 编辑 (Editing)





RNA及转录组概论

mRNA加工

mRNA加工 (mRNA Processing): 将初级mRNA转化为成熟RNA的加工过程，发生在细胞核中mRNA翻译之前，包括**5'端加帽**、**3'端多聚腺苷酸化**、**RNA剪接**

- 5'端加帽 (5' Capping): 在mRNA前体5'端加上7-甲基鸟苷 (m7G)
- 3'端加尾 (Cleavage and polyadenylation): 对mRNA前体3' 端进行切割，随后加上约200个腺嘌呤残基以形成多聚腺苷酸尾 (poly A tail)






RNA及转录组概论

Regulation of poly(A) tail length

- Poly(A) tail length plays an essential role in **regulating mRNA metabolism**.
- Poly(A) tail length is regulated in a **gene-specific manner**—mRNAs with **short half-lives** in general have **long poly(A) tails**, while **mRNAs with long half-lives** are featured with relatively **short poly(A) tails**.
- Across species, poly(A) tails in the nucleus are almost twice as long as in the cytoplasm.






RNA及转录组概论

RNA剪接

RNA剪接 (RNA Splicing)：将非编码内含子从RNA前体上除去，将外显子拼接在一起的加工过程

- **剪接体 (Spliceosome)**：由识别位于mRNA前体序列剪接位点的蛋白质和小核RNA (snRNA)聚合而成
- **RNA剪接反应**：由剪接体蛋白复合物催化，可发生在RNA前体合成加帽后及转录过程中
- **可变剪接 (Alternative Splicing)**：mRNA前体以多种方式被剪接，产生编码不同蛋白质序列的成熟mRNA






RNA及转录组概论

单基因转录模式的多样性

可变剪接 (alternative splicing, AS, 选择性剪接)：在 mRNA 前体到成熟 mRNA 的过程中，不同的剪切方式使得**同一个基因可以产生多个不同的成熟 mRNA**，最终产生不同的蛋白质。

在真核生物体内广泛存在，人类基因组中95%的基因都存在可变剪接现象，导致**转录本和蛋白质结构与功能的多态性**，是一种**重要的转录调控机制**。









RNA及转录组概论

RNA化学修饰

- RNA化学修饰 (Chemical Modification) : RNA分子合成后发生的化学组分变化, 具有**改变RNA结构、功能和稳定性**等作用
- 目前已知的RNA化学修饰类型包含**100多种**, 代表示例: m6A, m5C, Ψ , m7G



<https://mods.ma.albany.edu>




明德至诚 博学远志




RNA及转录组概论

RNA编辑


- RNA编辑 (RNA editing) 对RNA分子内特定核苷酸序列进行修饰的分子过程, 包括核苷酸的插入、删除和碱基替换
- 存在于真核生物、原核生物、病毒的一些tRNA、rRNA、mRNA或miRNA分子中
- 发生在细胞核和胞浆内, 也发生在线粒体和质体内
- 由对应编辑体 (Editosome) 介导



A-to-I RNA editing — immune protector and transcriptome diversifier. *Nat Rev Genet* 2018




Reference genome



DNA-seq reads



RNA-seq reads







■ A-to-I editing ■ Sequencing error ■ G Genomic SNP



RNA及转录组概论

RNA降解


- RNA分子的质量控制和**降解 (RNA Decay)** 对遗传信息的传递起着至关重要的作用
- mRNA具有不同的稳定性，其有限寿命使细胞快速改变蛋白质合成以响应变化需求
- 多种机制可导致mRNA降解。真核生物包括两条主要降解途径，皆由mRNA的**poly(A)尾缩短**引起。**3' 至5' 途径**，由外泌体多亚基复合体起关键作用。**5' 至3' 途径**，由5' 至3' 的外切酶降解转录本
- 细菌**核糖核酸内切酶E**为RNA降解关键酶
- 古细菌由**外泌体**介导RNA降解





RNA及转录组概论

RNA Interference with siRNA



RISC (RNA-induced silencing complex) will destroy the targeted mRNA, preventing translation of the associated gene.

siRNA is a double-stranded RNA molecule that is roughly 20 – 25 base pairs in length.

siRNA interferes with the expression of genes by causing the mRNA transcripts to be broken prior to translation

No translation



应用
功能鉴定
药物靶靶
疾病治疗

明德至诚 博学远志




RNA及转录组概论

RNA交互网络

RNA molecules play crucial roles in various biological processes. Their regulation and function are mediated by interacting with other molecules.


RNA-DNA



An R-loop is a **three-stranded** nucleic acid structure, composed of a **DNA:RNA hybrid** and the associated non-template **single-stranded DNA**.

Breaking bad: R-loops and genome integrity.
Trends in Cell Biology 2015


RNA-RNA



RNA-RNA interactions are important in **many basic cellular activities** including transcription, RNA processing, localization, and translation.

RNA granules: post-transcriptional and epigenetic modulators of gene expression.
Nature Reviews Molecular Cell Biology 2009

RNA-Protein



RNA granules contain various ribosomal subunits, translation factors, decay enzymes, helicases, scaffold proteins, and RNA-binding proteins.

明德至诚 博学远志




RNA及转录组概论

转录组 (Transcriptome)

- **转录组**：在某一特定条件下，**所能转录出的所有RNA的总和**，包括信使RNA (mRNA)、核糖体RNA (rRNA)、转运RNA (tRNA) 及非编码RNA；狭义上指细胞所能转录出的mRNA。
- 转录组可以被视为**蛋白质组的前体**，即由基因组表达的整组蛋白质。
- **转录组学**：研究在单个细胞或特定类型细胞、组织、器官或发育阶段的细胞群内所产生的**各类RNA分子的类型和数量**。

Transcriptome is the set of all RNA transcripts, including coding & non-coding.



明德至诚 博学远志



RNA及转录组概论

转录组的特点



- Transcriptome is highly **dynamic and complex** in comparison to the relatively stable genome.
- Transcriptome reflects the genes that are being **actively expressed at any given time—gene expression**.
- Understanding the transcriptome is essential for interpreting the functional elements of the genome and revealing the molecular constituents of cells and tissues, and also for understanding development and disease.
- The key aims of transcriptomics are:
 - to **catalogue all transcripts**, including mRNAs, non-coding RNAs and small RNAs;
 - to **determine the transcriptional structure of genes**, in terms of their start sites, 5' and 3' ends, splicing patterns and other post-transcriptional modifications;
 - to **quantify the changing expression levels** of each transcript during development and under different conditions.




RNA及转录组概论

转录组研究方法

Microarray: Hybridization-based



RNA-seq: sequencing-based



Short-read cDNA
Long-read cDNA
Long-read Direct

1995 Gene expression profiling using spotted cDNA microarray: expression levels of known genes

2002 Affymetrix, whole genome expression profiling using tiling array: identifying and profiling novel genes and splicing variants


2008 many groups, mRNA-seq: direct sequencing of mRNAs using next generation sequencing techniques (NGS)

明德至诚 博学远志



RNA及转录组概论


Microarray



双色寡核苷酸基因芯片



DNA microarray used to detect gene expression in a human (left) and a mouse (right)



明德至诚 博学远志



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

2. 转录组测序

明德至诚 博学远志



What is RNA-seq?

RNA-seq利用高通量测序技术来检测组织或细胞在特定状态中所有的转录产物

nature reviews genetics

Explore content ▾ About the journal ▾ Publish with us ▾ Subscribe

[nature](#) > [nature reviews genetics](#) > [innovation](#) > article

Innovation | Published: January 2009

RNA-Seq: a revolutionary tool for transcriptomics

[Zhong Wang](#), [Mark Gerstein](#) & [Michael Snyder](#)

[Nature Reviews Genetics](#) **10**, 57–63 (2009) | [Cite this article](#)

222k Accesses | 8938 Citations | 229 Altmetric | [Metrics](#)

- also called "Whole Transcriptome Shotgun Sequencing" ("WTSS")
- refers to the use of high-throughput sequencing technologies
- sequence cDNA to get information about a sample's RNA content
- a powerful tool to detect the whole transcriptome in cell and tissue



转录组测序 (RNA-sequencing)

- ◆ **转录组测序又称RNA测序** (RNA Sequencing, RNA-seq) , 就是把mRNA和 non-coding RNA (ncRNA) 全部或者其中一些用高通量测序技术进行测序分析的技术, 是一种基于二代测序技术研究转录组学的高通量测序方法
- ◆ 相比于传统的芯片方法, RNA-seq能够精确地定量转录本表达、**发现新转录本、识别可变剪接事件、检测基因融合**, 从而揭示不同条件下转录组的动态性
- ◆ RNA-seq具有背景噪音低、所需样品量少、灵敏度高等突出优点, 正逐渐取代芯片技术, 成为转录组分析的常规手段

融合基因: 指染色体重排过程中两个或多个不同基因的编码区首尾相连, 并被同一套调控序列 (如启动子、增强子等) 控制所构成的嵌合基因。融合基因可以编码异常的融合蛋白, 从而参与疾病的发生。




转录组测序

转录组测序 (RNA-sequencing)

RNA-seq可以发现新的转录本和可变剪切异构体，DNA芯片只能检测已知转录本的表达

RNA-seq比芯片的解析精度更高：单个碱基




明德至诚 博学远志



转录组测序

转录组测序基本流程




明德至诚 博学远志



转录组测序

RNA-seq 流程




◆ Step1: RNA样本的准备

- 从细胞或组织中提取RNA分子，然后根据实验目标选择特定类型的RNA分子
- mRNA-seq: 利用寡核苷酸磁珠富集poly(A)尾的RNA分子



转录组测序

RNA-seq 流程




◆ Step2: cDNA测序文库的构建

- 片段化: 将RNA分子打碎成200~500bp长的片段
- 将RNA片段反转录成cDNA
- 对cDNA片段进行末端修饰和接头添加, 并进行PCR扩增, 得到cDNA测序文库



RNA-seq 流程



◆ Step3: 高通量测序

- 对cDNA文库进行高通量测序，过程与DNA测序类似



转录组测序



RNA测序主要代表

二代测序



Illumina

Flowcell





Short read Sequencing

三代测序



Pacific Biosciences




Long read Sequencing

RNA直测



Oxford Nanopore




Direct Sequencing

明德至诚 博学远志




Microarray vs. RNA-seq



Microarray

- Explore changes in expression of known transcripts
- Dynamic range: 44-fold
- Simple data analysis, < 1G



RNA-seq

- Explore expression changes in known transcripts and find novel ones
- Dynamic range: 9,560-fold
- Complex data analysis, big data > 5G

Note: Dynamic range is the ratio between the maximum and minimum expression level.



转录组测序

Microarray



This animation will demonstrate how DNA microarray experiments are performed.

该动画将演示如何进行DNA微阵列实验。




明德至诚 博学远志



RNA-seq reads 比对

◆ RNA-seq 的reads比对是指将reads匹配到参考基因组或转录组的相应位置上，得到reads的基因组位置信息







转录组测序

RNA-seq reads 比对

◆ 非剪接比对

- 将reads比对到连续的基因组区域，**不考虑内含子 (intron)** 的剪接现象。
- 代表工具：Bowtie2, BWA
- 适用情况：**原核生物、比对到参考转录组**。研究的对象是人、小鼠或拟南芥等**注释信息相对完善**的物种，或者**只关注已知基因或转录本**的表达情况。






RNA-seq reads 比对

◆ 剪接比对

- 考虑到 reads匹配的基因区域可能会被内含子隔开而不连续，故在剪接位点附近的reads可能会部分比对到剪接点两侧外显子上，
 - 代表工具：STAR, HSAT2, TopHat2, GSNAP, MapSplice。（GSNAP 和 MapSplice在剪接比对的基础上专门对**鉴定SNP**进行了优化）
 - 适用情况：比配到**参考基因组**。
- 1、**构建剪接位点数据库**：使用已知注释（如GENCODE）或从头预测（de novo）识别潜在剪接位点。
 - 2、**分段比对（Split Alignment）**：将reads分成多个部分，分别比对到不同外显子，再通过剪接信号连接。
 - 3、**评分与过滤**：根据比对质量（如匹配得分、剪接信号强度）筛选可靠比对结果。





转录组测序

RNA-seq reads 比对


- ◆ reads来源于剪接后的转录组序列，但由于参考转录组信息不完善，当前研究通常是将reads比对到参考基因组，而不是参考转录组。这可能导致一些位于剪接区域的reads比对不准确。
- ◆ 由于测序错误引起的碱基插入、缺失、错配等现象使得reads比对更为复杂，影响比对结果的准确性。
- ◆ 在序列比对过程中，一个read可能比对到基因组的多个位置（多重匹配）。



转录组测序

转录组重建

- ◆ 利用reads定位信息推断出表达转录本的外显子结构，从而将比对的read组装成转录单元，最终确定所有表达的转录本的结构，这个过程被称为**转录组重建**。
- ◆ 转录组重建是转录本和基因表达定量的基础。
- ◆ 组装方法分为两类：**基因组引导法** (genome-guided) 和**基因组独立法** (genome-independent)





转录组重建

- ◆ 基因组引导法 (genome-guided) : 也叫**基于参考的转录组装配** (reference-based transcriptome assembly) , 首先根据read的基因组位置, 将重叠的read拼接成转录本片段, 然后利用位于剪接区域的read进行转录本结构刻画, 最后利用基因的已知注释信息对重构的转录本进行校正, 进而完成装配。
- ◆ 可以提高所构建转录本的敏感性和准确性; 可识别基因的新转录本。
- ◆ 常见软件有 **StringTie** 和 **cufflinks**。



转录组重建

- ◆ 基因组独立法 (genome-independent) : 也叫**从头装配**, 运用图论的思想, 基于reads之间的序列比对构建出de Bruijn图, 并根据图中的路径和reads的丰度确定转录本的结构, 从而完成转录本的装配。
- ◆ 可识别新的基因和新的转录本
- ◆ 代表性的软件有 **SOAPdenovo-Trans, Trans-ABYSS, Trinity**。



福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

3. 基因表达定量


明德至诚 博学远志



What is gene expression?

- Gene expression is the process by which information from a gene is used in the **synthesis of a functional gene product**.
- **Regulation of gene expression** refers to the **control of the amount and timing** of appearance of the functional product of a gene.
- Gene expression is the most fundamental level at **which the genotype gives rise to the phenotype**, i.e. *observable trait*.


转录组学也被称为“基因表达谱”，检测在一个特定条件下的RNA表达水平





基因表达定量

GTEx, Genotype-Tissue Expression



GTEx (基因型-组织表达研究联盟), 为研究遗传差异通过分子表型影响人类健康提供资源。收集并研究了来自948名生前健康的人类捐献者的17382多份尸检样本, 涵盖54个组织, 包括31个实体器官组织、13个脑分区、全血、两个来自捐献者血液和皮肤的细胞系。利用这些样本研究基因表达的组织 and 个体差异。



Science 348: 618, 640, 648, 660, and 666 (2015)

Nature 550: 190, 204, 239, 244, 249 (2017)

<https://gtexportal.org>

明德至诚 博学远志




基因表达定量

基因表达调控

- Regulation of gene expression includes **a wide range of mechanisms** that are used by cells to **increase or decrease** the production of gene products.
- Regulation of gene expression gives **control over the timing, location, and amount** of a given gene product present in a cell.
- Regulation of gene expression is the **basis** for development, morphogenesis, cellular differentiation, and the versatility and adaptability of any organism.
- Gene expression is regulated through **changes in the number and type of interactions between molecules** that collectively influence transcription of DNA and translation of RNA.

Regulate the **right genes**, at the **right time**,
in the **right cells**, and with the **right amount**.






基因表达定量

基因表达影响生物性状

2021.12, 华中农大高泽霞组提出无刺鱼的专利—斑马鱼

2022.10, 高泽霞组实验无刺武昌鱼, 敲除基因*Runx2b*


2023.01, 水生所桂建芳组和华农高泽霞—无刺鲫鱼



Creation of intermuscular bone-free mutants in amphitriploid gibel carp by editing two duplicated *runx2b* homeologs[J]. Aquaculture, 2023: 739300.

Human *RUNX2* – RUNX family transcription factor 2: a member of the RUNX family of transcription factors and encodes a nuclear protein with an Runt DNA-binding domain. This protein is essential for **osteoblastic differentiation and skeletal morphogenesis** and acts as a scaffold for nucleic acids and regulatory factors involved in **skeletal gene expression**.

<https://www.zhihu.com/question/507977981>



明德至诚 博学远志



基因表达定量


基因表达调控





基于RNA-seq的基因表达定量计算

- ◆ 通常RNA-seq利用**转录本匹配到的 reads 数**估算表达，比芯片技术的荧光信号更为精确。
- ◆ 对给定的基因组参考区域（如基因、转录本），计算比对上的read数，称为raw count (RC)，read count。





基于RNA-seq的基因表达定量计算

- ◆ reads 计数根据对多重比对reads（可能比对到基因组的多个位置）处理方式的不同分为两种策略:
 - ① 只选择唯一匹配reads计数
 - 将多重比对的reads舍弃，一般用于估计基因水平的reads匹配数。常用的工具具有 HTSeq-count 和 featureCounts。
 - ② 保留多重匹配的reads：
 - 利用统计模型将多重比对的reads定位到对应的转录本异构体上。常用工具包括 CufTlinks、StringTie 和 RSEM 等



基于RNA-seq的基因表达定量计算

- ◆ read counts 的数量会受到多种因素的影响
 - **基因长度**：在同一个样本中，基因越长，随机打断得到的片段就越多，该基因被测到的概率就越大，比对到该基因的reads 就越多。
 - **测序深度**：不同样本中，样本的测序深度越高，同一基因被测到的次数越多，比对到该基因的reads 就越多。
- ◆ 当我们进行基因差异表达的分析时，往往是在多个样本中比较不同基因的表达量，**如果不进行数据标准化，比较结果是没有意义的。**
- ◆ 因此，我们需要标准化的两个关键因素就是**基因长度**和**测序深度**。



基因表达定量

CPM

- ◆ CPM 全称 Counts Per Million mapped reads。
- ◆ 令 $Count_{ij}$ 和 $Count_{gj}$ 分别表示基因 i 和基因 g 在样本 j 中的 read count值, 则有

$$CPM_{ij} = \frac{Count_{ij} \times 10^6}{\sum_g Count_{gj}}$$

- ◆ 10^6 是标化因子 (Scale factor), 表示测序文库大小的数量级, 标化了测序深度的影响, 但没有考虑基因长度的影响
- ◆ CPM 适合于产生的read数不受基因长度影响的测序方法, 比如miRNA-seq测序, miRNA长度一般为20~24bp



基因表达定量

RPKM

- ◆ RPKM全称 Reads Per Kilobase Million 或 Reads Per Kilobase of exon model per Million mapped reads , 即 “**每一百万条Reads中, 对基因的每1000个Base而言, 比对到该1000个base的Reads数**”
- ◆ 令 $Count_{ij}$ 和 $Count_{gj}$ 分别表示基因 i 和基因 g 在样本 j 中的count值; L_i 表示基因 i 的长度 (单位为bp) ; N_j 表示样本 j 中的 count 总数, 则有

$$RPKM_{ij} = \frac{Count_{ij} \times 10^3 \times 10^6}{L_i \times \sum_g Count_{gj}} = \frac{Count_{ij}}{L_i \times N_j} \times 10^9$$

- ◆ 这里 $\frac{Count_{ij}}{L_i}$ 表示**每碱基的计数**(counts per base, **CPB**) , CPB会依赖于样本捕获的read总量, 因此通过除以count 总数来校正。



FPKM

- ◆ FPKM全称 Fragments Per Kilobase Million 或 Fragments Per Kilobase of exon model per Million mapped fragments。
- ◆ FPKM 与 RPKM 非常相似，只是 RPKM 用于 single-end 测序，而 FPKM 用于 pair-end 测序。
- ◆ 二代测序时，会将所有的 DNA 打成片段（fragment），然后再去测序。single-end 中，一个 fragment 对应一个 Read，而 pair-end 中，一个 fragment 会从两端分别测定一次，因此这两个配对 Read 对应的是同一fragment（偶尔也会有一个 fragment 只对应一个 Read 的情况，另一个 Read 因为某些原因被剔除或丢失了）。因此，对于 FPKM 来说，比对到同一片段上的两个 Read 只会算作一个 fragment，也就是说 FPKM 是以Fragment 为准，不以 Read 数为准，但计算方式是完全一样的。



基因表达定量

FPKM

- ◆ 令 F_{ij} 和 F_{gj} 分别表示基因 i 和基因 g 在样本 j 中的fragment值; L_i 表示基因 i 的长度 (单位为 bp) ; N_j 表示样本 j 中的 fragment 总数, 则有

$$FPKM_{ij} = \frac{F_{ij} \times 10^3 \times 10^6}{L_i \times \sum_g F_{gj}} = \frac{F_{ij}}{L_i \times N_j} \times 10^9$$

- ◆ RPKM/FPKM 适用于基因长度波动较大的测序方法, 如lncRNA测序, lncRNA长度在200~100000 bp不等
- ◆ RPKM/FPKM与RPM/CPM的区别: 考虑了基因长度对read count的影响



基因表达定量

TPM

- ◆ TPM 全称 Transcripts Per Kilobase of exon model per Million mapped reads 或 Transcripts Per Million
- ◆ 令 $Count_{ij}$ 和 $Count_{gj}$ 分别表示基因 i 和基因 g 在样本 j 中的count值, L_i 表示基因 i 的长度 (单位为kbp), 则有

$$CPB_{ij} = \frac{Count_{ij}}{L_i}$$

$$TPM_{ij} = CPB_{ij} \times \frac{1}{\sum_g CPB_{gj}} \times 10^6 = \frac{(Count_{ij}/L_i)}{\sum_g (Count_{gj}/L_g)} \times 10^6$$

- ◆ CPB 依赖于样本捕获的 $read$ 总量, 因此通过除以样本的 CPB 之和来校正。
- ◆ TPM使用 CPB 之和作为文库校正因子的好处是考虑了不同样本间的基因长度的分布。因为 CPB 是一个对基因长度进行校正后的表达量单位, 所以 CPB 之和不会再带入基因长度的bias。因此, 如果需要比较的样本之间转录本分布不一致时 (例如不同物种RNA-seq的比较), 使用TPM是一个较佳的Normalization 方案。



基因表达定量

TPM vs RPKM

基因	长度 (bp)	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	100	300	400	500
Gene 2	500	700	750	800
Gene 3	1000	1000	1300	1800
Read 总数		2000	2450	3100

Step 1: Normalize for gene length

基因	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	3	4	5
Gene 2	1.4	1.5	1.6
Gene 3	1	1.3	1.8
总和	5.4	6.8	8.4

TPM Step 2: Normalize for sequencing depth

基因	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1			
Gene 2			
Gene 3			

RPKM Step 2: Normalize for read depth

基因	样本A(10^6)	样本B(10^6)	样本C(10^6)
Gene 1			
Gene 2			
Gene 3			



基因表达定量

TPM vs RPKM

基因	长度 (bp)	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	100	300	400	500
Gene 2	500	700	750	800
Gene 3	1000	1000	1300	1800
Read 总数		2000	2450	3100

Step 1: Normalize for gene length

基因	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	3	4	5
Gene 2	1.4	1.5	1.6
Gene 3	1	1.3	1.8
总和	5.4	6.8	8.4

TPM Step 2: Normalize for sequencing depth

基因	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	0.56	0.59	0.60
Gene 2	0.26	0.22	0.19
Gene 3	0.19	0.19	0.21
总和	1.00	1.00	1.00


RPKM Step 2: Normalize for read depth

基因	样本A (10^6)	样本B (10^6)	样本C (10^6)
Gene 1	1.50	1.63	1.61
Gene 2	0.70	0.61	0.52
Gene 3	0.50	0.53	0.58
总和	2.70	2.78	2.71

明德至诚 博学远志




A sample RNA-Seq pipeline





RNA-seq分析核心策略





福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

4. 差异表达分析


明德至诚 博学远志



差异表达分析

差异表达分析的概念

- ◆ 差异表达分析的核心目标是**识别在不同实验条件下（如疾病 vs. 健康、处理 vs. 对照）表达水平发生显著变化的基因**。其本质是**统计建模**，通过比较不同组间的基因表达分布，判断差异是否具有**生物学意义而非技术误差**（组间差异大于组内差异）。



- 生物学重复
- 技术重复



差异表达分析


差异表达分析的概念

- ◆ 通过组内差异和组间差异的比较，就可以判断处理效应是否存在。显著与否还是要依赖于统计检验的结果。
- ◆ 差异表达分析的结果般用**差异倍数**(fold change)和**统计检验显著性值**来描述。
- ◆ 在转录组的基因差异表达分析中，一般的筛选标准是基因表达差异倍数大于2、并且 $FDR \leq 0.05$ 为显著差异的基因。



统计模型：负二项分布


- ◆ 由于二代数据得到的基因表达丰度是reads count，属于离散型分布，所以主流的方法是用负二项分布（属于离散型分布）模型进行检验。
- ◆ 主流差异分析软件edgeR、DESeq都采用负二项分布。



负二项分布的概率质量函数为：

$$P(X = k) = \binom{k + r - 1}{k} (1 - p)^r p^k$$

其中 r 和 p 参数化分布，或通过均值 μ 和离散参数 ϕ 表示方差 $\text{Var}(X) = \mu + \phi\mu^2$ 。



google scholar 40383次

明德至诚 博学远志



倍数法

实验条件下的表达均值

$$\text{Fold change} = \frac{\bar{x}_{case}}{\bar{x}_{control}}$$

对照条件下的表达均值

- ◆ 通常以**2倍**Fold change (FC)为阈值，判断基因是否差异表达
- ◆ 多数差异表达方法直接给出的是**log2(FC)**



倍数法

◆ 优缺点:

- 简单直接，早期常用，样本少，无统计意义
- 当基因表达水平的变化不大时，有可能找不到差异表达基因，假阴性率高；降低阈值，增大假阳性率。
- 极小值/极大值，如0.0002/0.0001无意义
- 无统计意义，目前主要用于大规模初筛或辅助其他方法使用。



T 检验

- ◆ T检验是对**两组样本的均值差**的检验。
- ◆ 适用于**两种实验条件**（两个组）下基因表达量的比较，要求基因表达服从**正态分布**。
- ◆ 运用 t 检验法可以判断基因在两个不同条件下的表达差异是否具有**统计显著性**。
- ◆ 零假设 $H_0: u_1 = u_2$ ，即某基因在两种不同条件下的**平均**表达水平相等。
- ◆ 对应的备择假设 $H_1: u_1 \neq u_2$ 。



T 检验

- ◆ 当两组样本相互独立，且两组方差相等（方差齐性）时，可以使用student-t检验方法比较两组差异

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s^2}{N_1} + \frac{s^2}{N_2}}}$$

$$S^2 = \frac{\sum (x - \bar{X}_1)^2 + \sum (x - \bar{X}_2)^2}{N_1 + N_2 - 2}$$

$$t = \frac{\text{两组均值之差}}{\text{这个均值差的标准误}}$$

- $\bar{X}_1$ 和 $\bar{X}_2$ 分别表示第1组和第2组样本的均值
- N_1 和 N_2 分别表示第1组和第2组的样本量
- S 是样本的标准差

- ◆ R语言实现: `t.test(x, y, alternative = "two.sided", var.equal = TRUE)`



T 检验

- ◆ 当两组样本相互独立，但两组方差不相等（方差不齐）时，可以使用校正的student-t检验方法，即Welch t检验比较两组差异

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{N_1} + \frac{S_2^2}{N_2}}}$$

- S_1 和 S_2 分别表示第1组
和第2组样本的标准差

- ◆ Welch t检验是一种相对保守安全的检验方法，一般默认选择该方法。
- ◆ 通常，除非组大小和标准差都非常不同，否则经典的student-t检验和Welch t检验的结果非常相似
- ◆ R语言实现： `t.test(x, y, alternative = "two.sided", var.equal = FALSE)`



T 检验

- ◆ 当**两组样本相互关联**（如同一组患者用药前后的表达数据），且两组**方差相等（方差齐性）**时，可以**配对样本t检验**。

$$t = \frac{\bar{D}}{S_D / \sqrt{N}}$$

- $\bar{D}$:样本差值的**均值**
- N :**样本量**
- S_D :样本差值的**标准差**

- ◆ R语言实现: `t.test(x, y, alternative = "two.sided", var.equal = TRUE, paired=TRUE)`



T 检验

- ◆ 结果解释：根据统计量 t 值，得到显著性水平 p 值，设定假设检验水平 α ，若 $p < \alpha$ ，则拒绝零假设，认为某基因在两个不同条件下的表达差异具有统计学意义。
- ◆ T 检验属于参数化检验方法，此类方法对数据分布有一定的假设，必要时需要首先检验样本分布是否符合该假设。
- ◆ 在进行T检验之前，最好首先检验数据是否为正态分布。如果数据不是正态分布的，建议使用非参数两样本Wilcoxon秩和检验。



秩和检验

- ◆ 如果**两组样本**来自两个**独立的**但**非正态分布或形态不清**的两总体，要检验两组样本之间的差异是否显著，不应运用参数检验中的T检验，而需采用**秩和检验**。
- ◆ R语言实现：**wilcox.test**(x, y = NULL, alternative = c("two.sided", "less", "greater"), paired = FALSE)



方差分析

- ◆ 方差分析是英国统计学家R.A.Fisher提出的对**两组或多组**样本**平均数**差异显著性检验的方法。
- ◆ 按因素划分，可分为**单因素方差分析**、双因素方差分析和多因素方差分析。单因素方差分析是对因素的主效应进行分析，而双因素方差分析与多因素方差分析则对因素的主效应和它们的相互作用进行分析。
- ◆ 方差分析**要求数据服从正态分布**。



方差分析

◆ 基本思想

- 反应测量数据变异性的指标有多个，在方差分析中选用**方差**来度量**资料的变异程度**。
- 在一次实验中，可以得到一系列不同的观测值。测量数据的总变异（即**总方差**）按照变异来源分为处理（**组间**）效应和误差（**组内**）效应，要正确认识观测值的变异是由于处理效应还是误差效应引起的，需要分别计算出处理效应的方差以及误差效应的方差，在一定显著水平下进行比较，如果二者相差不大，说明实验处理对观测值的影响不大；如果差异较大则说明实验处理对于观测的影响较大。

◆ 将基因在样本间的总变异分解为

- 组间变异：不同条件导致的基因表达的差异
- 组内变异：个体差异和测量引起的随机误差



方差分析

$$SS_{\text{总}} = \sum_i \sum_j (x_{ij} - \bar{x})^2$$

$$SS_{\text{组间}} = \sum_i n_i (\bar{x}_i - \bar{x})^2$$

$$SS_{\text{组内}} = \sum_i \sum_j (x_{ij} - \bar{x}_i)^2$$

- $SS_{\text{总}}$ ：总离均差平方和
- $SS_{\text{组间}}$ ：组间离均差平方和
- $SS_{\text{组内}}$ ：组内离均差平方和
- x_{ij} ：某基因在第*i*组第*j*个样本中的表达值
- $\bar{x}$ ：某基因在所有样本中的表达均值
- $\bar{x}_i$ ：某基因在第*i*组的样本中的表达均值
- n_i ：第*i*组的样本数



差异表达分析

方差分析

$$MS_{\text{组间}} = \frac{SS_{\text{组间}}}{v_{\text{组间}}}$$

$$MS_{\text{组内}} = \frac{SS_{\text{组内}}}{v_{\text{组内}}}$$

$$F = \frac{MS_{\text{组间}}}{MS_{\text{组内}}}$$

- $MS_{\text{组间}}$ ：组间方差
- $MS_{\text{组内}}$ ：组内方差
- N ：样本总数
- k ：分组数
- $v_{\text{组间}} = k - 1$
- $v_{\text{组内}} = N - k$

- ◆ 根据统计量 F ，得到 p 值，设定假设检验水平为 α ，当 $p < \alpha$ 时，认为该基因在不同条件下的表达差异具有统计学意义
- ◆ R语言实现：**aov**(formula, data = NULL, projections = FALSE,...)



Kruskal-Wallis检验

- ◆ 克鲁斯卡尔-沃利斯检验(Kruskal-Wallis H test)亦称 “K-W检验” 、 “H检验” 等, 是用于推断**计量资料或等级资料**的**多个**独立样本所来自的多个总体分布是否有差别的**非参数检验**。
- ◆ 被检验的几个样本必须是独立的或不相关的。
- ◆ K-W检验**不假设样本来自正态分布**。
- ◆ 在理论上K-W检验原假设 H_0 应为多个总体分布相同, 即多个样本来自同一总体, 原假设被拒绝意味着至少一个样本的总体分布不同于其他样本。
- ◆ R语言实现: **kruskal.test**(formula, data, subset, na.action, ...)



多重假设检验

- ◆ I型错误（假阳性）：在假设检验作推断结论时，拒绝了实际上正确的检验假设，即将无差异表达的基因判断为差异表达。
- ◆ II型错误（假阴性）：不拒绝实际上不正确的，即将有差异表达的基因判断为无差异表达。
- ◆ 假定表达谱包含 n 个基因，整个差异基因筛选需要做 n 次假设检验，若每次假设检验发生假阳性的概率为 p ，则在这个差异基因筛选过程中至少有一个基因是假阳性的概率为 $P = 1 - (1 - p)^n$ ，由于 n 较大，导致 P 较大。
- ◆ 多重假设检验带来的放大的假阳性率，需要进行纠正。常用的纠正策略有Bonferroni校正、控制FDR（false discovery rate）值、BH校正等。
- ◆ R语言实现：`p.adjust(p, method = p.adjust.methods, n = length(p))`。p.adjust.methods可选("holm", "hochberg", "hommel", "bonferroni", "BH", "BY", "fdr", "none")



常用差异表达分析工具比较

工具	版本	标准化方式	模型假设	统计检验
edgeR	3.18.1	TMM/Upper quartile/RLE	负二项分布	Exact test
DESeq2	1.16.1	DESeq sizeFactors	负二项分布	Wald test/LRT
baySeq	2.10.0	quantile/TMM/total	负二项分布	empirical Bayesian
NOIseq	2.20.0	RPKM/TMM/Upper quartile	非参数	Condition vs. null
Limma	3.32.10	TMM	voom 转换	Empirical Bayes
Cuffdiff2	2.2.1	Geometric/quartile/FPKM	β 负二项分布	t-test
EBSeq	1.16.0	DESeq median normalization	负二项分布	empirical Bayesian



常用差异表达分析工具比较

- ◆ **limma** 在大多数实验中表现良好，且运行速度很快
- ◆ **DESeq** 和 **edgeR** 在显著性值排序上与 **limma**表现相似，但是对于 **FDR 的控制似乎过于宽松**
- ◆ **SAMseq** 在FDR控制表现良好，但是需要10个以上的生物学重复才能达到可接受的检测灵敏度
- ◆ **NOISeq** 和 **NOISeqBIO** 可以有效控制假阳性，同时牺牲了部分灵敏度，但是在不同处理条件生物学重复数不同的情况下表现良好
- ◆ **Cuffdiff** 和 **Cuffdif2** 可以分析转录本水平的差异表达，但是表现不如人意，这也从侧面反映了转录本水平的reads比对分配问题仍然没有得到很好的解决，类似的异构体水平分析工具还有 **EBseq**等。
- ◆ 上述提及的分析工具大多只能进行成对比较，而**Next maSigPro**、**DyNB**、**Ballgown** 和 **EBSeq-HMM** 等工具可以分析时间序列的 **RNA-seq** 数据。



差异表达分析

limma差异表达分析

limma (Linear Models for Microarray Data) 是基因表达分析的金标准工具，最初为微阵列设计，后通过voom方法扩展支持RNA-seq数据。其核心优势在于线性模型+经验贝叶斯收缩，特别适合大样本 ($n>10$) 或多组比较场景

The screenshot shows the Nucleic Acids Research journal website. The header includes the journal logo and navigation links: Issues, Section browse, More Content, Submit, Purchase, About, and a search bar. A banner below the header states: "NEW: We have upgraded our email alerts. You can sign up using the 'Email alerts' panel available on most pages, or in your Oxford Academic personal account." The main content area features a journal article titled "limma powers differential expression analyses for RNA-sequencing and microarray studies" by Matthew E. Ritchie, Belinda Phipson, Di Wu, Yifang Hu, Charity W. Law, Wei Shi, and Gordon K. Smyth. The article is from Volume 43, Issue 7, published on 20 April 2015. The page includes a thumbnail of the journal cover, the article title, authors, publication date, and a link to the full text. At the bottom, there are icons for PDF, Split View, Cite, Permissions, and Share.

Nucleic Acids Research

Issues Section browse More Content Submit Purchase About Nucleic Acids Research

NEW: We have upgraded our email alerts. You can sign up using the 'Email alerts' panel available on most pages, or in your Oxford Academic personal account.

JOURNAL ARTICLE

limma powers differential expression analyses for RNA-sequencing and microarray studies

Matthew E. Ritchie, Belinda Phipson, Di Wu, Yifang Hu, Charity W. Law, Wei Shi, Gordon K. Smyth

Nucleic Acids Research, Volume 43, Issue 7, 20 April 2015, Page e47, <https://doi.org/10.1093/nar/gkv007>

Published: 20 January 2015 Article history

Article Contents

PDF Split View Cite Permissions Share



差异表达分析

scalpels_ bilibili



R语言实现TCGA数据分析



scalpels_

https://www.bilibili.com/video/BV1fh411g7HS/?spm_id_from=333.337.search-card.all.click&vd_source=2e9fa19be80bc6ffd38f90d60b9205da

明德至诚 博学远志



差异表达分析

第一步：转换为 $\log(\text{ratio})$ 数据形式

聚类分析是为了鉴定表达模式上发生共同变化趋势的基因，这些基因有可能是功能相同，共同调控的基因。聚类分析是在鉴定完毕差异表达基因的基础上做的。

数据形式为 $\log_2(\text{sample1}/\text{sample2})$



Gene X in sample (stress) 表达水平是 800

Gene X in sample (control) 表达水平是 200

$\log_2(800/200) = \log_2(4) = 2$ ，变化倍数为4，**正调控基因**，用红色表示“red”

Gene Y in sample (stress) 表达水平是 200

Gene Y in sample (control) 表达水平是 800

$\log_2(200/800) = \log_2(1/4) = -2$ ，变化倍数为4，**负调控基因**，用绿色表示“green”


$\log_2(400/400) = \log_2(1) = 0$ ，表达无变化，用黑色表示 “black”

ID	A/control	B/control	C/control	D/control
Gene 1	-2.3	-3.4	0	0.02
Gene 2	-10.2	3.9	0.01	1.03
Gene 3	2.4	2.01	3.1	1.2



差异表达分析

第二步：计算基因对间相关系数并聚类




Correlation matrix for any pair of genes

	1	2	3	4	5	6	7	8	9	10
1	1	0.00000	0.80178	0.61237	0.61237	0.91218	0.25000	0.40825	0.40825	0.37500
2	0.00000	1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
3	0.80178	0.00000	1	0.76376	0.21822	0.97590	0.53452	0.87287	0.32733	0.80178
4	0.61237	0.00000	0.76376	1	0.16667	0.74536	0.40825	0.66667	-0.16670	0.61237
5	0.61237	0.00000	0.21822	0.16667	1	0.37268	-0.61230	-0.16670	-0.16670	-0.61237
6	0.91287	0.00000	0.97590	0.74536	0.37268	1	0.45644	0.74536	0.37268	0.68465
7	0.25000	0.00000	0.53452	0.40825	-0.61240	0.45644	1	0.61237	0.61237	0.25000
8	0.40825	0.00000	0.87287	0.66667	-0.16670	0.74536	0.61237	1	0.16667	0.91856
9	0.40825	0.00000	0.32733	-0.16670	-0.16670	0.37268	0.61237	0.16667	1	-0.10210
10	0.37500	0.00000	0.80178	0.61237	0.10206	0.68465	0.25000	0.91856	-0.10210	1

表达变化趋势相同的一对基因具有高相关性，
Pearson correlation，线性相关

具有相关系数较高的基因
会聚类在一起

Hierarchical
Clustering Algorithm




明德至诚 博学远志



差异表达分析


基因表达模式





转录调控影响基因表达模式

不同基因在各组织中受到差异化转录调控



多组织
表达基因



管家基因与组织特异基因

管家基因 House-Keeping Genes	组织特异基因 Tissue-Specific Genes
Functional in all cell types	Functional in only certain cell types
Expressed constitutively	Expressed only when needed
Expression is not regulated	Expression is regulated by regulatory proteins, hormones, etc, as required under certain conditions
Needed for essential basic cellular activities	Needed for specific cellular activities
Genes coded for enzymes of glycolysis are active in all cell types throughout the life	Genes expressed only in specific conditions

https://www.majordifferences.com/2013/10/difference-between-house-keeping-and_4.html




差异表达分析

管家基因与组织特异基因

管家基因与组织特异基因示例

	 Developing red blood cell	 Eye lens cell (in embryo)	 Pancreatic cell
Hemoglobin gene	ON	OFF	OFF
Crystallin gene	OFF	ON	OFF
Insulin gene	OFF	OFF	ON
rRNA gene	ON	ON	ON

<https://slideplayer.com/slide/5337297/>



<https://biologywise.com/the-importance-of-housekeeping-genes>



差异表达分析


GO terms specific for HK & TS genes

GO terms	GO ID	Description	% of HK genes	% of TS genes
HK genes	GO:0006412	protein biosynthesis	29.1	-
	GO:0003735	structural constituent of ribosome	23.3	-
	GO:0005840	ribosome	18.4	-
	GO:0005842	cytosolic large ribos. subunit (sensu Euk.)	10.7	-
	GO:0030529	ribonucleoprotein complex	4.9	-
	GO:0006414	translational elongation	3.9	-
	GO:0005615	extracellular space	-	14.8
TS genes	GO:0004295	trypsin activity	-	8.4
	GO:0004263	chymotrypsin activity	-	8.4
	GO:0005576	extracellular region	-	6.7
	GO:0006810	transport	-	6.6
	GO:0008233	peptidase activity	-	6.6



差异表达分析

Differential gene expression profiles




Differential Expression Profile of NLRs and AIM2 in Glioma and Implications for NLRP12 in Glioblastoma. *Scientific Reports* 2019



差异表达分析

Circadian gene

Circadian genes are defined as genes whose protein products are necessary components for the **generation and regulation of circadian rhythms**.





福州大学
FUZHOU UNIVERSITY

医工交叉研究院

INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

5. 基于多组学数据的疾病分类

明德至诚 博学远志



基于多组学数据的疾病分类

疾病分类的常见任务

pan-cancer 多分类，即区分不同癌种。例如对BRCA、LUAD等多种癌症进行分类。

单癌种内部的分子亚型分类。例如在 BRCA、LUAD、LIHC 内部分亚型。

诊断性二分类/多分类。如BRCA的肿瘤与非肿瘤。




差异表达分析

疾病分类的常见方法

□ 传统机器学习

这是 TCGA 多组学分类最稳妥、最容易复现的一类路线。典型做法是先对各组学分别做特征筛选或降维，再把特征拼接或分层融合，最后用 SVM、Random Forest、XGBoost、Elastic Net、逻辑回归 等分类器建模。



它的优势是对中小样本、高维数据更稳，解释也相对直接；劣势是对跨组学非线性关系的建模能力有限。





差异表达分析

疾病分类的常见方法

□ 表示学习 / 深度学习

这类方法先为每种组学学习低维表示，再做分类，核心代表是 Autoencoder、Variational Autoencoder (VAE)、多分支 MLP/CNN。

MOFA/MOFA+ 更偏统计表示学习与可解释降维，适合先找潜在因子、再接下游分类；XOmivAE 是偏可解释的 VAE 分类模型；还有研究直接用 VAE/MMD-VAE 对 TCGA 卵巢癌等多组学数据做样本识别、亚型聚类 and 分类。






差异表达分析

疾病分类的常见方法

□ 图机器学习 / 图神经网络

多组学数据天然带有“关系结构”：基因—基因、蛋白—蛋白、患者—患者、通路—通路之间都不是独立的。

代表性方法里，MOGONET 很典型：它用图卷积网络整合多组学，用于生物医学分类任务，并兼顾生物标志物识别；近两年也出现了更多 multi-view GNN、graph attention、hierarchical GNN 变体，重点解决多模态关系建模和解释性问题。







差异表达分析

疾病分类的常见方法

□ 更广义的“AI”方法

对比学习、自监督预训练、迁移学习、生成式模型、foundation-model 风格的表征学习。






基于多组学数据的疾病分类

TCGA简介

- ◆ 肿瘤基因组图谱 (The Cancer Genome Atlas, TCGA)计划由美国 National Cancer Institute(NCI) 和 National Human Genome Research Institute (NHGRI) 于2006年联合启动。目前收录了来自 11,000 个病人, 33个癌症的数据, 2.5P的数据量。





基于多组学数据的疾病分类

TCGA数据下载——UCSC Xena

Explore TCGA, GDC, and other public cancer genomics resources

Mary Goldman · 6 March 2019



Discover new trends and validate your findings with 1500+ datasets and 50+ cancer types.

We provide interactive online visualization of seminal cancer genomics datasets, including data from The Cancer Genome Atlas (TCGA), International Cancer Genome Consortium (ICGC), and Genomic Data Commons (GDC). We also visualize the UCSC RNA-seq compendium which contains data from TCGA tumor samples, TCGA normal samples, and GTEx normal samples.

Xena supports virtually any functional genomics data, including SNVs, INDELs, large structural variants, copy number variation, gene-, transcript-, exon-, miRNA-, lncRNA-, protein-expressions, DNA methylation, ATAC-seq signals, phenotypic/clinical annotations, and higher-level derived genomic parameters.



Learn More about the public data we host

Launch Xena



◆ UCSC Xena中不仅包含TCGA数据，还包含ICGC、CCLE等其他数据资源。

◆ <https://xena.ucsc.edu/public/>

◆ 通过“Launch Xena”进入数据下载页面

明德至诚 博学远志



基于多组学数据的疾病分类

TCGA数据下载——UCSC Xena

◆ 选择数据中心和癌症类型

UNIVERSITY OF CALIFORNIA
SANTA CRUZ

1 DATA SETS VISUALIZATION TRANSCRIPTS DATA HUBS VIEW MY DATA HELP MORE TOOLS

42 Cohorts, 534 Datasets

- GDC MMRF-COMMPASS (6 datasets)
- GDC Pan-Cancer (PANCAN) (13 datasets)
- GDC TARGET-ALL-P3 (6 datasets)
- GDC TARGET-AML (6 datasets)
- GDC TARGET-CCSK (6 datasets)
- GDC TARGET-NBL (5 datasets)
- GDC TARGET-OS (6 datasets)
- GDC TARGET-RT (6 datasets)
- GDC TARGET-WT (6 datasets)
- GDC TCGA Acute Myeloid Leukemia (LAML) (15 datasets)
- GDC TCGA Adrenocortical Cancer (ACC) (14 datasets)
- GDC TCGA Bile Duct Cancer (CHOL) (14 datasets)
- GDC TCGA Bladder Cancer (BLCA) (14 datasets)
- GDC TCGA Breast Cancer (BRCA) (15 datasets) 3
- GDC TCGA Cervical Cancer (CESC) (14 datasets)
- GDC TCGA Colon Cancer (COAD) (15 datasets)
- GDC TCGA Endometrioid Cancer (UCEC) (15 datasets)

Active Data Hubs

- ☐ My computer hub
- ☐ UCSC Public Hub
- ☐ TCGA Hub
- ☐ Pan-Cancer Atlas Hub
- ☐ ICGC Hub
- ☐ PCAWG Hub
- ☐ UCSC Toil RNA-seq Recompute
- ☐ Treehouse Hub
- 2 ☒ GDC Hub
- ☐ ATAC-seq Hub
- ☐ Kids First Hub
- ☐ jupyter notebook



基于多组学数据的疾病分类

cohort: GDC TCGA Breast Cancer (BRCA)

VISUALIZE

copy number

[Copy Number Segment \(n=1,111\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

[Masked Copy Number Segment*](#) (n=1,111) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

copy number (gene-level)

[GISTIC - focal score by gene \(n=1,104\)](#) GDC Hub

The GDC GISTIC copy number dataset is derived from focal copy number estimates. Larger chromosomal-level deletions may not be captured in this dataset. More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

DNA methylation

[Illumina Human Methylation 27 \(n=342\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Methylation_LO_Pipeline/

[Illumina Human Methylation 450 \(n=890\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Methylation_LO_Pipeline/

gene expression RNAseq

[HTSeq - Counts \(n=1,217\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

[HTSeq - FPKM \(n=1,217\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

[HTSeq - FPKM-UQ*](#) (n=1,217) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

明德至诚 博学远志



基于多组学数据的疾病分类

phenotype

Phenotype (n=1,284) GDC Hub

survival data (n=1,260) GDC Hub

somatic mutation (SNPs and small INDELs)

MuSE Variant Aggregation and Masking (n=983) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

MuTect2 Variant Aggregation and Masking* (n=986) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

SomaticSniper Variant Aggregation and Masking (n=975) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

VarScan2 Variant Aggregation and Masking (n=986) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

stem loop expression

miRNA Expression Quantification (n=1,202) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/miRNA_Pipeline/



基于多组学数据的疾病分类

数据类型

(1) 基因表达数据 (RNA-seq)

数据矩阵: 基因 × 样本 (行是基因, 列是样本)

常用数据:

- FPKM / TPM (标准化表达量)
- **counts (原始读数, 适合差异分析)**
- 用途: 基因表达谱可用于区分癌症亚型或正常/肿瘤样本

gene expression RNAseq

[HTSeq - Counts \(n=1,217\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

[HTSeq - FPKM \(n=1,217\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

[HTSeq - FPKM-UQ* \(n=1,217\)](#) GDC Hub

More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

(2) 甲基化数据 (DNA Methylation)

数据矩阵: CpG位点 × 样本 (行是甲基化探针, 列是样本)

常用平台: Illumina 450K/EPIC

用途: 甲基化水平可用于表观遗传分类

Probe	TCGA-A1-A0SB-01A	TCGA-A1-A0SD-01A
cg00050873	0.83	0.12
cg00212031	0.45	0.67



基于多组学数据的疾病分类

数据类型

(3) 拷贝数变异 (CNV)

数据矩阵: 基因/基因组区域 × 样本 (行是基因, 列是样本)

常用数据:

GISTIC2 处理后的数据 (-2=深度缺失, -1=缺失, 0=正常, 1=增益, 2=扩增)

用途: 拷贝数变化可用于识别驱动基因和分子亚型。

Gene_Symbol	TCGA-XX-XXXX	TCGA-YY-YYYY
TP53	-1	0
EGFR	0.58	-0.3

(4) 体细胞突变 (SNV/Indel)

数据格式: 通常存储为MAF文件 (Mutation Annotation Format)

关键信息:

- Hugo_Symbol (基因名)
- Variant_Classification (突变类型, 如错义突变、无义突变)

用途: 可用于突变特征分析和分类。

Hugo_Symbol	Chromosome	Start_Position	Reference_Allele	
Tumor_Seq_Allele Variant_Classification				
TP53	17	7579474	G	A
Missense_Mutation				
EGFR	7	55259515	C	T
Nonsense_Mutation				

(5) 蛋白质组数据 (RPPA)

数据矩阵: 蛋白质/磷酸化位点 × 样本 (行是蛋白, 列是样本)

用途: 蛋白活性可用于功能亚型分类。

Sample_ID	TCGA-A1-A0SB-01A	TCGA-A1-A0SD-01A
AKT_pS473	0.85	-0.12
ERK1_pT202	1.34	0.45



基于多组学数据的疾病分类

phenotype

Phenotype (n=1,284) GDC Hub

survival data (n=1,260) GDC Hub

(1) 患者基本信息

字段名	说明
patient_id	患者唯一ID (如 TCGA-XX-XXXX)。
gender	性别 (Male / Female)。
age_at_diagnosis	诊断年龄 (单位: 天或年, 需注意单位)。
race	种族 (如 White、Asian、Black or African American)。
vital_status	生存状态 (Alive / Dead)。

(3) 治疗信息

字段名	说明
treatment_type	治疗类型 (如 Chemotherapy、Radiation Therapy)。
drug_name	药物名称 (如 Paclitaxel)。
days_to_treatment	从诊断到治疗的天数 (可能为负数, 表示术前治疗)。

数据类型

(2) 肿瘤特征与分期

字段名	说明
tumor_stage	肿瘤分期 (如 Stage I、Stage IIA)。
tumor_grade	肿瘤分级 (如 G1 - G4, 分化程度)。
histological_type	组织学类型 (如 Infiltrating Ductal Carcinoma)。
primary_site	原发部位 (如 Breast、Lung)。

(4) 生存数据 (关键分析字段)


字段名	说明
days_to_last_followup	末次随访时间 (天)。
days_to_death	死亡时间 (天, 仅当 vital_status = Dead 时有效)。
overall_survival	总生存期 (OS, 通常需结合 vital_status 计算)。
progression_free_survival	无进展生存期 (PFS, 部分数据集提供)。

明德至诚 博学远志



基于多组学数据的疾病分类

实验项目流程



(1) 癌症 vs 正常样本分类

数据: RNA-seq

步骤:

- 选择差异表达基因 (DEG, 如 DESeq2)
- 训练随机森林分类器
- 评估AUC-ROC

(2) 癌症分子亚型分类

数据: RNA-seq + 甲基化

步骤:

- 使用 MOFA 降维
- 聚类 (如 k-means)
- 用SVM分类新样本

(3) 预后分类 (高低风险组)

数据: RNA-seq + CNV + 临床数据

步骤:

- Cox回归筛选特征
- 构建多组学风险评分
- 用XGBoost分类



差异表达分析

年龄预测

NGDC EWAS Data Hub @EWAS Open Platform

Probes & Genes Samples Download Statistics Help EWAS Atlas

It is highly recommended that you download the dataset using a dedicated FTP tool, such as FileZilla Client .
Host address: <ftp://download.big.ac.cn/ewas/datahub/download/>

Description	Download (.txt & .RData)	File Size
DNA methylation profiles of 31 organism parts	tissue_methylation.zip	7.7 GB
Sample information of DNA methylation profiles of 31 organism parts	sample_tissue_methylation.zip	62.2 KB
DNA methylation profiles of 25 brain parts	brain_methylation.zip	2.77 GB
Sample information of DNA methylation profiles of 25 brain parts	sample_brain_methylation.zip	27.2 KB
DNA methylation profiles 25 blood cell types	blood_methylation.zip	4.86 GB
Sample information of DNA methylation profiles 25 blood cell types	sample_blood_methylation.zip	41.8 KB
DNA methylation profiles of male and female in 24 tissues	sex_methylation.zip	4.33 GB
Sample information of DNA methylation profiles of male and female in 24 tissues	sample_sex_methylation.zip	38 KB
DNA methylation changes with age	age_methylation.zip	11.73 GB
Sample information of DNA methylation changes with age	sample_age_methylation.zip	89.3 KB
DNA methylation profiles of 6 ancestry categories	ancestry_category_methylation.zip	1.96 GB
Sample information of DNA methylation profiles of 6 ancestry categories	sample_ancestry_category_methylation.zip	20.9 KB
DNA methylation changes with BMI	bmi_methylation.zip	3.06 GB
Sample information of DNA methylation changes with BMI	sample_bmi_methylation.zip	28.4 KB
DNA methylation profiles of 39 cancers	cancer_methylation.zip	16.07 GB
Sample information of DNA methylation profiles of 39 cancers	sample_cancer_methylation.zip	117.3 KB
DNA methylation profiles of 28 diseases	disease_methylation.zip	20.11 GB
Sample information of DNA methylation profiles of 28 diseases	sample_disease_methylation.zip	154.1 KB

DNA甲基化值 (样本ID、探针ID、甲基化值)

样本meta信息 (样本ID、年龄、组织等信息)

<https://ngdc.cncb.ac.cn/ewas/datahub/download>

明德至诚 博学远志



基于多组学数据的疾病分类

大作业：基于多组学数据的癌症分类

- 1、TCGA数据库中的肿瘤数据（可自行选择一种或多种癌症）、DNA甲基化芯片年龄数据
- 2、转录组、DNA甲基化组、基因组结合临床信息等数据
- 3、算法选择：传统机器学习算法、深度学习算法等
- 4、对分类准确度进行评估、对年龄回归要计算MSE等
- 5、以小组为单位提交一份研究报告（题目、摘要、背景、内容（方法、结论）、总结）
- 6、5-8人一个小组，在在线文档填写小组成员信息【腾讯文档】生信小组分组及成员



生信小组分组及成员
扫一扫二维码打开或分享...



<https://docs.qq.com/sheet/DZnRmcUp5c2RjQWt6?tab=BB08J2>